

Modelo de Reporte EDA - Supervivencia en el Titanic

Hiter Frank Rubio Peralta
Alumno

Curso:
Introduccion a Ciencia de Datos e Inteligencia Artificial

19 de Septiembre del 2026

**CIENCIA DE DATOS E
INTELIGENCIA ARTIFICIAL**

+51 936 603 314
hiter.rubio@utec.edu.pe

Tabla de contenidos

Resumen	4
1. Planteamiento del problema	4
2. Contexto del dataset	4
2.1. Fuente y unidad de analisis	4
2.2. Diccionario de variables	4
3. Carga y exploracion inicial	5
3.1. Dimensiones y tipos de variables	5
3.2. Calidad de datos	6
3.3. Rangos y valores atipicos	6
4. Preprocesamiento y decisiones de data wrangling	7
4.1. Revision de fuga de informacion	7
4.2. Tratamiento de valores faltantes	8
4.3. Variable derivada para la comunicacion	9
5. Analisis exploratorio de datos	9
5.1. Analisis univariado	9
5.2. Analisis multivariado	13
6. Conclusiones	18
7. Limitaciones y consideraciones eticas	19
Herramientas utilizadas	19

Listado de Tablas

1. Tipo de dato y cantidad de valores no nulos por variable.	5
2. Variables con valores faltantes, en cantidad y porcentaje.	6
3. Estadisticos descriptivos de las variables numericas.	7
4. Tabulacion cruzada entre <code>alive</code> y la variable objetivo <code>survived</code>	7
5. Tabulacion cruzada entre <code>class</code> y <code>pclass</code> : la misma informacion en dos formatos.	8
6. Medidas de centralidad y dispersion de las variables numericas.	12
7. Correlacion de cada variable numerica con <code>survived</code> , ordenada por magnitud.	15
8. Matriz de covarianza entre las variables numericas.	18

Listado de Figuras

1. Distribucion de la variable objetivo. El conjunto esta desbalanceado.	10
2. Distribucion de las variables numericas.	11
3. Dispersion y valores extremos de las variables numericas.	12
4. Frecuencia de las variables categoricas.	13

5.	Matriz de correlacion entre las variables numericas y el objetivo.	14
6.	Distribucion de edad y precio del pasaje segun el desenlace.	16
7.	Porcentaje de supervivencia por sexo y por clase de pasaje.	17
8.	Relacion entre edad y precio del pasaje, diferenciada por desenlace.	18

```
# -----
# Configuracion unica para todo el documento.
# Todo lo que se repite (colores, estilo, funciones de apoyo) se define aqui
# una sola vez, para no ensuciar los chunks de analisis.
# -----

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from IPython.display import Markdown

# Paleta fija del reporte: dos colores para la variable objetivo y un gris
# neutro para las series unicas. El orden nunca cambia entre graficos, de modo
# que "azul" significa lo mismo en todo el documento.
AZUL, AMBAR, GRIS = "#1F5FA9", "#C2701A", "#4B5563"
COLORES_OBJETIVO = {"No sobrevivio": AZUL, "Sobrevivio": AMBAR}

sns.set_theme(style="whitegrid")
plt.rcParams.update({
    "figure.dpi": 150,
    "axes.spines.top": False,      # menos tinta: se quitan los bordes
    "axes.spines.right": False,   # superior y derecho de cada grafico
    "axes.titlesize": 11,
    "axes.titleweight": "bold",
    "axes.labelsize": 9,
    "xtick.labelsize": 8,
    "ytick.labelsize": 8,
    "legend.fontsize": 8,
    "grid.alpha": 0.25,           # rejilla discreta, de fondo
})

def tabla(df, decimales=2):
    """Muestra un DataFrame como tabla con formato correcto en el PDF."""
    return Markdown(df.round(decimales).to_markdown())
```

Resumen

Este reporte aplica un analisis exploratorio de datos sobre el conjunto *Titanic* distribuido con la libreria seaborn (Waskom 2024), compuesto por 891 pasajeros y 15 variables, con el objetivo de identificar que características del pasajero se asocian con la supervivencia. El trabajo de preparacion tomo tres decisiones centrales: se descarto la variable `deck` por tener 688 valores faltantes de 891 registros; se conservaron los 107 registros duplicados al verificar que corresponden a pasajeros distintos sin identificador unico y no a errores de captura; y se excluyeron cinco variables redundantes (`alive`, `class`, `who`, `adult_male`, `embark_town`) por reproducir informacion ya contenida en otras columnas, siendo `alive` un caso de fuga de informacion directa sobre la variable objetivo. El analisis muestra un conjunto desbalanceado (38.4% de sobrevivientes), una diferencia marcada de supervivencia por sexo (74.2% en mujeres frente a 18.9% en hombres) y un gradiente claro por clase de pasaje (63.0%, 47.3% y 24.2% de primera a tercera). Ninguna variable numerica supera por si sola una correlacion de 0.34 con el objetivo, lo que anticipa que un modelo predictivo necesitara combinar varios predictores en lugar de apoyarse en uno solo.

1. Planteamiento del problema

El hundimiento del RMS Titanic en 1912 dejo un registro de pasajeros que se ha convertido en un caso de estudio clasico para el analisis exploratorio, porque combina variables demograficas, economicas y de contexto familiar sobre un desenlace binario y bien documentado. La pregunta no es historica sino metodologica: cuando un resultado depende de multiples factores que ademas estan relacionados entre si, el analisis exploratorio es el paso que permite distinguir que variables aportan informacion y cuales solo repiten lo que otras ya dicen (Tukey 1977).

Para este reporte se formula la siguiente pregunta de analisis:

Que características del pasajero (demograficas, economicas y de contexto familiar) se asocian con la supervivencia en el conjunto de datos?

Este documento no entrena modelos predictivos. Su finalidad es explorar los datos, documentar su calidad y justificar que variables quedan disponibles para una etapa posterior de modelamiento.

2. Contexto del dataset

2.1. Fuente y unidad de analisis

El archivo corresponde al conjunto *Titanic* incluido en la libreria seaborn (Waskom 2024), derivado a su vez del registro historico de pasajeros del naufragio. Cada fila representa a un pasajero y contiene informacion demografica, economica y de contexto familiar, junto con el desenlace del viaje.

La unidad de analisis es el pasajero.

2.2. Diccionario de variables

- **Objetivo:** `survived` es binaria: 0 significa *no sobrevivio* y 1 significa *sobrevivio*.
- **Demografia:** `age` (numerica) y `sex` (categorica).
- **Economia:** `pclass` (categorica ordinal: 1, 2 o 3) y `fare` (numerica, el precio del pasaje).

- **Contexto familiar:** sibsp (numero de hermanos o conyuge a bordo) y parch (numero de padres o hijos a bordo), ambas numericas de conteo.
- **Embarque:** embarked (categorica: S, C o Q).
- **Variables redundantes:** alive, class, who, adult_male, embark_town y alone reproducen informacion ya contenida en las columnas anteriores. Se auditan en la seccion Sección 4.1 antes de descartarlas.
- **Variable con alta ausencia:** deck registra la cubierta del camarote y esta mayormente vacia.

3. Carga y exploracion inicial

3.1. Dimensiones y tipos de variables

```
df = pd.read_csv("datos/titanic.csv")

print(f"Filas: {df.shape[0]}    Columnas: {df.shape[1]}")
```

Filas: 891 Columnas: 15

```
resumen_tipos = pd.DataFrame({
    "tipo": df.dtypes.astype(str),
    "no_nulos": df.notna().sum(),
    "nulos": df.isna().sum(),
})
tabla(resumen_tipos)
```

Tabla 1: Tipo de dato y cantidad de valores no nulos por variable.

	tipo	no_nulos	nulos
survived	int64	891	0
pclass	int64	891	0
sex	str	891	0
age	float64	714	177
sibsp	int64	891	0
parch	int64	891	0
fare	float64	891	0
embarked	str	889	2
class	str	891	0
who	str	891	0
adult_male	bool	891	0
deck	str	203	688
embark_town	str	889	2
alive	str	891	0
alone	bool	891	0

El conjunto tiene 891 filas y 15 columnas. La Tabla 1 confirma que los tipos de dato son coherentes con lo que representa cada variable: las numericas (age, fare, sibsp, parch) estan cargadas como numeros y no como texto, que es el error silencioso mas comun al leer un CSV. Se observa ademas que tres variables tienen valores faltantes, lo que se examina a continuacion.

3.2. Calidad de datos

```
nulos = df.isna().sum()
nulos = nulos[nulos > 0].sort_values(ascending=False)

tabla(pd.DataFrame({
    "faltantes": nulos,
    "porcentaje": (nulos / len(df) * 100),
}))
```

Tabla 2: Variables con valores faltantes, en cantidad y porcentaje.

	faltantes	porcentaje
deck	688	77.22
age	177	19.87
embarked	2	0.22
embark_town	2	0.22

```
print(f"Filas duplicadas: {df.duplicated().sum()}")
```

Filas duplicadas: 107

La Tabla 2 muestra tres situaciones distintas, y cada una exige una decision distinta:

1. deck tiene 688 faltantes sobre 891 registros (77.2%). Imputar el 77% de una columna seria inventar la mayor parte de su contenido, asi que se descarta del analisis.
2. age tiene 177 faltantes (19.9%). Es una proporcion recuperable, pero imputarla exige un criterio explicito; se documenta mas adelante.
3. embarked y embark_town tienen 2 faltantes cada una (0.2%), un volumen despreciable.

Respecto a los 107 duplicados: el conjunto no tiene columna de identificador, de modo que dos pasajeros de tercera clase, varones, sin familiares a bordo y con el mismo pasaje economico producen filas identicas sin ser la misma persona. Se conservan, porque eliminarlos borraría pasajeros reales y distorsionaria la distribucion justamente del grupo mas numeroso.

3.3. Rangos y valores atipicos

```
numericas = ["age", "fare", "sibsp", "parch"]
tabla(df[numericas].describe())
```

Tabla 3: Estadísticos descriptivos de las variables numericas.

	age	fare	sibsp	parch
count	714	891	891	891
mean	29.7	32.2	0.52	0.38
std	14.53	49.69	1.1	0.81
min	0.42	0	0	0
25 %	20.12	7.91	0	0
50 %	28	14.45	0	0
75 %	38	31	1	0
max	80	512.33	8	6

Los rangos de la Tabla 3 son plausibles: la edad va de 0.42 a 80 años (0.42 corresponde a un bebé de cinco meses, no a un error) y el precio del pasaje parte de 0, valor compatible con tripulación o pasajes de cortesía. El máximo de fare es 512.33, muy por encima de la mediana de 14.45, lo que anticipa una distribución fuertemente sesgada. Ningún valor cae fuera de un rango lógico, de modo que no se corrige ni elimina ninguna observación por implausibilidad.

4. Preprocesamiento y decisiones de data wrangling

4.1. Revisión de fuga de información

La fuga de información ocurre cuando una variable predictora contiene, de forma directa o disfrazada, la respuesta que se quiere predecir. Un modelo entrenado con ella alcanza una exactitud casi perfecta en evaluación y falla por completo en uso real, porque en la práctica esa información no existe antes de conocer el desenlace. Por eso se audita antes de cualquier modelamiento.

```
tabla(pd.crosstab(df["alive"], df["survived"]))
```

Tabla 4: Tabulación cruzada entre *alive* y la variable objetivo *survived*.

alive	0	1
no	549	0
yes	0	342

La Tabla 4 es concluyente: las 549 filas con `alive = "no"` corresponden exactamente a `survived = 0`, y las 342 con `alive = "yes"` a `survived = 1`. La correspondencia es perfecta porque `alive` es la misma variable objetivo escrita como texto. Usarla como predictora equivaldría a darle la respuesta al modelo, por lo que se excluye.

```
tabla(pd.crosstab(df["class"], df["pclass"]))
```

Tabla 5: Tabulacion cruzada entre *class* y *pclass*: la misma informacion en dos formatos.

class	1	2	3
First	216	0	0
Second	0	184	0
Third	0	0	491

La Tabla 5 ilustra un caso distinto pero igualmente relevante: *class* no filtra la respuesta, simplemente repite *pclass* en formato de texto. Mantener ambas no aporta informacion nueva y si introduce colinealidad perfecta. El mismo razonamiento aplica a *who* y *adult_male* (derivadas de *sex* y *age*), *embark_town* (equivalente a *embarked*) y *alone* (derivada de *sibsp* y *parch*).

```
# Se excluyen: la fuga (alive), las redundantes y la columna mayormente vacia.
a_excluir = ["alive", "class", "who", "adult_male",
             "embark_town", "alone", "deck"]
datos = df.drop(columns=a_excluir)

print(f"Variables antes: {df.shape[1]} | despues: {datos.shape[1]}")
print("Variables conservadas:", ", ".join(datos.columns))
```

Variables antes: 15 | despues: 8

Variables conservadas: survived, pclass, sex, age, sibsp, parch, fare, embarked

4.2. Tratamiento de valores faltantes

```
# age: se imputa con la mediana, que no se desplaza por los valores extremos.
mediana_edad = datos["age"].median()
datos["age"] = datos["age"].fillna(mediana_edad)

# embarked: solo 2 casos; se usa la categoria mas frecuente.
moda_embarque = datos["embarked"].mode()[0]
datos["embarked"] = datos["embarked"].fillna(moda_embarque)

print(f"age imputada con la mediana: {mediana_edad}")
print(f"embarked imputada con la moda: {moda_embarque}")
print(f"Faltantes restantes: {datos.isna().sum().sum()}")
```

age imputada con la mediana: 28.0

embarked imputada con la moda: S

Faltantes restantes: 0

Se eligio la mediana y no la media para age porque la mediana no se desplaza ante valores extremos. Conviene dejar constancia de que imputar 177 valores con una misma cifra reduce artificialmente la

varianza de la variable, de modo que las conclusiones sobre la dispersion de la edad deben leerse con esa advertencia presente.

4.3. Variable derivada para la comunicacion

```
# Version legible del objetivo, solo para tablas y graficos.
etiquetas = {0: "No sobrevivio", 1: "Sobrevivio"}
datos["estado"] = datos["survived"].map(etiquetas)

print(datos["estado"].value_counts().to_string())
```

```
estado
No sobrevivio    549
Sobrevivio       342
```

estado no agrega informacion: es survived escrito en palabras, y existe unicamente para que las leyendas de los graficos se lean sin consultar el diccionario. Para cualquier calculo o modelamiento se usa la version numerica original.

5. Analisis exploratorio de datos

5.1. Analisis univariado

```
conteo = datos["estado"].value_counts()
porcentaje = datos["estado"].value_counts(normalize=True) * 100

fig, ax = plt.subplots()
barras = ax.bar(conteo.index, conteo.values,
                 color=[COLORES_OBJETIVO[c] for c in conteo.index], width=0.55)

# Etiqueta directa sobre cada barra: evita que el lector tenga que medir
# contra el eje.
for barra, n, pct in zip(barras, conteo.values, porcentaje.values):
    ax.text(barra.get_x() + barra.get_width() / 2, n + 8,
            f"{n} ({pct:.1f}%)", ha="center", fontsize=9, color="#1F2937")

ax.set_ylabel("Pasajeros")
ax.set_ylim(0, conteo.max() * 1.18)
ax.set_title("Supervivencia en el Titanic")
plt.show()
```




Figura 1: Distribucion de la variable objetivo. El conjunto esta desbalanceado.

La Figura 1 muestra 549 pasajeros que no sobrevivieron (61.6%) frente a 342 que si (38.4%). El desbalance es moderado, pero tiene dos consecuencias concretas para una etapa de modelamiento: la particion entre entrenamiento y prueba debe ser estratificada para preservar esa proporcion en ambos conjuntos, y la exactitud (*accuracy*) deja de ser una metrica informativa, porque un modelo que prediga siempre “no sobrevivio” acertaria el 61.6% de las veces sin haber aprendido nada.

```
fig, axes = plt.subplots(2, 2, figsize=(7, 5.5))

for ax, columna in zip(axes.flat, numericas):
    sns.histplot(data=datos, x=columna, bins=30, color=AZUL, ax=ax,
                 edgecolor="white", linewidth=0.5)
    ax.set_title(columna)
    ax.set_xlabel("")
    ax.set_ylabel("Frecuencia")

plt.tight_layout()
plt.show()
```




Figura 2: Distribucion de las variables numericas.

Las cuatro distribuciones de la Figura 2 tienen formas distintas y cada una implica algo diferente:

- age es aproximadamente simetrica y centrada cerca de los 28 años, con una barra alta en ese punto producida por la imputacion.
- fare esta fuertemente sesgada a la derecha: la mayoría de pasajes cuesta menos de 50 y unos pocos superan los 500. Una transformacion logaritmica ayudaria a un modelo lineal.
- sibsp y parch son variables de conteo concentradas en cero: la mayoría viajaba sin familiares a bordo.

La diferencia de escala tambien importa: fare llega a 512 mientras parch no pasa de 6. Cualquier algoritmo basado en distancias exigiria estandarizar antes de entrenar.

```
fig, axes = plt.subplots(1, 4, figsize=(7, 3.4))

for ax, columna in zip(axes, numericas):
    sns.boxplot(data=datos, y=columna, ax=ax, color=AZUL, width=0.45,
                fliersize=2.5, linewidth=1)
    ax.set_title(columna)
    ax.set_ylabel("")
```

```
plt.tight_layout()
plt.show()
```




Figura 3: *Dispersión y valores extremos de las variables numéricas.*

```
resumen = pd.DataFrame({
    "media": datos[numericas].mean(),
    "mediana": datos[numericas].median(),
    "desv_est": datos[numericas].std(),
    "rango": datos[numericas].max() - datos[numericas].min(),
    "Q1": datos[numericas].quantile(0.25),
    "Q3": datos[numericas].quantile(0.75),
})
tabla(resumen)
```

Tabla 6: *Medidas de centralidad y dispersión de las variables numéricas.*

	media	mediana	desv_est	rango	Q1	Q3
age	29.36	28	13.02	79.58	22	35
fare	32.2	14.45	49.69	512.33	7.91	31
sibsp	0.52	0	1.1	8	0	1
parch	0.38	0	0.81	6	0	0

La Figura 3 y la Tabla 6 deben leerse juntos. En *fare*, la media (32.20) duplica largamente a la mediana (14.45): esa distancia entre ambas es la firma numérica del sesgo que el histograma mostro de forma visual. Los 116 puntos por encima del límite superior del bigote (65.63) corresponden a camarotes de lujo, no a errores de captura, de modo que se conservan; eliminarlos borraría justamente

el grupo de primera clase. En age, media (29.36) y mediana (28.00) casi coinciden, lo que confirma una distribucion simetrica.

```

categoricas = ["sex", "pclass", "embarked"]
fig, axes = plt.subplots(1, 3, figsize=(7, 2.8))

for ax, columna in zip(axes, categoricas):
    conteos = datos[columna].value_counts()
    ax.bar(conteos.index.astype(str), conteos.values,
           color=GRIS, width=0.55)
    ax.set_title(columna)
    ax.set_ylabel("Pasajeros" if columna == "sex" else "")

plt.tight_layout()
plt.show()

```




Figura 4: Frecuencia de las variables categoricas.

La Figura 4 muestra que ninguna categoria es tan rara como para volverse problematica: la menos frecuente es el puerto Q con 77 pasajeros, suficiente para estimar proporciones. `pclass` se trata como ordinal, porque el orden $1 < 2 < 3$ tiene significado economico, mientras que `sex` y `embarked` son nominales y requeririan codificacion *one-hot*.

5.2. Analisis multivariado

```

correlaciones = datos[numericas + ["pclass", "survived"]].corr()

# Se recorta la primera fila y la ultima columna (quedarían vacías) y se
# enmascara la mitad superior, que solo repite la inferior.
recortada = correlaciones.iloc[1:, :-1]
mascara = np.triu(np.ones_like(recortada, dtype=bool), k=1)

fig, ax = plt.subplots(figsize=(5.6, 4.2))

```

```
sns.heatmap(recortada, mask=mascara, annot=True, fmt=".2f",
            cmap="RdBu_r", center=0, vmin=-1, vmax=1,
            linewidths=0.5, linecolor="white",
            cbar_kws={"label": "Correlacion"}, ax=ax,
            annot_kws={"size": 8})
ax.set_title("Correlaciones (mitad inferior)")
plt.tight_layout()
plt.show()
```




Figura 5: Matriz de correlacion entre las variables numericas y el objetivo.

Se enmascara la mitad superior porque la matriz es simetrica y mostrarla completa duplica la misma informacion. La escala es divergente y centrada en cero: el color indica el signo y la intensidad indica la fuerza. En la Figura 5 destacan dos pares: pclass con fare (-0.55), esperable porque la primera clase paga mas y esta codificada con el numero menor, y sibsp con parch (0.41), ambas midiendo la presencia de familiares a bordo. Ninguna pareja alcanza niveles de colinealidad severa. Conviene recordar que la correlacion mide asociacion lineal y no implica causalidad.

```
corr_objetivo = (
    datos[numericas + ["pclass", "survived"]]
    .corr()["survived"]
    .drop("survived")
    .sort_values(key=abs, ascending=False)
    .to_frame("correlacion_con_survived")
)
```

```
)  
tabla(corr_objetivo, decimales=3)
```

Tabla 7: *Correlacion de cada variable numerica con survived, ordenada por magnitud.*

	correlacion_con_survived
pclass	-0.338
fare	0.257
parch	0.082
age	-0.065
sibsp	-0.035

La Tabla 7 ordena las variables por fuerza de asociacion: pclass (-0.338) y fare (0.257) encabezan la lista, mientras age (-0.065) y sibsp (-0.035) son practicamente planas. Dos advertencias sobre como leer esta tabla. Primero, ninguna variable pasa de 0.34, de modo que ningun predictor aislado separa las clases y un modelo debera combinarlos. Segundo, esta tabla no incluye sex, que es categorica; como se vera enseguida, es justamente la variable con mayor poder de discriminacion. Una seleccion de variables basada solo en correlaciones numericas habria descartado la mejor senal del conjunto.

```
fig, axes = plt.subplots(1, 2, figsize=(7, 3.2))  
orden = ["No sobrevivio", "Sobrevivio"]  
  
for ax, columna in zip(axes, ["age", "fare"]):  
    sns.boxplot(data=datos, x="estado", y=columna, order=orden,  
                hue="estado", hue_order=orden, palette=COLORES_OBJETIVO,  
                legend=False, ax=ax, width=0.5, fliersize=2.5, linewidth=1)  
    ax.set_title(columna)  
    ax.set_xlabel("")  
  
# Se recorta la cola extrema de fare para poder ver las cajas.  
axes[1].set_ylim(0, 300)  
plt.tight_layout()  
plt.show()
```




Figura 6: Distribucion de edad y precio del pasaje segun el desenlace.

La Figura 6 contrasta dos comportamientos opuestos. En age las dos cajas se solapan casi por completo y ambas medianas coinciden en 28 años: la edad, por si sola, no distingue a los sobrevivientes. En fare la separación si es visible, con una mediana de 10.50 entre quienes no sobrevivieron frente a 26.00 entre quienes si, aunque el solapamiento sigue siendo amplio. El eje de fare se recorto en 300 para que las cajas resulten legibles; el recorte oculta puntos extremos, no los elimina del calculo.

```
fig, axes = plt.subplots(1, 2, figsize=(7, 3.0))

for ax, columna, titulo in zip(axes, ["sex", "pclass"],
                                ["Por sexo", "Por clase de pasaje"]):
    tasa = datos.groupby(columna)["survived"].mean() * 100
    barras = ax.bar(tasa.index.astype(str), tasa.values,
                    color=AMBAR, width=0.55)
    for barra, valor in zip(barras, tasa.values):
        ax.text(barra.get_x() + barra.get_width() / 2, valor + 2,
                f"{valor:.1f}%", ha="center", fontsize=9, color="#1F2937")
    ax.axhline(datos["survived"].mean() * 100, color=GRIS,
               linestyle="--", linewidth=1)
    ax.set_title(titulo)
    ax.set_ylim(0, 100)
    ax.set_ylabel("Supervivencia (%) " if columna == "sex" else "")

plt.tight_layout()
plt.show()
```




Figura 7: Porcentaje de supervivencia por sexo y por clase de pasaje.

La Figura 7 usa proporciones y no conteos, porque los grupos tienen tamanos muy distintos y comparar frecuencias absolutas seria enganioso. La linea punteada marca la tasa general del conjunto (38.4%), lo que permite ver de un vistazo que grupos quedan por encima y cuales por debajo. El contraste por sexo es el hallazgo mas fuerte del reporte: 74.2% de las mujeres sobrevivio frente a 18.9% de los hombres, una diferencia de 55 puntos porcentuales. Por clase se observa un gradiente ordenado: 63.0%, 47.3% y 24.2% de primera a tercera.

```
fig, ax = plt.subplots(figsize=(7, 3.8))

sns.scatterplot(data=datos, x="age", y="fare", hue="estado",
                hue_order=orden, palette=COLORES_OBJETIVO,
                alpha=0.65, s=28, edgecolor="white",
                linewidth=0.4, ax=ax)

ax.set_ylim(0, 300)
ax.set_xlabel("Edad (años)")
ax.set_ylabel("Precio del pasaje")
ax.legend(title="", frameon=False, loc="upper right")
ax.set_title("Edad frente a precio del pasaje")
plt.tight_layout()
plt.show()
```




Figura 8: Relacion entre edad y precio del pasaje, diferenciada por desenlace.

En la Figura 8 no se observa una relacion lineal entre edad y precio: los puntos se reparten sin tendencia definida. Los dos colores se superponen en casi todo el plano, con una leve concentracion de sobrevivientes en la franja de pasajes mas caros. La lectura es la misma que sugirio la tabla de correlaciones: estas dos variables por si solas no separan las clases.

```
tabla(datos[numericas].cov())
```

Tabla 8: Matriz de covarianza entre las variables numericas.

	age	fare	sibsp	parch
age	169.51	62.56	-3.35	-1.81
fare	62.56	2469.44	8.75	8.66
sibsp	-3.35	8.75	1.22	0.37
parch	-1.81	8.66	0.37	0.65

La Tabla 8 confirma el signo de las relaciones: la covarianza entre age y fare es positiva (62.56), es decir, tienden a crecer juntas. Su magnitud, sin embargo, no es interpretable ni comparable entre pares, porque depende de las unidades de cada variable: una covarianza de 62.56 entre años y libras esterlinas no es “mas fuerte” que la de 0.37 entre sibsp y parch, que son dos conteos. Esa es exactamente la razon por la que se reporta junto con la correlacion, que al estar normalizada entre -1 y 1 si permite comparar.

6. Conclusiones

1. **Calidad de datos.** El conjunto presenta faltantes en tres variables, con tratamientos distintos segun su magnitud: deck se descarto (77.2% vacia), age se imputo con la mediana (19.9%) y

embarked con la moda (0.2%). Los 107 duplicados se conservaron por corresponder a pasajeros distintos sin identificador unico.

2. **Desbalance del objetivo.** La clase positiva representa el 38.4% de los registros. Un modelo posterior exige particion estratificada y metricas distintas de la exactitud, como *recall* o F1.
3. **Variables excluidas.** Se descartaron siete columnas: *alive* por fuga de informacion directa, *class*, *who*, *adult_male*, *embark_town* y *alone* por redundancia con variables ya presentes, y *deck* por ausencia masiva de datos.
4. **Variables mas prometedoras.** *sex* es el predictor con mayor poder de discriminacion (55 puntos porcentuales de diferencia), seguido de *pclass* y *fare*. *age*, *sibsp* y *parch* muestran asociaciones debiles de forma aislada, aunque podrian aportar en combinacion con las anteriores.
5. **Advertencia metodologica.** Las correlaciones numericas por si solas habrian pasado por alto a *sex*, que es categorica y resulto ser la variable mas informativa. La seleccion de predictores no puede apoyarse unicamente en una matriz de correlacion.
6. **Hacia el modelamiento.** Un modelo posterior deberia codificar *sex* y *embarked* (*one-hot*), tratar *pclass* como ordinal, estandarizar las numericas si el algoritmo lo requiere y ajustar toda transformacion unicamente sobre los datos de entrenamiento, para no trasladar informacion del conjunto de prueba al de ajuste.

7. Limitaciones y consideraciones eticas

El conjunto no documenta su procedimiento de recoleccion ni el criterio con que se completaron los registros historicos, de modo que no puede asumirse libre de errores de transcripcion. Tampoco es una muestra aleatoria: corresponde a la totalidad de un evento unico, por lo que sus patrones no son extrapolables a otros contextos.

El uso de este conjunto como ejercicio academico no debe hacer perder de vista que cada fila representa a una persona real fallecida o sobreviviente de una catastrofe. Al reportar diferencias por sexo o por clase social, el analisis describe las condiciones de acceso a los botes salvavidas en 1912 y no una propiedad de las personas involucradas. Esta distincion entre describir un patron y explicarlo es la misma que aplica a cualquier analisis sobre datos de personas.

Herramientas utilizadas

El analisis se realizo en Python con *pandas* para la manipulacion de datos (McKinney 2010), *matplotlib* para la generacion de graficos (Hunter 2007) y *seaborn* para los graficos estadisticos (Waskom 2021). Los criterios de organizacion de los datos siguen los principios de *tidy data* (Wickham 2014).

Referencias

Hunter, JD (2007). *Matplotlib: A 2D Graphics Environment*. *Computing in Science & Engineering* 9(3), 90-95.

- McKinney, W (2010). Data Structures for Statistical Computing in Python. En: *Proceedings of the 9th Python in Science Conference*, pp.56-61.
- Tukey, JW (1977). *Exploratory Data Analysis*. Reading, MA: Addison-Wesley.
- Waskom, ML (2021). seaborn: statistical data visualization. *Journal of Open Source Software* **6**(60), 3021.
- Waskom, ML (2024). *seaborn-data: Titanic dataset*. <https://github.com/mwaskom/seaborn-data>.
Conjunto de datos distribuido con la librería seaborn.
- Wickham, H (2014). Tidy Data. *Journal of Statistical Software* **59**(10), 1-23.