

P1 - Uso de Smartphones y Riesgo de Adiccion

Hiter Frank Rubio Peralta

Alumno

Jossep Jorge Froilan Choroco Neyra

Alumno

Joel David De la Cruz Cardenas

Alumno

Rodrigo Octavio Lucatoni Flores Ruiz

Alumno

Victor Andres Diaz Garcia

Alumno

Curso:

Introduccion a Ciencia de Datos e Inteligencia Artificial

22 de Septiembre del 2026

Tabla de contenidos

1. Resumen	3
2. Planteamiento del problema	3
3. Contexto del dataset	3
3.1. Fuente y unidad de análisis	3
3.2. Diccionario de variables	3
4. Carga y exploración inicial	4
4.1. Librerías	4
4.2. Carga de datos	4
4.3. Dimensiones y estructura	5
4.4. Tipos de variables y primeras estadísticas	7
4.5. Calidad de datos	7
5. Preprocesamiento y decisiones de data wrangling	8
5.1. Revisión de fuga de información	8
5.2. Variable derivada para la comunicación	10
6. Análisis exploratorio de datos	11
6.1. Análisis univariado	11
6.2. Análisis multivariado	24
7. Conclusiones de P1	32
8. Limitaciones y consideraciones éticas	32

Listado de Tablas

1. Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.	5
2. Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.	6
3. Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.	7

Listado de Figuras

1. Resumen

*Instrucciones para esta sección: este resumen se escribe **al final**, cuando ya se tengan los resultados de la exploración de datos y las conclusiones de P1. Debe tener entre 150 y 200 palabras e incluir, en este orden: (1) qué dataset se usó y cuántos registros/columnas tiene, (2) el objetivo del análisis (qué se busca entender sobre `etiqueta_de_adiccion`), (3) las dos o tres decisiones de limpieza más importantes que se tomaron y por qué, (4) los dos o tres hallazgos más relevantes del EDA, citando cifras reales obtenidas del código (no inventadas ni copiadas de un borrador), y (5) una frase que conecte con lo que se hará en la P2. No copiar texto de otras secciones; debe ser una síntesis propia, escrita por el equipo.*

2. Planteamiento del problema

El uso intensivo de celulares puede influir en la salud integral de las personas al relacionarse con irregularidades en el sueño, estrés, dificultades en el ámbito académico y laboral. Además, la investigación requiere de una conceptualización alta: una alta frecuencia de uso no significa necesariamente a una condición clínica. Artículos como SABAS permiten estudiar síntomas de uso problemático, pero no sustituyen una evaluación profesional Csibi et al. (2018). La literatura también ayuda con asociaciones entre el uso del smartphone y el desempeño académico, aunque con limitaciones claras para atribuir causalidad Amez y Baert (2020).

Para este proyecto, se formula la siguiente pregunta de análisis:

¿Qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos `smartphone-use-prediction`?

3. Contexto del dataset

3.1. Fuente y unidad de análisis

El archivo `Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv` fue proporcionado para el proyecto y corresponde al dataset publicado como *Smartphone Usage and Addiction Analysis* en Kaggle Nusrat (s.f.). Cada fila representa a un usuario y contiene indicadores demográficos, de comportamiento digital, descanso, estrés e impacto percibido en actividades académicas o laborales.

La unidad de análisis es el usuario. El dataset incluye 7,500 registros y 16 columnas originales: dos identificadores, nueve variables numéricas, cuatro variables categóricas y la etiqueta binaria objetivo.

3.2. Diccionario de variables

- **Identificadores:** `ID_transaccion` y `ID_usuario` son variables de texto. Se usan para verificar unicidad, pero no aportan significado analítico y se excluirán como predictores.
- **Demografía:** `edad` (numérica) y `genero` (categórica) caracterizan la muestra.
- **Uso del smartphone:** `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo_estudio`, `notificaciones_por_dia`, `aperturas_apps_por_dia` y `tiempo_en_pantalla_fin_de_semana` son variables numéricas que miden intensidad y tipo de uso.

- **Bienestar y contexto:** horas_sueño es numérica; nivel_estres y impacto_academico/laboral son categóricas. Se emplean para explorar descanso e impacto funcional.
- **Severidad:** nivel_adiccion es categórica ordinal. Se describe en P1, pero se excluye como predictor en P2 por fuga de información.
- **Objetivo:** etiqueta_de_adiccion es binaria: 0 significa *No adicción* y 1 significa *Con adicción*.

La variable nivel_adiccion contiene una categorización de severidad (None, Mild, Moderate, Severe). Por su definición operativa, puede estar construida directamente a partir de la etiqueta final; por ello se audita explícitamente antes de considerar su uso en P2.

4. Carga y exploración inicial

4.1. Librerías

El primer bloque reúne las librerías necesarias para el proyecto y el estilo de seaborn

```
# =====  
# CONFIGURACIÓN ÚNICA DEL REPORTE  
# Librerías y estilos se ejecutan una sola vez  
# =====  
import pandas as pd  
import numpy as np  
from matplotlib.pyplot import boxplot  
from matplotlib.pyplot import hist  
import matplotlib.pyplot as plt  
import seaborn as sns  
from IPython.display import display, Latex  
import kagglehub  
from scipy import stats  
  
sns.set_theme(style="whitegrid")
```

El segundo bloque, que no se imprime en el PDF para no alargarlo, define funciones de presentación: la función tabla(), que reproduce desde Python el estilo de tabla (kable con booktabs), en el PDF se omite el código que solo dibuja los gráficos, igual que en la plantilla del curso; todo ese código está completo y comentado en Project-Report.qmd. Sí se muestra todo el código que carga, transforma o calcula.

4.2. Carga de datos

Usando la librería de kaggle y os logramos una carga universal exitosa en cualquier equipo y evitamos errores de carga del dataset

```
# Cargamos el archivo csv  
path = (kagglehub.dataset_download  
        ("jayjoshi37/smartphone-usage-and-addiction-prediction"))  
  
import os
```

```
# Ruta directa al archivo CSV combinando la ruta de descarga y el nombre del
# archivo
ruta_csv = (os.path.join(path,
                          "Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv"))
df = pd.read_csv(ruta_csv)
n_filas, n_columnas = df.shape
print(f"Dimensiones: {n_filas:,} filas x {n_columnas} columnas")
```

Dimensiones: 7,500 filas x 16 columnas

El archivo se carga completo, con 7500 filas y 16 columnas. `df` no se modifica en ningún momento: todas las transformaciones posteriores se aplican sobre copias, de modo que cada decisión puede contrastarse contra el archivo original.

4.3. Dimensiones y estructura

```
primeras = df.head(5).fillna("NaN").T.astype(str)
primeras.columns = [f"Usuario {i}" for i in range(1, 6)]
primeras.index.name = "Columna"
tabla(primeras, tamaño="footnotesize")
```

Tabla 1: Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
transaction_id	TXN00001	TXN00002	TXN00003	TXN00004	TXN00005
user_id	U00001	U00002	U00003	U00004	U00005
age	21	24	31	32	25
gender	Male	Other	Other	Other	Male
daily_screen_time_hours	3.23	5.09	6.06	7.83	9.96
social_media_hours	2.01	3.81	1.36	5.85	5.92
gaming_hours	0.89	2.24	3.83	1.51	3.42
work_study_hours	4.55	4.44	2.35	3.54	5.27
sleep_hours	7.55	7.66	4.92	8.23	6.21
notifications_per_day	248	127	44	178	136
app_opens_per_day	154	71	106	107	177
weekend_screen_time	3.95	6.71	8.68	9.77	12.55
stress_level	Medium	Medium	High	High	Low
academic_work_impact	Yes	Yes	No	Yes	No
addiction_level	NaN	NaN	Mild	Moderate	Severe
addicted_label	0	0	0	1	1

La Tabla 1 se presenta transpuesta porque las 16 columnas no caben a lo ancho de la página. Ya en estas cinco filas aparece una señal de alerta: los usuarios 1 y 2 muestran NaN (valor nulo) en `addiction_level`, un valor que se investiga en la sección (inserta sección).

Tabla 2: Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.

Columna	Tipo (pandas)	No nulos	Nulos	Valores distintos
transaction_id	str	7,500	0	7,500
user_id	str	7,500	0	7,500
age	int64	7,500	0	18
gender	str	7,500	0	3
daily_screen_time_hours	float64	7,500	0	900
social_media_hours	float64	7,500	0	551
gaming_hours	float64	7,500	0	401
work_study_hours	float64	7,500	0	551
sleep_hours	float64	7,500	0	451
notifications_per_day	int64	7,500	0	231
app_opens_per_day	int64	7,500	0	166
weekend_screen_time	float64	7,500	0	1,096
stress_level	str	7,500	0	3
academic_work_impact	str	7,500	0	2
addiction_level	str	6,681	819	3
addicted_label	int64	7,500	0	2

Interpretación. La Tabla 2 permite verificar que el tipo asignado por pandas sea coherente con lo que representa cada variable:

- Las nueve variables de uso, edad y sueño se cargaron como números (int64 o float64) y no como texto, que es el error silencioso más frecuente al leer un CSV.
- addicted_label se cargó como entero, pero es una variable **categorica binaria**: el tipo de dato no coincide con su naturaleza estadística, y así se tratará en el análisis.
- Las columnas de texto (tipo object en pandas 2 o str en pandas 3) son de dos clases muy distintas: transaction_id y user_id tienen 7500 valores distintos, uno por fila, lo que las identifica como **identificadores**; en cambio, gender, stress_level, academic_work_impact y addiction_level tienen entre 2 y 4 valores, es decir, son **categoricas**.
- Solo addiction_level presenta nulos np.int64(819), y muestra 3 valores distintos, cuando una escala de severidad suele tener cuatro niveles.

4.4. Tipos de variables y primeras estadísticas

Tabla 3: Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.

Columna original	Nombre en el reporte	Tipo estadístico	Descripción
transaction_id	ID_transaccion	Identificador	Código del registro (TXN00001...)
user_id	ID_usuario	Identificador	Código del usuario (U00001...)
age	edad	Cuantitativa discreta	Edad en años cumplidos
gender	genero	Cualitativa nominal	Masculino, Femenino u Otro
daily_screen_time_hours	horas_diarias_pantalla	Cuantitativa continua	Horas de pantalla en un día típico
social_media_hours	horas_redes_sociales	Cuantitativa continua	Horas diarias en redes sociales
gaming_hours	horas_videojuegos	Cuantitativa continua	Horas diarias en videojuegos
work_study_hours	horas_trabajo/estudio	Cuantitativa continua	Horas diarias de trabajo o estudio
sleep_hours	horas_sueño	Cuantitativa continua	Horas de sueño por noche
notifications_per_day	notificaciones_por_dia	Cuantitativa discreta	Notificaciones recibidas al día
app_opens_per_day	aperturas_apps_por_dia	Cuantitativa discreta	Veces que abre aplicaciones al día
weekend_screen_time	tiempo_en_pantalla_fin_de_semana	Cuantitativa continua	Horas de pantalla en un día de fin de semana
stress_level	nivel_estres	Cualitativa ordinal	Bajo < Medio < Alto
academic_work_impact	impacto_academico/laboral	Cualitativa nominal (binaria)	Si el uso afecta sus estudios o trabajo (Sí/No)
addiction_level	nivel_adiccion	Cualitativa ordinal	Ninguna < Leve < Moderada < Severa
addicted_label	etiqueta_de_adiccion	Cualitativa binaria (objetivo)	1 = adicto, 0 = no adicto

La Tabla 3 resume la naturaleza de cada variable. La distinción entre tipos estadísticos no es un detalle formal: decide qué gráficos y estadísticos corresponden a cada variable (histogramas y boxplots para las cuantitativas, gráficos de barras para las cualitativas) y, en la P2, cómo se codificará cada una.

4.5. Calidad de datos

```
# TODO: contar valores nulos por columna (df.isnull().sum()) y filas
↳ duplicadas (df.duplicated().sum()).
```

```
# TODO: contar valores nulos por columna (df.isnull().sum()) y filas
↳ duplicadas (df.duplicated().sum()).
df_renombrado["nivel_adiccion"].isnull().sum()
#Notamos que hay 819 valores nulos en la columna 'nivel_adiccion'
```

```
np.int64(819)
```

Instrucciones para esta sección: reportar cuántos valores faltantes se encontraron y en qué columna(s), y cuántas filas duplicadas existen. Explicar la causa probable de los faltantes (por ejemplo, si corresponden a una categoría real como “sin severidad registrada”) y justificar la decisión tomada: ¿se imputan, se eliminan o se excluye la columna? Si se excluye una variable por fuga de información, explicarlo aquí o remitir a la sección de fuga de información.

```
# TODO: revisar rangos (df.describe()) de las variables numéricas y valores
↳ únicos de las categóricas, para detectar valores imposibles o atípicos.
df.describe()
```

	age	daily_screen_time_hours	social_media_hours	gaming_hours	work_study_hours	sleep_hours
count	7500.000000	7500.000000	7500.000000	7500.000000	7500.000000	7500.000000
mean	26.568800	7.499912	3.273484	2.014183	3.242420	6.750000
std	5.197108	2.609188	1.585342	1.146039	1.600765	1.250000
min	18.000000	3.000000	0.500000	0.000000	0.500000	4.500000
25 %	22.000000	5.220000	1.910000	1.020000	1.850000	5.600000
50 %	27.000000	7.525000	3.270000	2.040000	3.230000	6.750000
75 %	31.000000	9.810000	4.630000	2.990000	4.640000	7.800000
max	35.000000	12.000000	6.000000	4.000000	6.000000	9.000000

Instrucciones para esta sección: comentar si los rangos observados en `df.describe()` son plausibles para lo que representa cada variable (por ejemplo, edades, horas de uso, horas de sueño). Señalar explícitamente cualquier valor fuera de rango lógico y qué se hizo con los identificadores (`ID_transaccion`, `ID_usuario`): ¿se conservan solo como referencia o se descartan del análisis?

5. Preprocesamiento y decisiones de data wrangling

Notamos que hay 819 valores nulos en la columna “nivel_adiccion”, por lo que procederemos a analizar las filas que contengan valores nulos en esta columna

	ID_transaccion	ID_usuario	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos
0	TXN00001	U00001	21	Male	3.23	2.01	0.89
1	TXN00002	U00002	24	Other	5.09	3.81	2.24
8	TXN00009	U00009	21	Other	4.38	1.38	2.72
11	TXN00012	U00012	27	Other	5.16	1.82	2.27
13	TXN00014	U00014	32	Male	4.09	1.74	1.35

5.1. Revisión de fuga de información

```
# TODO: construir una tabla cruzada (pd.crosstab) entre nivel_adiccion y
→ etiqueta_de_adiccion para revisar si nivel_adiccion "filtra" la
→ respuesta.

pd.crosstab(df_renombrado["nivel_adiccion"],
→ df_renombrado["etiqueta_de_adiccion"])

# Notamos que la columna 'nivel_adiccion' o cae en 0 cuando es baja o cae en
→ 1 cuando es media o alta, no hay ninguna excepción
# para alguien de adicción media p alta, la información de
→ 'etiqueta_de_adiccion' es la necesaria y objetivo para este análisis
# puesto que queremos encontrar qué patrones de uso, descanso y contexto
→ personal están asociados con la etiqueta de adicción en el conjunto de
→ datos que estamos abordando.
```

etiqueta_de_adiccion	0	1
nivel_adiccion		
Mild	1373	0
Moderate	0	2874
Severe	0	2434

*Instrucciones para esta sección: interpretar la tabla cruzada anterior: ¿existe alguna categoría de nivel_adiccion que se asocie de forma perfecta o casi perfecta con una sola clase de etiqueta_de_adiccion? Si es así, explicar por qué eso constituye **fuga de información** y qué variables se decide excluir de X para la P2 (y por qué).*

Notamos que la columna 'nivel_adiccion' o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de 'etiqueta_de_adiccion' es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando.

Esto permitirá no repetir información en el proceso de modelamiento, ya que 'nivel_adiccion' ya revelaría que 'etiqueta_de_adiccion' es 1 o 0.

Instrucciones para esta sección: explicar por qué excluir las variables identificadas en el punto anterior protege la validez de la evaluación del modelo. Indicar además qué método de codificación se planea usar en P2 para cada variable categórica (genero, impacto_academico/laboral, nivel_estres) y por qué (one-hot, binaria, ordinal, etc.), aclarando que cualquier transformación debe ajustarse solo con los datos de entrenamiento. Si se usa scikit-learn para esto, citar la librería (Pedregosa et al. (2011)).

Contrato de nombres para el resto del proyecto (acordado por el equipo, para que el código de todos encaje sin romperse al juntarlo): a partir de aquí se crean y se reutilizan siempre las mismas variables:

```
# TODO: crear df_clean = df sin ID_transaccion, ID_usuario ni nivel_adiccion
→ (por fuga de información).
# num_cols = lista de las 9 columnas numéricas (edad,
→ horas_diarias_pantalla, horas_redes_sociales,
#         horas_videojuegos, horas_trabajo/estudio, horas_sueño,
→ notificaciones_por_dia,
#         aperturas_apps_por_dia, tiempo_en_pantalla_fin_de_semana,)
# cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]
```

5.1.1. Enriquecimiento de datos:

Instrucciones para esta sección: quien complete esta parte debe dejar creadas exactamente las variables df_clean, num_cols y cat_cols con esos nombres. Las secciones de EDA (más abajo) las dan por hechas y no deben volver a definirlas.

```
# TODO: crear df_clean = df sin ID_transaccion, ID_usuario ni nivel_adiccion
↳ (por fuga de información).
df_clean = df_renombrado.drop(columns=["ID_transaccion", "ID_usuario",
↳ "nivel_adiccion"])
num_cols = ["edad", "horas_diarias_pantalla", "horas_redes_sociales",
"horas_videojuegos", "horas_trabajo/estudio", "horas_sueño",
↳ "notificaciones_por_dia",
"aperturas_apps_por_dia", "tiempo_en_pantalla_fin_de_semana"]
cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]
```

	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
0	21	Male	3.23	2.01	0.89	4.55
1	24	Other	5.09	3.81	2.24	4.44
2	31	Other	6.06	1.36	3.83	2.35
3	32	Other	7.83	5.85	1.51	3.54
4	25	Male	9.96	5.92	3.42	5.27

	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
0	21	Male	3.23	2.01	0.89	4.55
1	24	Other	5.09	3.81	2.24	4.44
2	31	Other	6.06	1.36	3.83	2.35
3	32	Other	7.83	5.85	1.51	3.54
4	25	Male	9.96	5.92	3.42	5.27
...	...	...	...	...	...	...
7495	26	Other	9.85	1.75	3.13	3.49
7496	35	Male	5.67	2.33	2.76	5.90
7497	22	Female	9.99	3.61	1.09	1.16
7498	23	Male	8.74	1.59	0.07	4.64
7499	27	Female	10.04	5.40	0.73	5.45

5.2. Variable derivada para la comunicación

```
# TODO: agregar a df_clean una columna nueva (por ejemplo, estado_adiccion)
↳ que traduzca etiqueta_de_adiccion a etiquetas legibles ("No adicción" /
↳ "Con adicción") solo para tablas y gráficos.

df_clean["estado_adiccion"] = df_clean["etiqueta_de_adiccion"].
↳ replace({1:"Adicto", 0 : "No adicto"})
df_clean["estado_adiccion"].value_counts()
```

```
estado_adiccion
Adicto      5308
```

No adicto 2192

Name: count, dtype: int64

Instrucciones para esta sección: confirmar que la nueva variable de etiquetas legibles no introduce ninguna información distinta a etiqueta_de_adiccion (es solo una versión “para humanos” de la misma columna) y aclarar que para el modelamiento en P2 se seguirá usando la versión numérica original.


6. Análisis exploratorio de datos

6.1. Análisis univariado

```
# TODO: graficar la distribución de etiqueta_de_adiccion (conteo y/o
→ porcentaje por clase), usando df_clean #Aquí no se puede distribución
→ porque etiqueta_de_adiccion es una variable categórica
sns.barplot(data=df_clean, x= "estado_adiccion", y = )
counts = df_clean["estado_adiccion"].value_counts()

counts.plot(kind="bar", color=['darkred','darkgreen'], edgecolor="none")

plt.xlabel("Estado de adicción")
plt.ylabel(None)
plt.show()
```







Instrucciones para esta sección: reportar cuántos registros hay en cada clase de etiqueta_de_adiccion (conteo y porcentaje) y comentar si existe desbalance de clases. Si lo hay, explicar qué implicancia tiene para




la partición entrenamiento/prueba y las métricas que se deberán usar en P2 (por ejemplo, estratificación, F1, recall).




```
# TODO: graficar un histograma por cada variable numérica (usar num_cols).
# usa las columnas que ya tienes cargadas en la sesión



#crear una variable j que pase por una lista que tenga los nombres bien
→ escritos de los histogramas
colores =
→ ['steelblue', 'darkorange', 'forestgreen', 'crimson', 'gold', 'lightcoral', 'yellowgreen',
'powderblue', 'lightgreen', 'lightgray', 'plum']
contador = 0
for col in num_cols:
    plt.figure(figsize=(4, 3))
    sns.histplot(
        data=df_clean,
        x=col,
        bins=20,
        kde=False,
        color= colores[contador]
    )
    plt.title(f"Histograma de {col}")
    plt.xlabel(None)
    plt.ylabel(None)
    plt.tight_layout() #es una función de matplotlib que ajusta
→ automáticamente los márgenes
    plt.show()
    contador +=1
```












```
# TODO: graficar un histograma por cada variable numérica (usar num_cols).  
df_clean['estado_adiccion'].value_counts().plot(kind='bar',color=['darkred','darkgreen'])  
plt.show() #usamos la variable comunicativa de 'etiqueta_de_adiccion'
```



Instrucciones para esta sección: para cada histograma, describir la forma de la distribución (simétrica, sesgada, con varias modas) y qué implica para el análisis (por ejemplo, si conviene una transformación o estandarización más adelante). Comentar si alguna variable de conteo tiene una escala muy distinta a las variables medidas en horas.

Los boxplots se apoyan en los cuartiles, que dividen los datos ordenados en cuatro partes iguales (**walpole2012probabilidad**):



$$Q_k = \text{valor en la posición } \frac{k}{4}(n+1) \quad (1)$$




```
# TODO: graficar un boxplot por cada variable numérica (usar num_cols).
# asegúrate de que num_cols existe y tiene nombres reales




colores =
  ↳ ['steelblue','darkorange','forestgreen','lightcoral','yellowgreen','cadetblue',
    'powderblue','lightgreen','lightgray']
num_cols = [
  "edad",
  "horas_diarias_pantalla",
  "horas_redes_sociales",
  "horas_videojuegos",
  "horas_trabajo/estudio",
  "horas_sueño",
  "notificaciones_por_dia",
```


```
"aperturas_apps_por_dia",
"tiempo_en_pantalla_fin_de_semana",
]#aqui descartamos "etiqueta_de_adiccion"

contador = 0
for col in num_cols:
    plt.figure(figsize=(4, 3))
    sns.boxplot(
        data=df_clean,
        y=col,
        color=colores[contador],
    )
    contador += 1
    plt.xlabel("")
    plt.ylabel(col)
    plt.tight_layout()
    plt.show()
```









Instrucciones para esta sección: comentar, variable por variable, la dispersión, la posible presencia de outliers y la simetría observada en los boxplots. Discutir si esos valores extremos deberían tratarse como errores de captura o si son observaciones reales del comportamiento de los usuarios, y justificar la decisión tomada.

Se calculan las medidas de tendencia central y dispersión de cada variable numérica (walpole2012probabilidad):

$$CV = \frac{s}{\bar{x}} \times 100\% \quad (2)$$

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & \text{si } n \text{ es par} \end{cases} \quad (3)$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (4)$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (5)$$

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (6)$$

```
# TODO: calcular media, mediana, moda, desviación estándar, varianza, rango
↳ y cuartiles por variable numérica (num_cols).
```

```
for i in num_cols:
    display(df_clean[i].describe())
```

```
count    7500.000000
```

```
mean      26.568800
std        5.197108
min        18.000000
25%        22.000000
50%        27.000000
75%        31.000000
max        35.000000
Name: edad, dtype: float64
```

```
count      7500.000000
mean        7.499912
std         2.609188
min         3.000000
25%         5.220000
50%         7.525000
75%         9.810000
max         12.000000
Name: horas_diarias_pantalla, dtype: float64
```

```
count      7500.000000
mean        3.273484
std         1.585342
min         0.500000
25%         1.910000
50%         3.270000
75%         4.630000
max         6.000000
Name: horas_redes_sociales, dtype: float64
```

```
count      7500.000000
mean        2.014183
std         1.146039
min         0.000000
25%         1.020000
50%         2.040000
75%         2.990000
max         4.000000
Name: horas_videojuegos, dtype: float64
```

```
count      7500.000000
mean        3.242420
std         1.600765
min         0.500000
25%         1.850000
```

50% 3.230000

75% 4.640000

max 6.000000

Name: horas_trabajo/estudio, dtype: float64

count 7500.000000

mean 6.737561

std 1.283605

min 4.500000

25% 5.630000

50% 6.720000

75% 7.840000

max 9.000000

Name: horas_sueño, dtype: float64

count 7500.000000

mean 134.257333

std 66.586883

min 20.000000

25% 76.000000

50% 134.000000

75% 191.000000

max 250.000000

Name: notificaciones_por_dia, dtype: float64

count 7500.000000

mean 97.832400

std 48.423349

min 15.000000

25% 55.000000

50% 98.000000

75% 140.000000

max 180.000000

Name: aperturas_apps_por_dia, dtype: float64

count 7500.000000

mean 9.243827

std 2.718281

min 3.580000

25% 6.960000

50% 9.260000

75% 11.540000

max 14.880000

Name: tiempo_en_pantalla_fin_de_semana, dtype: float64

Instrucciones para esta sección: comparar media y mediana para detectar asimetría en cada variable, e interpretar la desviación estándar en el contexto de la escala de cada una (no comparar directamente variables con unidades distintas). Señalar qué variables muestran mayor dispersión o valores extremos.

```
# TODO: graficar la frecuencia de las variables categóricas (cat_cols:
↳ genero, nivel_estres, impacto_academico/laboral). #están debajo
for i in cat_cols:
    df_clean[i].value_counts(normalize=True)
```

```
genero
Male      0.340400
Other     0.331467
Female    0.328133
Name: proportion, dtype: float64
```

```
nivel_estres
High      0.341333
Low       0.333733
Medium    0.324933
Name: proportion, dtype: float64
```

```
impacto_academico/laboral
No        0.5004
Yes       0.4996
Name: proportion, dtype: float64
```

```
estado_adiccion
Adicto    0.707733
No adicto 0.292267
Name: proportion, dtype: float64
```

Instrucciones para esta sección: describir qué categorías son dominantes o poco frecuentes en cada variable categórica y comentar si eso podría afectar el análisis posterior (por ejemplo, categorías con muy pocos casos). Indicar si alguna de estas variables se tratará como ordinal y por qué.

6.2. Análisis multivariado


```
# TODO: graficar un mapa de calor de correlaciones entre las variables
↳ numéricas (num_cols).
df_num = df_clean[num_cols+ ["etiqueta_de_adiccion"]].copy()
# 1. Primero va el tamaño y la resolución (el lienzo)
plt.figure(figsize=(30, 10), dpi=300)

# 2. Luego armamos el mapa de calor con tus mismos parámetros
sns.heatmap(
    df_num.corr(),
    annot=True,
```

```

fmt=".1f",
vmax=1,
center=0,
linewidths=0.5, # Líneas divisorias sutiles
cbar_kws={"shrink": 1}, # Barra de color un poco más chica
annot_kws={"size": 23}, # Números chiquitos para que no se amontonen
)
plt.xticks(fontsize=29) # etiquetas del eje X más grandes
plt.yticks(fontsize=29) # etiquetas del eje Y más grandes
# 3. Ponemos el título y mostramos
plt.title("Matriz de Correlación de Variables Numéricas")
plt.show()

```



Instrucciones para esta sección: identificar en el mapa de calor los pares de variables con correlación fuerte (positiva o negativa) y comentar si sugieren colinealidad. Aclarar que la correlación no implica causalidad.

```

# TODO: calcular y ordenar las correlaciones de cada variable numérica
↳ (num_cols) con etiqueta_de_adiccion.
#Chamba Jossep


```



La correlación de Pearson mide la fuerza y dirección de la relación lineal entre dos variables, y se calcula a partir de la covarianza y las desviaciones estándar de cada una (**walpole2012**probabilidad):



$$r_{xy} = \frac{\text{cov}(x, y)}{s_x s_y} \quad (7)$$


Instrucciones para esta sección: comentar qué variables tienen mayor asociación lineal con la etiqueta objetivo y cuáles tienen asociación muy baja. Aclarar que esto es solo un indicio y no una selección final de variables para el modelo.

```
# TODO: graficar boxplots comparativos de variables numéricas clave (por
→ ejemplo, horas_diarias_pantalla, horas_redes_sociales, horas_sueño)
→ separadas por etiqueta_de_adiccion.
del plt
import matplotlib.pyplot as plt
sns.boxplot(data=df_clean, x="estado_adiccion", y="horas_ocio", palette =
→ "husl", legend=True)
```











```
['edad',  
 'horas_diarias_pantalla',  
 'horas_redes_sociales',  
 'horas_videojuegos',  
 'horas_trabajo/estudio',  
 'horas_sueño',  
 'notificaciones_por_dia',  
 'aperturas_apps_por_dia',  
 'tiempo_en_pantalla_fin_de_semana']
```

```
['genero', 'nivel_estres', 'impacto_academico/laboral', 'estado_adiccion']
```



Instrucciones para esta sección: comentar cómo cambian la tendencia central y la dispersión de cada variable entre las dos clases, y si hay solapamiento amplio entre grupos (lo que anticiparía dificultad para separar las clases con un solo predictor).

```
plt.figure(figsize=(8,5))
sns.countplot(data=df_clean, x="nivel_estres", hue="estado_adiccion",
              order=["Low","Medium","High"], palette="colorblind")
plt.title("Nivel de estrés, agrupado por estado de adicción")
plt.xlabel("Nivel de estrés")
plt.ylabel("Conteo")
plt.tight_layout()
plt.show()
```



TODO: graficar histogramas o barras agrupadas comparando subgrupos (por ejemplo, nivel_estres o impacto_academico/laboral vs. etiqueta_de_adiccion).

Instrucciones para esta sección: interpretar las proporciones (no solo los conteos) entre subgrupos, evitando conclusiones que estigmaticen a los usuarios. Comentar si estas variables parecen ser causa, consecuencia o simplemente indicadores asociados al uso problemático.

TODO: graficar al menos 5 diagramas de dispersión (scatterplots) entre pares de variables numéricas (num_cols), coloreando por etiqueta_de_adiccion.

TODO: graficar al menos 5 diagramas de dispersión (scatterplots) entre pares de variables numéricas (num_cols), coloreando por etiqueta_de_adiccion.

Instrucciones para esta sección: para cada par de variables, comentar si se observa un patrón (lineal o no lineal), agrupamientos, o separación visible entre clases. Si los colores se solapan mucho, señalar que esas dos variables por sí solas no bastan para separar las clases.

TODO: calcular la covarianza entre pares de variables numéricas relevantes (num_cols).

La covarianza mide cómo varían juntas dos variables: positiva si crecen juntas, negativa si una crece cuando la otra decrece (walpole2012probabilidad).

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (8)$$

Instrucciones para esta sección: interpretar el signo de la covarianza (si dos variables crecen o decrecen juntas) y explicar por qué se complementa con la correlación (que sí permite comparar la fuerza de la relación entre variables con escalas distintas).

7. Conclusiones de P1

Instrucciones para esta sección: redactar entre 4 y 6 conclusiones numeradas, basadas únicamente en los resultados obtenidos arriba (no inventar cifras). Deben cubrir, como mínimo: (1) calidad de datos (nulos, duplicados) y qué se hizo al respecto, (2) si la clase objetivo está balanceada o no y qué implica para P2, (3) qué variables se excluyen como predictoras y por qué, (4) qué variables lucen más prometedoras para el modelamiento, y (5) qué se debe tener en cuenta al pasar a la P2 (codificación, escalamiento, evaluación).

Estos hallazgos son consistentes con estudios previos que asocian la adicción al smartphone con menor rendimiento académico, en parte por su efecto negativo sobre el sueño (rathakrishnan2021smartphone).

La correlación observada entre horas_redes_sociales y la etiqueta de adicción coincide con la dirección reportada por un meta-análisis reciente sobre redes sociales y rendimiento académico (salari2025socialmedia).

Un estudio con un dataset público similar reporta que Random Forest es el modelo con mejor desempeño para este tipo de predicción (azeez2026ml), lo que sugiere una línea de partida razonable para la P2.

8. Limitaciones y consideraciones éticas

El archivo no incluye documentación sobre el muestreo, instrumento de medición, país, periodo de recolección ni procedimiento de etiquetado. En consecuencia, la muestra no debe asumirse representativa de la población universitaria peruana ni de un grupo demográfico específico. Además, el término “adicción” debe tratarse como una etiqueta del dataset y no como un diagnóstico clínico. La evidencia académica recomienda emplear instrumentos validados y distinguir entre uso frecuente y uso problemático Kwon et al. (2013); Csibi et al. (2018).

Si este análisis se trasladara a un contexto real, la privacidad, el consentimiento informado y el riesgo de estigmatización serían centrales. Una predicción debe apoyar la prevención o la derivación voluntaria, nunca justificar sanciones automáticas o decisiones de alto impacto.

Referencias

Amez, S y S Baert (2020). Smartphone Use and Academic Performance: A Literature Review. *International Journal of Educational Research* **103**, 101618.

- Csibi, S, MD Griffiths, B Cook, Z Demetrovics y A Szabo (2018). The Psychometric Properties of the Smartphone Application-Based Addiction Scale (SABAS). *International Journal of Mental Health and Addiction* **16**(2), 393-403.
- Kwon, M, JY Lee, WY Won, JW Park, JA Min, C Hahn, X Gu, JH Choi y DJ Kim (2013). Development and Validation of a Smartphone Addiction Scale (SAS). *PLOS ONE* **8**(2), e56936.
- Nusrat, Z (s.f.). *Smartphone Usage and Addiction Analysis Dataset*. Kaggle. Fecha de publicación no indicada en la página; consultado el 17 de septiembre de 2026. <https://www.kaggle.com/datasets/zahranusratt/smartphone-usage-and-addiction-analysis-dataset>.
- Pedregosa, F, G Varoquaux, A Gramfort, V Michel, B Thirion, O Grisel, M Blondel, P Prettenhofer, R Weiss, V Dubourg, J Vanderplas, A Passos, D Cournapeau, M Brucher, M Perrot y É Duchesnay (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* **12**, 2825-2830.