

P1 - Uso de Smartphones y Riesgo de Adiccion

Hiter Frank Rubio Peralta

Alumno

Jossep Jorge Froilan Choroco Neyra

Alumno

Joel David De la Cruz Cardenas

Alumno

Rodrigo Octavio Lucatoni Flores Ruiz

Alumno

Victor Andres Diaz Garcia

Alumno

Curso:

Introduccion a Ciencia de Datos e Inteligencia Artificial

24 de Septiembre del 2026

Tabla de contenidos

1. Resumen	4
2. Planteamiento del problema	4
3. Contexto del dataset	4
3.1. Fuente y unidad de análisis	4
3.2. Diccionario de variables	4
4. Carga y exploración inicial	5
4.1. Librerías	5
4.2. Carga de datos	5
4.3. Dimensiones y estructura	6
4.4. Tipos de variables y primeras estadísticas	8
4.5. Calidad de datos	8
5. Preprocesamiento y decisiones de data wrangling	9
5.1. Revisión de fuga de información	10
6. Análisis exploratorio de datos	13
6.1. Análisis univariado	13
6.2. Análisis multivariado	20
7. Conclusiones de P1	31
8. Limitaciones y consideraciones éticas	32

Listado de Tablas

1. Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.	6
2. Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.	7
3. Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.	8
4. Primeras estadísticas de las variables numéricas (archivo original).	9
5. Primeras filas con valores nulos en nivel de adicción.	9
6. Tabla cruzada entre nivel_adiccion y etiqueta_de_adiccion.	10
7. Primeras cinco filas del dataset limpio (df_clean).	11
8. Primeras cinco filas del dataset con variables derivadas (horas_ocio y ratio_finde_diario).	12
9. Estadística descriptiva de las variables numéricas.	18
10. Proporción de registros por género.	19
11. Proporción de registros por nivel de estrés.	19
12. Proporción de registros por impacto académico o laboral.	19
13. Proporción de registros por estado de adicción.	19

14. Matriz de correlación entre las variables numéricas.	31
--	----

Listado de Figuras

1. Histogramas de las variables numéricas del dataset.	14
2. Distribución de la variable objetivo: estado de adicción (0 = No adicción, 1 = Con adicción).	15
3. Boxplots de las variables numéricas del dataset.	17
4. Matriz de correlación de las variables numéricas.	20
5. Horas de ocio según el estado de adicción.	21
6. Horas de ocio según el género.	22
7. Horas de ocio según el impacto académico o laboral.	22
8. Razón entre pantalla de fin de semana y pantalla diaria según el estado de adicción.	23
9. Horas de sueño según el estado de adicción.	23
10. Horas diarias de pantalla según el nivel de estrés.	24
11. Horas de ocio según el nivel de estrés.	24
12. Nivel de estrés según el estado de adicción.	25
13. Distribución de genero según la etiqueta de adicción.	26
14. Distribución del nivel de estrés según la etiqueta de adicción.	26
15. Distribución del impacto academico y social según la etiqueta de adicción.	27
16. Relación entre horas de trabajo o estudio y horas diarias de pantalla, según la etiqueta de adicción.	28
17. Relación entre horas de sueño y horas en redes sociales, según la etiqueta de adicción.	28
18. Relación entre notificaciones por día y horas de sueño, según la etiqueta de adicción.	29
19. Relación entre horas de videojuegos y horas de trabajo o estudio, según la etiqueta de adicción.	29
20. Relación entre edad y horas diarias de pantalla, según la etiqueta de adicción.	30

1. Resumen

*Instrucciones para esta sección: este resumen se escribe **al final**, cuando ya se tengan los resultados de la exploración de datos y las conclusiones de P1. Debe tener entre 150 y 200 palabras e incluir, en este orden: (1) qué dataset se usó y cuántos registros/columnas tiene, (2) el objetivo del análisis (qué se busca entender sobre `etiqueta_de_adiccion`), (3) las dos o tres decisiones de limpieza más importantes que se tomaron y por qué, (4) los dos o tres hallazgos más relevantes del EDA, citando cifras reales obtenidas del código (no inventadas ni copiadas de un borrador), y (5) una frase que conecte con lo que se hará en la P2. No copiar texto de otras secciones; debe ser una síntesis propia, escrita por el equipo.*

2. Planteamiento del problema

El uso intensivo de celulares puede influir en la salud integral de las personas al relacionarse con irregularidades en el sueño, estrés, dificultades en el ámbito académico y laboral. Además, la investigación requiere de una conceptualización alta: una alta frecuencia de uso no significa necesariamente a una condición clínica. Artículos como SABAS permiten estudiar síntomas de uso problemático, pero no sustituyen una evaluación profesional Csibi et al. (2018). La literatura también ayuda con asociaciones entre el uso del smartphone y el desempeño académico, aunque con limitaciones claras para atribuir causalidad Amez y Baert (2020).

Para este proyecto, se formula la siguiente pregunta de análisis:

¿Qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos `smartphone-use-prediction`?

3. Contexto del dataset

3.1. Fuente y unidad de análisis

El archivo `Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv` fue proporcionado para el proyecto y corresponde al dataset publicado como *Smartphone Usage and Addiction Analysis* en Kaggle Nusrat (s.f.). Cada fila representa a un usuario y contiene indicadores demográficos, de comportamiento digital, descanso, estrés e impacto percibido en actividades académicas o laborales.

La unidad de análisis es el usuario. El dataset incluye 7,500 registros y 16 columnas originales: dos identificadores, nueve variables numéricas, cuatro variables categóricas y la etiqueta binaria objetivo.

3.2. Diccionario de variables

- **Identificadores:** `ID_transaccion` y `ID_usuario` son variables de texto. Se usan para verificar unicidad, pero no aportan significado analítico y se excluirán como predictores.
- **Demografía:** `edad` (numérica) y `genero` (categórica) caracterizan la muestra.
- **Uso del smartphone:** `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo/estudio`, `notificaciones_por_dia`, `aperturas_apps_por_dia` y `tiempo_pantalla_finde` son variables numéricas que miden intensidad y tipo de uso.

- **Bienestar y contexto:** horas_sueño es numérica; nivel_estres y impacto_academico/laboral son categóricas. Se emplean para explorar descanso e impacto funcional.
- **Severidad:** nivel_adiccion es categórica ordinal. Se describe en P1, pero se excluye como predictor en P2 por fuga de información.
- **Objetivo:** etiqueta_de_adiccion es binaria: 0 significa *No adicción* y 1 significa *Con adicción*.

La variable nivel_adiccion contiene una categorización de severidad (None, Mild, Moderate, Severe). Por su definición operativa, puede estar construida directamente a partir de la etiqueta final; por ello se audita explícitamente antes de considerar su uso en P2.

4. Carga y exploración inicial

4.1. Librerías

El primer bloque reúne las librerías necesarias para el proyecto y el estilo de seaborn

```
# =====  
# CONFIGURACIÓN ÚNICA DEL REPORTE  
# Librerías y estilos se ejecutan una sola vez  
# =====  
import pandas as pd  
import numpy as np  
from stack_data import Variable  
from matplotlib.pyplot import boxplot  
from matplotlib.pyplot import hist  
import matplotlib.pyplot as plt  
import seaborn as sns  
from IPython.display import display, Latex  
import kagglehub  
from scipy import stats  
import math  
  
sns.set_theme(style="whitegrid")
```

El segundo bloque, que no se imprime en el PDF para no alargarlo, define funciones de presentación: la función `tabla()`, que reproduce desde Python el estilo de tabla (`kable` con `booktabs`), en el PDF se omite el código que solo dibuja los gráficos, igual que en la plantilla del curso; todo ese código está completo y comentado en `Project-Report.qmd`. Sí se muestra todo el código que carga, transforma o calcula.

4.2. Carga de datos

Usando la librería de kaggle y os logramos una carga universal exitosa en cualquier equipo y evitamos errores de carga del dataset

```
# Cargamos el archivo csv
path = (kagglehub.dataset_download
        ("jayjoshi37/smartphone-usage-and-addiction-prediction"))

import os
# Ruta directa al archivo CSV combinando la ruta de descarga y el nombre del
# archivo
ruta_csv = (os.path.join(path,
                          "Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv"))
df = pd.read_csv(ruta_csv)
n_filas, n_columnas = df.shape
print(f"Dimensiones: {n_filas:,} filas x {n_columnas} columnas")
```

Dimensiones: 7,500 filas x 16 columnas

El archivo se carga completo, con 7500 filas y 16 columnas. `df` no se modifica en ningún momento: todas las transformaciones posteriores se aplican sobre copias, de modo que cada decisión puede contrastarse contra el archivo original.

4.3. Dimensiones y estructura

```
primeras = df.head(5).fillna("NaN").T.astype(str)
primeras.columns = [f"Usuario {i}" for i in range(1, 6)]
primeras.index.name = "Columna"
tabla(primeras, tamano="footnotesize")
```

Tabla 1: *Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
transaction_id	TXN00001	TXN00002	TXN00003	TXN00004	TXN00005
user_id	U00001	U00002	U00003	U00004	U00005
age	21	24	31	32	25
gender	Male	Other	Other	Other	Male
daily_screen_time_hours	3.23	5.09	6.06	7.83	9.96
social_media_hours	2.01	3.81	1.36	5.85	5.92
gaming_hours	0.89	2.24	3.83	1.51	3.42
work_study_hours	4.55	4.44	2.35	3.54	5.27
sleep_hours	7.55	7.66	4.92	8.23	6.21
notifications_per_day	248	127	44	178	136
app_opens_per_day	154	71	106	107	177
weekend_screen_time	3.95	6.71	8.68	9.77	12.55
stress_level	Medium	Medium	High	High	Low
academic_work_impact	Yes	Yes	No	Yes	No
addiction_level	NaN	NaN	Mild	Moderate	Severe
addicted_label	0	0	0	1	1

La Tabla 1 se presenta transpuesta porque las 16 columnas no caben a lo ancho de la página. Ya en estas cinco filas aparece una señal de alerta: los usuarios 1 y 2 muestran NaN (valor nulo) en `addiction_level`, un valor que se investiga en la sección (Sección 5.1).

Tabla 2: Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.

Columna	Tipo (pandas)	No nulos	Nulos	Valores distintos
<code>transaction_id</code>	str	7,500	0	7,500
<code>user_id</code>	str	7,500	0	7,500
<code>age</code>	int64	7,500	0	18
<code>gender</code>	str	7,500	0	3
<code>daily_screen_time_hours</code>	float64	7,500	0	900
<code>social_media_hours</code>	float64	7,500	0	551
<code>gaming_hours</code>	float64	7,500	0	401
<code>work_study_hours</code>	float64	7,500	0	551
<code>sleep_hours</code>	float64	7,500	0	451
<code>notifications_per_day</code>	int64	7,500	0	231
<code>app_opens_per_day</code>	int64	7,500	0	166
<code>weekend_screen_time</code>	float64	7,500	0	1,096
<code>stress_level</code>	str	7,500	0	3
<code>academic_work_impact</code>	str	7,500	0	2
<code>addiction_level</code>	str	6,681	819	3
<code>addicted_label</code>	int64	7,500	0	2

Interpretación. La Tabla 2 permite verificar que el tipo asignado por pandas sea coherente con lo que representa cada variable:

- Las nueve variables de uso, edad y sueño se cargaron como números (int64 o float64) y no como texto, que es el error silencioso más frecuente al leer un CSV.
- `addicted_label` se cargó como entero, pero es una variable **categorica binaria**: el tipo de dato no coincide con su naturaleza estadística, y así se tratará en el análisis.
- Las columnas de texto (tipo object en pandas 2 o str en pandas 3) son de dos clases muy distintas: `transaction_id` y `user_id` tienen 7500 valores distintos, uno por fila, lo que las identifica como **identificadores**; en cambio, `gender`, `stress_level`, `academic_work_impact` y `addiction_level` tienen entre 2 y 4 valores, es decir, son **categoricas**.
- Solo `addiction_level` presenta nulos `np.int64(819)`, y muestra 3 valores distintos, cuando una escala de severidad suele tener cuatro niveles.

4.4. Tipos de variables y primeras estadísticas

Tabla 3: Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.

Columna original	Nombre en el reporte	Tipo estadístico	Descripción
transaction_id	ID_transaccion	Identificador	Código del registro (TXN00001...)
user_id	ID_usuario	Identificador	Código del usuario (U00001...)
age	edad	Cuantitativa discreta	Edad en años cumplidos
gender	genero	Cualitativa nominal	Masculino, Femenino u Otro
daily_screen_time_hours	horas_diarias_pantalla	Cuantitativa continua	Horas de pantalla en un día típico
social_media_hours	horas_redes_sociales	Cuantitativa continua	Horas diarias en redes sociales
gaming_hours	horas_videojuegos	Cuantitativa continua	Horas diarias en videojuegos
work_study_hours	horas_trabajo/estudio	Cuantitativa continua	Horas diarias de trabajo o estudio
sleep_hours	horas_sueño	Cuantitativa continua	Horas de sueño por noche
notifications_per_day	notificaciones_por_dia	Cuantitativa discreta	Notificaciones recibidas al día
app_opens_per_day	aperturas_apps_por_dia	Cuantitativa discreta	Veces que abre aplicaciones al día
weekend_screen_time	tiempo_pantalla_finde	Cuantitativa continua	Horas de pantalla en un día de fin de semana
stress_level	nivel_estres	Cualitativa ordinal	Bajo < Medio < Alto
academic_work_impact	impacto_academico/laboral	Cualitativa nominal (binaria)	Si el uso afecta sus estudios o trabajo (Sí/No)
addiction_level	nivel_adiccion	Cualitativa ordinal	Ninguna < Leve < Moderada < Severa
addicted_label	etiqueta_de_adiccion	Cualitativa binaria (objetivo)	1 = adicto, 0 = no adicto

La Tabla 3 resume la naturaleza de cada variable. La distinción entre tipos estadísticos no es un detalle formal: decide qué gráficos y estadísticos corresponden a cada variable (histogramas y boxplots para las cuantitativas, gráficos de barras para las cualitativas) y, en la P2, cómo se codificará cada una.

4.5. Calidad de datos

```
nulos_por_columna = df.isnull().sum()
filas_duplicadas = df.duplicated().sum()
print("Valores nulos por columna:")
print(nulos_por_columna[nulos_por_columna > 0])
print(f"\nFilas duplicadas: {filas_duplicadas}")
```

Valores nulos por columna:

```
addiction_level      819
dtype: int64
```

Filas duplicadas: 0

Se encontraron **819 valores nulos** en la columna nivel_adicción, esto es aproximadamente un 10.92% de los registros del dataset. Por otro lado, no hay filas duplicadas, probablemente esto sea porque los usuarios con nivel_adiccion = None simplemente no completaron esa escala de severidad. A partir de este problema, decidimos **excluir** a la variable nivel_adicción ya que esta representa una fuga de información y no aporta información nueva.

Tabla 4: Primeras estadísticas de las variables numéricas (archivo original).

Variable	n	Media	Desv. est.	Mín.	Q1	Mediana	Q3	Máy.
edad	7,500	26.57	5.20	18.00	22.00	27.00	31.00	35.00
horas_diarias_pantalla	7,500	7.50	2.61	3.00	5.22	7.53	9.81	12.00
horas_redes_sociales	7,500	3.27	1.59	0.50	1.91	3.27	4.63	6.00
horas_videojuegos	7,500	2.01	1.15	0.00	1.02	2.04	2.99	4.00
horas_trabajo/estudio	7,500	3.24	1.60	0.50	1.85	3.23	4.64	6.00
horas_sueño	7,500	6.74	1.28	4.50	5.63	6.72	7.84	9.00
notificaciones_por_dia	7,500	134.26	66.59	20.00	76.00	134.00	191.00	250.00
aperturas_apps_por_dia	7,500	97.83	48.42	15.00	55.00	98.00	140.00	180.00
tiempo_pantalla_finde	7,500	9.24	2.72	3.58	6.96	9.26	11.54	14.88
etiqueta_de_adiccion	7,500	0.71	0.45	0.00	0.00	1.00	1.00	1.00

Los rangos que se observan en la anterior tabla `df.describe()` son coherentes con lo que representan las variables. La edad está entre 18 y 35 años, con una media de 26.57, las horas de pantalla diaria van de 3 a 12 horas con una media de 7.50, las horas de sueño de 4.5 a 9 con una media de 6.74 y las horas de trabajo/estudio de 0.5 a 6 con media de 3.24. Por otro lado, los valores de notificaciones por día y aperturas de apps por día muestran una alta dispersión, eso es esperable ya que cada usuario tiene distintos patrones de uso que generar cantidades completamente diferentes de notificaciones y aperturas. Además, `ID_transaccion` y `ID_usuario` se conservan únicamente como referencia para verificar autenticidad, pero no forman parte del análisis.

5. Preprocesamiento y decisiones de data wrangling

Notamos que hay 819 valores nulos en la columna “nivel_adiccion”, por lo que procederemos a analizar las filas que contengan valores nulos en esta columna

```
columnas_mostrar = [
    "ID_transaccion", "edad", "genero",
    "horas_diarias_pantalla", "horas_sueño",
    "nivel_estres", "etiqueta_de_adiccion"
]

df_adiccionnull = df_renombrado[df_renombrado["nivel_adiccion"].isnull()]
df_adiccionnull_head = df_adiccionnull.head()

tabla(df_adiccionnull_head[columnas_mostrar], indice=False,
      ↪ tamaño="scriptsize", interlineado=1.1)
```

Tabla 5: Primeras filas con valores nulos en nivel de adicción.

ID_transaccion	edad	genero	horas_diarias_pantalla	horas_sueño	nivel_estres	etiqueta_de_adiccion
TXN00001	21	Male	3.23	7.55	Medium	0
TXN00002	24	Other	5.09	7.66	Medium	0
TXN00009	21	Other	4.38	6.23	High	0
TXN00012	27	Other	5.16	7.79	High	0
TXN00014	32	Male	4.09	5.54	High	0

5.1. Revisión de fuga de información

```
crosstab = pd.crosstab(df_renombrado["nivel_adiccion"],  
    ↪ df_renombrado["etiqueta_de_adiccion"])  
tabla(crosstab)
```

Tabla 6: *Tabla cruzada entre nivel_adiccion y etiqueta_de_adiccion.*

nivel_adiccion	0	1
Mild	1,373	0
Moderate	0	2,874
Severe	0	2,434

En la tabla cruzada Notamos que la columna nivel_adiccion o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de etiqueta_de_adiccion es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando.

Notamos que la columna nivel_adiccion o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de etiqueta_de_adiccion es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando. Esto permitirá no repetir información en el proceso de modelamiento, ya que nivel_adiccion ya revelaría que etiqueta_de_adiccion es 1 o 0. Por lo tanto, con esto confirmamos que incluir nivel_adiccion en el predictor del modelo P2 sería igual a una **fuga de información**, entonces lo excluirémos de las variables predictoras. Además, se descartan ID_transaccion e ID_usuario al ser solo identificadores sin un valor predictivo.

Contrato de nombres para el resto del proyecto (acordado por el equipo, para que el código de todos encaje sin romperse al juntarlo): a partir de aquí se crean y se reutilizan siempre las mismas variables:

```
df_clean = df_renombrado.drop(columns=["ID_transaccion", "ID_usuario",  
    ↪ "nivel_adiccion"])  
num_cols = ["edad", "horas_diarias_pantalla", "horas_redes_sociales",  
"horas_videojuegos", "horas_trabajo/estudio", "horas_sueño",  
    ↪ "notificaciones_por_dia",  
"aperturas_apps_por_dia", "tiempo_pantalla_finde"]  
cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]  
vista_df_clean = df_clean.head().T  
vista_df_clean.columns = [f"Usuario {i}" for i in range(1, 6)]  
vista_df_clean.index.name = "Columna"  
  
tabla(vista_df_clean, tamano="footnotesize")
```

Tabla 7: *Primeras cinco filas del dataset limpio (df_clean).*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
edad	21	24	31	32	25
genero	Male	Other	Other	Other	Male
horas_diarias_pantalla	3.23	5.09	6.06	7.83	9.96
horas_redes_sociales	2.01	3.81	1.36	5.85	5.92
horas_videojuegos	0.89	2.24	3.83	1.51	3.42
horas_trabajo/estudio	4.55	4.44	2.35	3.54	5.27
horas_sueño	7.55	7.66	4.92	8.23	6.21
notificaciones_por_dia	248	127	44	178	136
aperturas_apps_por_dia	154	71	106	107	177
tiempo_pantalla_finde	3.95	6.71	8.68	9.77	12.55
nivel_estres	Medium	Medium	High	High	Low
impacto_academico/laboral	Yes	Yes	No	Yes	No
etiqueta_de_adiccion	0	0	0	1	1

5.1.1. Enriquecimiento de datos:

Se crean dos variables derivadas para el análisis exploratorio:

```
df_clean["horas_ocio"] = df_renombrado["horas_redes_sociales"] +  
    ↪ df_renombrado["horas_videojuegos"]  
df_clean["ratio_finde_diario"] = (  
    df_renombrado["tiempo_pantalla_finde"]  
    / df_renombrado["horas_diarias_pantalla"]  
)  
df_clean["estado_adiccion"] =  
    ↪ df_renombrado["etiqueta_de_adiccion"].replace({1:"Adicto", 0:"No  
    ↪ adicto"})  
vista2_df_clean = df_clean.head().T  
vista2_df_clean.columns = [f"Usuario {i}" for i in range(1, 6)]  
vista2_df_clean.index.name = "Columna"  
  
tabla(vista2_df_clean, tamano="footnotesize")
```

Tabla 8: *Primeras cinco filas del dataset con variables derivadas (horas_ocio y ratio_finde_diario).*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
edad	21	24	31	32	25
genero	Male	Other	Other	Other	Male
horas_diarias_pantalla	3.23	5.09	6.06	7.83	9.96
horas_redes_sociales	2.01	3.81	1.36	5.85	5.92
horas_videojuegos	0.89	2.24	3.83	1.51	3.42
horas_trabajo/estudio	4.55	4.44	2.35	3.54	5.27
horas_sueño	7.55	7.66	4.92	8.23	6.21
notificaciones_por_dia	248	127	44	178	136
aperturas_apps_por_dia	154	71	106	107	177
tiempo_pantalla_finde	3.95	6.71	8.68	9.77	12.55
nivel_estres	Medium	Medium	High	High	Low
impacto_academico/laboral	Yes	Yes	No	Yes	No
etiqueta_de_adiccion	0	0	0	1	1
horas_ocio	2.90	6.05	5.19	7.36	9.34
ratio_finde_diario	1.22	1.32	1.43	1.25	1.26
estado_adiccion	No adicto	No adicto	No adicto	Adicto	Adicto

Con esto se confirma que estado_adiccion es solo una traducción de etiqueta_de_adiccion a etiquetas legibles: 5308 registros se etiquetaron como “Adicto” (equivalente a 1) y 2192 como “No adicto” (equivalente a 0). No se está introduciendo nada nuevo. Las variables num_cols y cat_cols actualizadas son: - num_cols: edad, horas_diarias_pantalla, horas_redes_sociales, horas_videojuegos, horas_trabajo/estudio, horas_sueño, notificaciones_por_dia, aperturas_apps_por_dia, tiempo_en_pantalla_fin_de_semana, horas_ocio, ratio_finde_diario, etiqueta_de_adiccion - cat_cols: genero, nivel_estres, impacto_academico/laboral, estado_adiccion

6. Análisis exploratorio de datos

6.1. Análisis univariado

```
colores = [
    "steelblue", "darkorange", "forestgreen",
    "crimson", "gold", "lightcoral",
    "yellowgreen", "cadetblue", "powderblue",
    "lightgreen", "lightgray", "plum"
]

n_columnas = 3
n_filas = math.ceil(len(num_cols) / n_columnas)

fig, axes = plt.subplots(
    n_filas,
    n_columnas,
    figsize=(10.5, 2.25 * n_filas),
    constrained_layout=True
)

axes = axes.flatten()

for i, col in enumerate(num_cols):
    sns.histplot(
        data=df_clean,
        x=col,
        bins=20,
        kde=False,
        color=colores[i % len(colores)],
        ax=axes[i]
    )

    axes[i].set_title(col.replace("_", " "), fontsize=8)
    axes[i].set_xlabel("")
    axes[i].set_ylabel("Frecuencia", fontsize=7)
    axes[i].tick_params(axis="both", labelsize=6)

# Quitar recuadros que no se usan
for ax in axes[len(num_cols):]:
    ax.remove()

fig.suptitle(
    "Distribución de las variables numéricas",
    fontsize=11
)

plt.show()
```




Figura 1: Histogramas de las variables numéricas del dataset.

Cada histograma muestra cómo se distribuyen los valores de cada variable numérica. En las variables relacionadas con la interacción, como `notificaciones_por_dia` y `aperturas_apps_por_dia`, se observa una dispersión bastante amplia. Aunque la mayoría de los usuarios se concentra en rangos intermedios, también hay algunos con frecuencias mucho más altas. Por otro lado, las variables expresadas en horas, como `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo/estudio` y `horas_sueño`, presentan rangos más reducidos. En particular, `horas_sueño` se concentra alrededor de valores medios, mientras que el tiempo de pantalla y de uso de redes sociales varía más entre los usuarios. La edad también se encuentra dentro de un rango relativamente limitado, correspondiente principalmente a adultos jóvenes.

```
counts = df_clean['estado_adiccion'].value_counts()
counts.plot(kind='bar',color=['darkred','darkgreen'])
plt.xlabel("Estado de adicción")
plt.ylabel("Frecuencia")
plt.xticks(rotation=0)
plt.show()
```




Figura 2: Distribución de la variable objetivo: estado de adicción (0 = No adicción, 1 = Con adicción).

El gráfico de barras muestra una clara asimetría y desbalance de clases, donde la categoría “Adicto” predomina ampliamente (superando las 5,000 observaciones) frente a la de “No adicto” (alrededor de 2,200). Este desequilibrio implica que, para fases posteriores de modelado o análisis estadístico, se debe considerar el balanceo de datos o métricas de evaluación adecuadas para evitar sesgos hacia la clase mayoritaria.*

```
colores = [
    "steelblue", "darkorange", "forestgreen",
    "lightcoral", "yellowgreen", "cadetblue",
    "powderblue", "lightgreen", "lightgray"
]

num_cols = [
    "edad",
    "horas_diarias_pantalla",
    "horas_redes_sociales",
    "horas_videojuegos",
    "horas_trabajo/estudio",
    "horas_sueño",
    "notificaciones_por_dia",
    "aperturas_apps_por_dia",
    "tiempo_pantalla_finde",
]

n_columnas = 3
n_filas = math.ceil(len(num_cols) / n_columnas)

fig, axes = plt.subplots(
    n_filas,
    n_columnas,
    figsize=(10.5, 2.4 * n_filas),
    constrained_layout=True
)

axes = axes.flatten()

for i, col in enumerate(num_cols):
    sns.boxplot(
        data=df_clean,
        y=col,
        color=colores[i % len(colores)],
        ax=axes[i],
        width=0.45,
        fliersize=2
    )

    axes[i].set_title(col.replace("_", " "), fontsize=8)
    axes[i].set_xlabel("")
    axes[i].set_ylabel("")
    axes[i].tick_params(axis="both", labelsize=6)

for ax in axes[len(num_cols):]:
    ax.remove()
```

```
fig.suptitle(
    "Dispersión y valores atípicos de las variables numéricas",
    fontsize=11
)

plt.show()
```




Figura 3: Boxplots de las variables numéricas del dataset.

Los boxplots se apoyan en los cuartiles, que dividen los datos ordenados en cuatro partes iguales (Walpole et al. 2012):

$$Q_k = \text{valor en la posición } \frac{k}{4}(n + 1) \quad (1)$$

La visualización de las variables numéricas (edad, tiempo en pantalla, uso de apps, sueño, etc.) muestra en general una distribución bastante homogénea y centrada. Salvo por ligeras asimetrías o atípicos aislados en hábitos de uso intensivo (como notificaciones o videojuegos), las observaciones representan comportamientos reales de los usuarios y no errores de registro, por lo que se decide conservar todas las variables completas para el análisis.

```

descripcion = df_clean[num_cols].describe().T
descripcion.columns = [
    "n", "Media", "Desv. est.", "Mín.", "Q1", "Mediana", "Q3", "Máx."]
descripcion.index.name = "Variable"
tabla(descripcion, decimales={"n": 0}, tamaño="small",
    → alineacion="p{3.5cm}*{8}{c}")

```

Tabla 9: Estadística descriptiva de las variables numéricas.

Variable	n	Media	Desv. est.	Mín.	Q1	Mediana	Q3	Máx.
edad	7,500	26.57	5.20	18.00	22.00	27.00	31.00	35.00
horas_diarias_pantalla	7,500	7.50	2.61	3.00	5.22	7.53	9.81	12.00
horas_redes_sociales	7,500	3.27	1.59	0.50	1.91	3.27	4.63	6.00
horas_videojuegos	7,500	2.01	1.15	0.00	1.02	2.04	2.99	4.00
horas_trabajo/estudio	7,500	3.24	1.60	0.50	1.85	3.23	4.64	6.00
horas_sueño	7,500	6.74	1.28	4.50	5.63	6.72	7.84	9.00
notificaciones_por_dia	7,500	134.26	66.59	20.00	76.00	134.00	191.00	250.00
aperturas_apps_por_dia	7,500	97.83	48.42	15.00	55.00	98.00	140.00	180.00
tiempo_pantalla_finde	7,500	9.24	2.72	3.58	6.96	9.26	11.54	14.88

Se calculan las medidas de tendencia central y dispersión de cada variable numérica (Walpole et al. 2012):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & \text{si } n \text{ es par} \end{cases} \quad (3)$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (4)$$

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (5)$$

$$CV = \frac{s}{\bar{x}} \times 100\% \quad (6)$$

En general, al comparar la media y la mediana de las variables numéricas observamos distribuciones relativamente equilibradas y sin una asimetría marcada. Por ejemplo, la edad presenta una media de 26.57 y una mediana de 27 años; las horas diarias de pantalla, 7.50 y 7.53; las horas en redes sociales, 3.27 y 3.27; las horas de trabajo/estudio, 3.24 y 3.23; las horas de sueño, 6.74 y 6.72; y el tiempo de pantalla durante el fin de semana, 9.24 y 9.26. En videojuegos, la diferencia es ligeramente

mayor, con una media de 2.01 y una mediana de 2.04 horas, lo que sugiere una ligera asimetría. Con respecto a la desviación estándar: las notificaciones por día (66.59) y las aperturas de aplicaciones (48.42) tienen una dispersión amplia, mientras que entre las variables medidas en horas destacan el tiempo de pantalla durante el fin de semana (2.72) y las horas diarias de pantalla (2.61). Los boxplots también muestran algunos valores extremos o atípicos aislados, especialmente en variables relacionadas con el uso intensivo del celular, como las notificaciones y los videojuegos. En resumen, estas variables presentan mayor variabilidad en los patrones de uso, aunque los valores extremos fueron considerados comportamientos posibles de los usuarios y se conservaron para el análisis.

```
for i in cat_cols:
    df_clean[i].value_counts(normalize=True)
```

Tabla 10: *Proporción de registros por género.*

Variable	Male	Other	Female
proportion	34.04	33.15	32.81

Tabla 11: *Proporción de registros por nivel de estrés.*

Variable	High	Low	Medium
proportion	34.13	33.37	32.49

Tabla 12: *Proporción de registros por impacto académico o laboral.*

Variable	No	Yes
proportion	50.04	49.96

Tabla 13: *Proporción de registros por estado de adicción.*

Variable	Adicto	No adicto
proportion	70.77	29.23

En las variables categóricas se observa bien equilibrio en género, ya que Masculino representa el 34.04%, Otro el 33.15% y Femenino el 32.81%, el estrés también se presenta de manera similar: Alto concentra el 34.13%, Bajo el 33.37% y Medio el 32.49%. En el impacto académico o laboral hay prácticamente una igualdad en No (50.04%) y Sí (49.96%). En diferencia, la variable estado de adicción presenta un desbalance evidente: Adicto representa el 70.77% de los registros, mientras que No adicto corresponde al 29.23%, esta va a ser importante para modelos predictivos posteriores. De las variables categóricas utilizadas, `nivel_estres` se tratará como ordinal, debido a que sus categorías tienen un orden natural: Bajo < Medio < Alto; en cambio, 'género' e 'impacto académico/laboral' son variables nominales y `estado_adiccion` es una variable binaria.

6.2. Análisis multivariado

```
sns.heatmap(df_clean.corr(numeric_only = True), annot = True, fmt=".2f",
            cmap="vlag")
```




Figura 4: Matriz de correlación de las variables numéricas.

En el mapa de calor se observa una relación fuerte entre las horas de pantalla diarias y las horas de pantalla durante el fin de semana, con una correlación cercana a 1. Esto quiere decir que las personas que suelen pasar más tiempo frente a una pantalla durante el día a día también tienden a mantener un uso elevado los fines de semana. Debido a que ambas variables muestran un comportamiento muy parecido, lo que podría generar colinealidad.

Por otro lado, la etiqueta de adicción presenta una correlación aproximada de 0.6 con las horas diarias de pantalla, 0.4 con el tiempo dedicado a redes sociales y 0.6 con las horas de pantalla durante el fin de semana.

Estos resultados muestran que las tres variables tienen cierta relación con la etiqueta de adicción. Pero es importante recordar que una correlación no significa necesariamente que exista una relación de causa y efecto.

Las variables que tienen mayor asociación lineal podemos fijarnos que son cantidad de horas diarias en pantalla, cantidad de horas en redes sociales y tiempo de pantalla en los fines de semanas, siendo

aproximadamente 0.6 , 0.4 , 0.6 aproximadamente. A diferencia del resto que cuenta con valores muy cercanos 0.0. Estos resultados podrían ser útil para futuros modelos

La correlación de Pearson mide la fuerza y dirección de la relación lineal entre dos variables, y se calcula a partir de la covarianza y las desviaciones estándar de cada una (Walpole et al. 2012):

$$r_{xy} = \frac{\text{cov}(x, y)}{s_x s_y} \quad (7)$$

```
del plt
import matplotlib.pyplot as plt
sns.boxplot(data=df_clean, x="estado_adiccion", y="horas_ocio", palette =
→ "husl", legend=True)
```




Figura 5: Horas de ocio según el estado de adicción.




Figura 6: Horas de ocio según el género.




Figura 7: Horas de ocio según el impacto académico o laboral.




Figura 8: Razón entre pantalla de fin de semana y pantalla diaria según el estado de adicción.




Figura 9: Horas de sueño según el estado de adicción.




Figura 10: Horas diarias de pantalla según el nivel de estrés.




Figura 11: Horas de ocio según el nivel de estrés.

En los tres géneros, los usuarios con etiqueta de adicción presentan una mediana de horas de ocio mayor que quienes tienen etiqueta 0.

Las cajas del grupo con etiqueta 1 también son algo más altas, lo que indica mayor dispersión. Pero existe solapamiento entre ambas clases, por lo que las horas de ocio por sí solas no permiten separarlas completamente.

Al comparar los géneros, las medianas y la dispersión son similares dentro de cada clase.

```
plt.figure(figsize=(8,5))
sns.countplot(data=df_clean, x="nivel_estres", hue="estado_adiccion",
              order=["Low","Medium","High"], palette="colorblind")
plt.title("Nivel de estrés, agrupado por estado de adicción")
plt.xlabel("Nivel de estrés")
plt.ylabel("Conteo")
plt.tight_layout()
plt.show()
```




Figura 12: Nivel de estrés según el estado de adicción.

```
sns.histplot(data=df_clean, x = df_clean["genero"], hue =
             'etiqueta_de_adiccion')
plt.show()
```




Figura 13: Distribución de genero según la etiqueta de adicción.




Figura 14: Distribución del nivel de estrés según la etiqueta de adicción.




Figura 15: Distribución del impacto académico y social según la etiqueta de adicción.

La proporción de usuarios con una etiqueta de adicción se mantiene bastante similar entre los distintos géneros, niveles de estrés y categorías de impacto académico o laboral. Esto indica que no existen diferencias importantes entre estos grupos. Sin embargo, con estos resultados no podemos concluir que estas variables sean una causa o una consecuencia directa del uso problemático.

```
sns.scatterplot(data=df_renombrado, x= 'horas_trabajo/estudio', y=
↳ 'horas_diarias_pantalla', hue = 'etiqueta_de_adiccion')
```




Figura 16: Relación entre horas de trabajo o estudio y horas diarias de pantalla, según la etiqueta de adicción.




Figura 17: Relación entre horas de sueño y horas en redes sociales, según la etiqueta de adicción.




Figura 18: Relación entre notificaciones por día y horas de sueño, según la etiqueta de adicción.




Figura 19: Relación entre horas de videojuegos y horas de trabajo o estudio, según la etiqueta de adicción.




Figura 20: Relación entre edad y horas diarias de pantalla, según la etiqueta de adicción.

En la primera comparación podemos observar que a medida que aumentan las horas diarias frente a una pantalla, también parece aumentar la posibilidad de que una persona sea 'adicta'. A partir de las 8 horas, se puede notar que la mayoría de las personas son consideradas adictas. En cambio, en las horas de trabajo y estudio no se observa un patrón claro.

En la segunda comparación, entre las 0 y 4 horas no se logra identificar un patrón a simple vista. Sin embargo, entre las 4 y 6 horas podemos observar que todas las personas son consideradas adictas. Por otro lado, en las horas de sueño tampoco se aprecia un patrón claro relacionado con la adicción.

En la tercera y cuarta comparación no se observa una tendencia clara entre las variables. Lo que sí podemos notar en las gráficas es que las personas consideradas adictas aparecen en una mayor proporción que las que no lo son.

Finalmente, en la última gráfica podemos observar que, en las edades más bajas, hay una mayor cantidad de personas consideradas adictas. Además, nuevamente se puede apreciar que mientras aumentan las horas diarias de uso de pantalla, también parece aumentar la posibilidad de que una persona sea considerada adicta hasta el valor de 8, ya que de 8 en adelante la persona ya se le considera como una persona 'adicta'.

```
variables = [
    "edad",
    "horas_diarias_pantalla",
    "horas_redes_sociales",
    "horas_sueño",
    "etiqueta_de_adiccion"
```

]

```
matriz_correlacion = df_clean[variables].corr().round(2)
tabla(matriz_correlacion, decimales=2, tamaño="scriptsize")
```

Tabla 14: Matriz de correlación entre las variables numéricas.

index	edad	horas_diarias_pantalla	horas_redes_sociales	horas_sueño	etiqueta_de_adiccion
edad	1.00	0.01	0.00	-0.01	0.00
horas_diarias_pantalla	0.01	1.00	0.01	0.02	0.58
horas_redes_sociales	0.00	0.01	1.00	0.01	0.41
horas_sueño	-0.01	0.02	0.01	1.00	0.04
etiqueta_de_adiccion	0.00	0.58	0.41	0.04	1.00

La covarianza mide cómo varían juntas dos variables: positiva si crecen juntas, negativa si una crece cuando la otra decrece (Walpole et al. 2012).

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (8)$$

7. Conclusiones de P1

Hemos encontrado 819 valores nulos correspondientes a una única columna: nivel_adiccion, por lo cual hemos optado excluir la columna nivel_adiccion, puesto que revelaba la misma información que la variable objetivo que es etiqueta_de_adiccion.

La cantidad de personas que presentan la condición de “Adicto” de la variable etiqueta_de_adiccion es 5308 y la que presentan la condición de “No adicto” es 2192. El 70.77% presenta adicción al smartphone y el 29.22% no presenta esta adicción: por lo tanto la clase objetivo no está balanceada y eso implica una mayor tendencia a la categoría “Adicto” lo cual en un futuro puede llevar a sesgos en el modelo de predicción. Las variables más prometedoras que encontramos fueron: horas_diarias_pantalla, horas_redes_sociales, ratio_ratio_finde_diario y nivel_estres reúnen información muy relacionada con etiqueta_de_adiccion. horas_diarias_pantalla: Las personas que usan más tiempo su celular son las que tienen la mayor cantidad de adictos. horas_redes_sociales: En los adictos, dedican la mayor cantidad de horas a las redes sociales. ratio_ratio_finde_diario: En las personas adictas el ratio de su uso del fin de semana con el uso diario normal se mantiene cerca a uno, dejando en claro que ven la misma cantidad de horas sin importar el día. En cambio en las no adictas encontramos que el ratio de su uso del fin de semana con su uso diario tiende siempre a más que uno, por lo cual se infiere que usan menos el celular en horarios de trabajo o estudio y lo usan más en su tiempo libre. Por último hemos encontrado que el factor más determinante en clasificar a una persona como Adicto o No adicto es la cantidad de horas que dedica al celular, específicamente a redes sociales, lo cual nos servirá a futuro para el entrenamiento del modelo de clasificación. Por otro lado, al ser un set de datos sintéticos no encontramos muchos patrones clásicos relacionados con

estudios previos que asocian la adicción al smartphone con menor rendimiento académico, en parte por su efecto negativo sobre el sueño (Rathakrishnan et al. 2021).

8. Limitaciones y consideraciones éticas

El archivo no incluye documentación sobre el muestreo, instrumento de medición, país, periodo de recolección ni procedimiento de etiquetado. En consecuencia, la muestra no debe asumirse representativa de la población universitaria peruana ni de un grupo demográfico específico. Además, el término “adicción” debe tratarse como una etiqueta del dataset y no como un diagnóstico clínico. La evidencia académica recomienda emplear instrumentos validados y distinguir entre uso frecuente y uso problemático Kwon et al. (2013); Csibi et al. (2018).

Referencias

- Amez, S y S Baert (2020). Smartphone Use and Academic Performance: A Literature Review. *International Journal of Educational Research* **103**, 101618.
- Csibi, S, MD Griffiths, B Cook, Z Demetrovics y A Szabo (2018). The Psychometric Properties of the Smartphone Application-Based Addiction Scale (SABAS). *International Journal of Mental Health and Addiction* **16**(2), 393-403.
- Kwon, M, JY Lee, WY Won, JW Park, JA Min, C Hahn, X Gu, JH Choi y DJ Kim (2013). Development and Validation of a Smartphone Addiction Scale (SAS). *PLOS ONE* **8**(2), e56936.
- Nusrat, Z (s.f.). *Smartphone Usage and Addiction Analysis Dataset*. Kaggle. Fecha de publicación no indicada en la página; consultado el 17 de septiembre de 2026. <https://www.kaggle.com/datasets/zahranusratt/smartphone-usage-and-addiction-analysis-dataset>.
- Rathakrishnan, B, SS Bikar Singh, MR Kamaluddin, A Yahaya, MA Mohd Nasir, F Ibrahim y Z Ab Rahman (2021). Smartphone Addiction and Sleep Quality on Academic Performance of University Students: An Exploratory Research. *International Journal of Environmental Research and Public Health* **18**(16), 8291.
- Walpole, RE, RH Myers, SL Myers y K Ye (2012). *Probabilidad y Estadística para Ingeniería y Ciencias*. 9na. Pearson Educación.