

P1 - Uso de Smartphones y Riesgo de Adiccion

Hiter Frank Rubio Peralta

Alumno

Jossep Jorge Froilan Choroco Neyra

Alumno

Joel David De la Cruz Cardenas

Alumno

Rodrigo Octavio Lucatoni Flores Ruiz

Alumno

Victor Andres Diaz Garcia

Alumno

Curso:

Introduccion a Ciencia de Datos e Inteligencia Artificial

20 de Septiembre del 2026

Tabla de contenidos

1. Resumen	3
2. Planteamiento del problema	3
3. Contexto del dataset	3
3.1. Fuente y unidad de análisis	3
3.2. Diccionario de variables	3
4. Carga y exploración inicial	4
4.1. Librerías	4
4.2. Carga de datos	4
4.3. Dimensiones y estructura	5
4.4. Tipos de variables y primeras estadísticas	7
4.5. Dimensiones y tipos de variables	8
4.6. Calidad de datos	9
5. Preprocesamiento y decisiones de data wrangling	10
5.1. Revisión de fuga de información	10
5.2. Variable derivada para la comunicación	12
6. Análisis exploratorio de datos	12
6.1. Análisis univariado	13
6.2. Análisis multivariado	25
7. Conclusiones de P1	32
8. Limitaciones y consideraciones éticas	32

Listado de Tablas

1. Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV	5
2. Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.	6
3. Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.	7
4. Primeras 10 filas del dataset (ya con nombres de columna en español)	7

Listado de Figuras

1. Resumen

*Instrucciones para esta sección: este resumen se escribe **al final**, cuando ya se tengan los resultados de la exploración de datos y las conclusiones de P1. Debe tener entre 150 y 200 palabras e incluir, en este orden: (1) qué dataset se usó y cuántos registros/columnas tiene, (2) el objetivo del análisis (qué se busca entender sobre `etiqueta_de_adiccion`), (3) las dos o tres decisiones de limpieza más importantes que se tomaron y por qué, (4) los dos o tres hallazgos más relevantes del EDA, citando cifras reales obtenidas del código (no inventadas ni copiadas de un borrador), y (5) una frase que conecte con lo que se hará en la P2. No copiar texto de otras secciones; debe ser una síntesis propia, escrita por el equipo.*

2. Planteamiento del problema

El uso intensivo de celulares puede influir en la salud integral de las personas al relacionarse con irregularidades en el sueño, estrés, dificultades en el ámbito académico y laboral. Además, la investigación requiere de una conceptualización alta: una alta frecuencia de uso no significa necesariamente a una condición clínica. Artículos como SABAS permiten estudiar síntomas de uso problemático, pero no sustituyen una evaluación profesional Csibi et al. (2018). La literatura también ayuda con asociaciones entre el uso del smartphone y el desempeño académico, aunque con limitaciones claras para atribuir causalidad Amez y Baert (2020).

Para este proyecto, se formula la siguiente pregunta de análisis:

¿Qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos `smartphone-use-prediction`?

3. Contexto del dataset

3.1. Fuente y unidad de análisis

El archivo `Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv` fue proporcionado para el proyecto y corresponde al dataset publicado como *Smartphone Usage and Addiction Analysis* en Kaggle Nusrat (s.f.). Cada fila representa a un usuario y contiene indicadores demográficos, de comportamiento digital, descanso, estrés e impacto percibido en actividades académicas o laborales.

La unidad de análisis es el usuario. El dataset incluye 7,500 registros y 16 columnas originales: dos identificadores, nueve variables numéricas, cuatro variables categóricas y la etiqueta binaria objetivo.

3.2. Diccionario de variables

- **Identificadores:** `ID_transaccion` y `ID_usuario` son variables de texto. Se usan para verificar unicidad, pero no aportan significado analítico y se excluirán como predictores.
- **Demografía:** `edad` (numérica) y `genero` (categórica) caracterizan la muestra.
- **Uso del smartphone:** `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo_estudio`, `notificaciones_por_dia`, `aperturas_apps_por_dia` y `tiempo_en_pantalla_fin_de_semana` son variables numéricas que miden intensidad y tipo de uso.

- **Bienestar y contexto:** horas_sueño es numérica; nivel_estres y impacto_academico/laboral son categóricas. Se emplean para explorar descanso e impacto funcional.
- **Severidad:** nivel_adiccion es categórica ordinal. Se describe en P1, pero se excluye como predictor en P2 por fuga de información.
- **Objetivo:** etiqueta_de_adiccion es binaria: 0 significa *No adicción* y 1 significa *Con adicción*.

La variable nivel_adiccion contiene una categorización de severidad (None, Mild, Moderate, Severe). Por su definición operativa, puede estar construida directamente a partir de la etiqueta final; por ello se audita explícitamente antes de considerar su uso en P2.

4. Carga y exploración inicial

4.1. Librerías

El primer bloque reúne las librerías necesarias para el proyecto. Además el estilo de seaborn

```
# =====  
# CONFIGURACIÓN ÚNICA DEL REPORTE  
# Librerías y estilos se ejecutan una sola vez  
# =====  
import pandas as pd  
import numpy as np  
from matplotlib.pyplot import boxplot  
from matplotlib.pyplot import hist  
import matplotlib.pyplot as plt  
import seaborn as sns  
from IPython.display import display, Latex  
import kagglehub  
from scipy import stats  
  
sns.set_theme(style="whitegrid")
```

El segundo bloque, que no se imprime en el PDF para no alargarlo, define funciones de presentación: la función tabla(), que reproduce desde Python el estilo de tabla (kable con booktabs y filas alternadas), en el PDF se omite el código que solo dibuja los gráficos, igual que en la plantilla del curso; todo ese código está completo y comentado en UTEC-Report1.qmd. Sí se muestra todo el código que carga, transforma o calcula.

4.2. Carga de datos

Usando la librería de kaggle y os logramos una carga universal exitosa en cualquier equipo y evitamos errores de carga del dataset

```
# Cargamos el archivo csv  
path = (kagglehub.dataset_download  
        ("jayjoshi37/smartphone-usage-and-addiction-prediction"))  
  
import os
```

```
# Ruta directa al archivo CSV combinando la ruta de descarga y el nombre del
# archivo
ruta_csv = (os.path.join(path,
                          "Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv"))
df = pd.read_csv(ruta_csv)
n_filas, n_columnas = df.shape
print(f"Dimensiones: {n_filas:,} filas x {n_columnas} columnas")
```

Dimensiones: 7,500 filas x 16 columnas

El archivo se carga completo, con 7500 filas y 16 columnas. `df` no se modifica en ningún momento: todas las transformaciones posteriores se aplican sobre copias, de modo que cada decisión puede contrastarse contra el archivo original.

4.3. Dimensiones y estructura

```
primeras = df.head(5).fillna("NaN").T.astype(str)
primeras.columns = [f"Usuario {i}" for i in range(1, 6)]
primeras.index.name = "Columna"
tabla(primeras, tamaño="footnotesize")
```

Tabla 1: Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
transaction_id	TXN00001	TXN00002	TXN00003	TXN00004	TXN00005
user_id	U00001	U00002	U00003	U00004	U00005
age	21	24	31	32	25
gender	Male	Other	Other	Other	Male
daily_screen_time_hours	3.23	5.09	6.06	7.83	9.96
social_media_hours	2.01	3.81	1.36	5.85	5.92
gaming_hours	0.89	2.24	3.83	1.51	3.42
work_study_hours	4.55	4.44	2.35	3.54	5.27
sleep_hours	7.55	7.66	4.92	8.23	6.21
notifications_per_day	248	127	44	178	136
app_opens_per_day	154	71	106	107	177
weekend_screen_time	3.95	6.71	8.68	9.77	12.55
stress_level	Medium	Medium	High	High	Low
academic_work_impact	Yes	Yes	No	Yes	No
addiction_level	NaN	NaN	Mild	Moderate	Severe
addicted_label	0	0	0	1	1

La Tabla 1 se presenta transpuesta porque las 16 columnas no caben a lo ancho de la página. Ya en estas cinco filas aparece una señal de alerta: los usuarios 1 y 2 muestran NaN (valor nulo) en `addiction_level`, un valor que se investiga en la sección (inserta sección).

Tabla 2: Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.

Columna	Tipo (pandas)	No nulos	Nulos	Valores distintos
transaction_id	str	7,500	0	7,500
user_id	str	7,500	0	7,500
age	int64	7,500	0	18
gender	str	7,500	0	3
daily_screen_time_hours	float64	7,500	0	900
social_media_hours	float64	7,500	0	551
gaming_hours	float64	7,500	0	401
work_study_hours	float64	7,500	0	551
sleep_hours	float64	7,500	0	451
notifications_per_day	int64	7,500	0	231
app_opens_per_day	int64	7,500	0	166
weekend_screen_time	float64	7,500	0	1,096
stress_level	str	7,500	0	3
academic_work_impact	str	7,500	0	2
addiction_level	str	6,681	819	3
addicted_label	int64	7,500	0	2

Interpretación. La Tabla 2 permite verificar que el tipo asignado por pandas sea coherente con lo que representa cada variable:

- Las nueve variables de uso, edad y sueño se cargaron como números (int64 o float64) y no como texto, que es el error silencioso más frecuente al leer un CSV.
- addicted_label se cargó como entero, pero es una variable **categorica binaria**: el tipo de dato no coincide con su naturaleza estadística, y así se tratará en el análisis.
- Las columnas de texto (tipo object en pandas 2 o str en pandas 3) son de dos clases muy distintas: transaction_id y user_id tienen 7500 valores distintos, uno por fila, lo que las identifica como **identificadores**; en cambio, gender, stress_level, academic_work_impact y addiction_level tienen entre 2 y 4 valores, es decir, son **categoricas**.
- Solo addiction_level presenta nulos np.int64(819), y muestra 3 valores distintos, cuando una escala de severidad suele tener cuatro niveles.

4.4. Tipos de variables y primeras estadísticas

Tabla 3: Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.

Columna original	Nombre en el reporte	Tipo estadístico	Descripción
transaction_id	id_transaccion	Identificador	Código del registro (TXN00001...)
user_id	id_usuario	Identificador	Código del usuario (U00001...)
age	edad	Cuantitativa discreta	Edad en años cumplidos
gender	genero	Cualitativa nominal	Masculino, Femenino u Otro
daily_screen_time_hours	horas_diarias_pantalla	Cuantitativa continua	Horas de pantalla en un día típico
social_media_hours	horas_redes_sociales	Cuantitativa continua	Horas diarias en redes sociales
gaming_hours	horas_videojuegos	Cuantitativa continua	Horas diarias en videojuegos
work_study_hours	horas_trabajo_estudio	Cuantitativa continua	Horas diarias de trabajo o estudio
sleep_hours	horas_sueno	Cuantitativa continua	Horas de sueño por noche
notifications_per_day	notificaciones_por_dia	Cuantitativa discreta	Notificaciones recibidas al día
app_opens_per_day	aperturas_apps_por_dia	Cuantitativa discreta	Veces que abre aplicaciones al día
weekend_screen_time	tiempo_en_pantalla_fin_de_semana	Cuantitativa continua	Horas de pantalla en un día de fin de semana
stress_level	nivel_estres	Cualitativa ordinal	Bajo < Medio < Alto
academic_work_impact	impacto_academico_laboral	Cualitativa nominal (binaria)	Si el uso afecta sus estudios o trabajo (Sí/No)
addiction_level	nivel_adiccion	Cualitativa ordinal	Ninguna < Leve < Moderada < Severa
addicted_label	etiqueta_de_adiccion	Cualitativa binaria (objetivo)	1 = adicto, 0 = no adicto

La Tabla 3 resume la naturaleza de cada variable. La distinción entre tipos estadísticos no es un detalle formal: decide qué gráficos y estadísticos corresponden a cada variable (histogramas y boxplots para las cuantitativas, gráficos de barras para las cualitativas) y, en la P2, cómo se codificará cada una.

```
# Ejemplo de tabla bien formada: sin print(), como última línea del chunk,
# con label + tbl-cap.
df.head(6)
```

	ID_transaccion	ID_usuario	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos
0	TXN00001	U00001	21	Male	3.23	2.01	0.89
1	TXN00002	U00002	24	Other	5.09	3.81	2.24
2	TXN00003	U00003	31	Other	6.06	1.36	3.83
3	TXN00004	U00004	32	Other	7.83	5.85	1.51
4	TXN00005	U00005	25	Male	9.96	5.92	3.42
5	TXN00006	U00006	26	Male	9.32	4.26	0.29

```
<class 'pandas.DataFrame'>
```

```
RangeIndex: 7500 entries, 0 to 7499
```

```
Data columns (total 16 columns):
```

```
#      Column                                Non-Null Count  Dtype
---  -
0     ID_transaccion                        7500 non-null    str
```

```

1  ID_usuario          7500 non-null    str
2  edad                7500 non-null    int64
3  genero              7500 non-null    str
4  horas_diarias_pantalla  7500 non-null    float64
5  horas_redes_sociales  7500 non-null    float64
6  horas_videojuegos    7500 non-null    float64
7  horas_trabajo/estudio  7500 non-null    float64
8  horas_sueño         7500 non-null    float64
9  notificaciones_por_dia  7500 non-null    int64
10 aperturas_apps_por_dia  7500 non-null    int64
11 tiempo_en_pantalla_fin_de_semana  7500 non-null    float64
12 nivel_estres        7500 non-null    str
13 impacto_academico/laboral  7500 non-null    str
14 nivel_adiccion      6681 non-null    str
15 etiqueta_de_adiccion  7500 non-null    int64

```

dtypes: float64(6), int64(4), str(6)

memory usage: 937.6 KB

```

Index(['ID_transaccion', 'ID_usuario', 'edad', 'genero',
      'horas_diarias_pantalla', 'horas_redes_sociales', 'horas_videojuegos',
      'horas_trabajo/estudio', 'horas_sueño', 'notificaciones_por_dia',
      'aperturas_apps_por_dia', 'tiempo_en_pantalla_fin_de_semana',
      'nivel_estres', 'impacto_academico/laboral', 'nivel_adiccion',
      'etiqueta_de_adiccion'],
      dtype='str')

```

4.5. Dimensiones y tipos de variables

TODO: mostrar df.shape y df.dtypes (o df.info()) para revisar dimensiones
→ y tipos de variables.

df.shape

(7500, 16)

TODO: mostrar df.shape y df.dtypes (o df.info()) para revisar dimensiones
→ y tipos de variables.

df.dtypes

```

ID_transaccion      str
ID_usuario           str
edad                int64
genero              str
horas_diarias_pantalla  float64
horas_redes_sociales  float64
horas_videojuegos    float64

```

```

horas_trabajo/estudio      float64
horas_sueño                float64
notificaciones_por_dia     int64
aperturas_apps_por_dia    int64
tiempo_en_pantalla_fin_de_semana float64
nivel_estres               str
impacto_academico/laboral str
nivel_adiccion             str
etiqueta_de_adiccion       int64
dtype: object

```

Instrucciones para esta sección: comentar, con base en la salida real de `df.info()` / `df.dtypes`, cuántas filas y columnas tiene el dataset, qué columnas son numéricas y cuáles categóricas, y si algún tipo de dato no corresponde con lo esperado (por ejemplo, una variable numérica cargada como texto). No repetir de memoria las cifras ya mencionadas en “Contexto del dataset”; verificarlas con el código.

4.6. Calidad de datos

```

# TODO: contar valores nulos por columna (df.isnull().sum()) y filas
↳ duplicadas (df.duplicated().sum()).

```

```

# TODO: contar valores nulos por columna (df.isnull().sum()) y filas
↳ duplicadas (df.duplicated().sum()).
df["nivel_adiccion"].isnull().sum()
#Notamos que hay 819 valores nulos en la columna 'nivel_adiccion'

```

```
np.int64(819)
```

Instrucciones para esta sección: reportar cuántos valores faltantes se encontraron y en qué columna(s), y cuántas filas duplicadas existen. Explicar la causa probable de los faltantes (por ejemplo, si corresponden a una categoría real como “sin severidad registrada”) y justificar la decisión tomada: ¿se imputan, se eliminan o se excluye la columna? Si se excluye una variable por fuga de información, explicarlo aquí o remitir a la sección de fuga de información.

```

# TODO: revisar rangos (df.describe()) de las variables numéricas y valores
↳ únicos de las categóricas, para detectar valores imposibles o atípicos.
df.describe()

```

	edad	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
count	7500.000000	7500.000000	7500.000000	7500.000000	7500.000000
mean	26.568800	7.499912	3.273484	2.014183	3.242420
std	5.197108	2.609188	1.585342	1.146039	1.600765
min	18.000000	3.000000	0.500000	0.000000	0.500000
25 %	22.000000	5.220000	1.910000	1.020000	1.850000
50 %	27.000000	7.525000	3.270000	2.040000	3.230000

	edad	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
75 %	31.000000	9.810000	4.630000	2.990000	4.640000
max	35.000000	12.000000	6.000000	4.000000	6.000000

Instrucciones para esta sección: comentar si los rangos observados en `df.describe()` son plausibles para lo que representa cada variable (por ejemplo, edades, horas de uso, horas de sueño). Señalar explícitamente cualquier valor fuera de rango lógico y qué se hizo con los identificadores (`ID_transaccion`, `ID_usuario`): ¿se conservan solo como referencia o se descartan del análisis?

5. Preprocesamiento y decisiones de data wrangling

Notamos que hay 819 valores nulos en la columna “nivel_adiccion”, por lo que procederemos a analizar las filas que contengan valores nulos en esta columna

	ID_transaccion	ID_usuario	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos
0	TXN00001	U00001	21	Male	3.23	2.01	0.89
1	TXN00002	U00002	24	Other	5.09	3.81	2.24
8	TXN00009	U00009	21	Other	4.38	1.38	2.72
11	TXN00012	U00012	27	Other	5.16	1.82	2.27
13	TXN00014	U00014	32	Male	4.09	1.74	1.35

5.1. Revisión de fuga de información

```
# TODO: construir una tabla cruzada (pd.crosstab) entre nivel_adiccion y
↳ etiqueta_de_adiccion para revisar si nivel_adiccion "filtra" la
↳ respuesta.

pd.crosstab(df["nivel_adiccion"], df["etiqueta_de_adiccion"])

# Notamos que la columna 'nivel_adiccion' o cae en 0 cuando es baja o cae en
↳ 1 cuando es media o alta, no hay ninguna excepción
# para alguien de adicción media p alta, la información de
↳ 'etiqueta_de_adiccion' es la necesaria y objetivo para este análisis
# puesto que queremos encontrar qué patrones de uso, descanso y contexto
↳ personal están asociados con la etiqueta de adicción en el conjunto de
↳ datos que estamos abordando.
```

etiqueta_de_adiccion	0	1
nivel_adiccion		
Mild	1373	0
Moderate	0	2874
Severe	0	2434

Instrucciones para esta sección: interpretar la tabla cruzada anterior: ¿existe alguna categoría de nivel_adiccion que se asocie de forma perfecta o casi perfecta con una sola clase de etiqueta_de_adiccion? Si es así, explicar por qué eso constituye fuga de información y qué variables se decide excluir de X para la P2 (y por qué).

Notamos que la columna 'nivel_adiccion' o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de 'etiqueta_de_adiccion' es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando.

Esto permitirá no repetir información en el proceso de modelamiento, ya que 'nivel_adiccion' ya revelaría que 'etiqueta_de_adiccion' es 1 o 0.

Instrucciones para esta sección: explicar por qué excluir las variables identificadas en el punto anterior protege la validez de la evaluación del modelo. Indicar además qué método de codificación se planea usar en P2 para cada variable categórica (genero, impacto_academico/laboral, nivel_estres) y por qué (one-hot, binaria, ordinal, etc.), aclarando que cualquier transformación debe ajustarse solo con los datos de entrenamiento. Si se usa scikit-learn para esto, citar la librería (Pedregosa et al. (2011)).

Contrato de nombres para el resto del proyecto (acordado por el equipo, para que el código de todos encaje sin romperse al juntarlo): a partir de aquí se crean y se reutilizan siempre las mismas variables:

```
# TODO: crear df_clean = df sin ID_transaccion, ID_usuario ni nivel_adiccion
↳ (por fuga de información).
# num_cols = lista de las 9 columnas numéricas (edad,
↳ horas_diarias_pantalla, horas_redes_sociales,
#         horas_videojuegos, horas_trabajo/estudio, horas_sueño,
↳ notificaciones_por_dia,
#         aperturas_apps_por_dia, tiempo_en_pantalla_fin_de_semana,)
# cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]
```

5.1.1. Enriquecimiento de datos:

Instrucciones para esta sección: quien complete esta parte debe dejar creadas exactamente las variables df_clean, num_cols y cat_cols con esos nombres. Las secciones de EDA (más abajo) las dan por hechas y no deben volver a definir las.

```
# TODO: crear df_clean = df sin ID_transaccion, ID_usuario ni nivel_adiccion
↳ (por fuga de información).
df_clean = df.drop(columns=["ID_transaccion", "ID_usuario",
↳ "nivel_adiccion"])
num_cols = ["edad", "horas_diarias_pantalla", "horas_redes_sociales",
"horas_videojuegos", "horas_trabajo/estudio", "horas_sueño",
↳ "notificaciones_por_dia",
"aperturas_apps_por_dia", "tiempo_en_pantalla_fin_de_semana"]
cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]
```

	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
0	21	Male	3.23	2.01	0.89	4.55
1	24	Other	5.09	3.81	2.24	4.44
2	31	Other	6.06	1.36	3.83	2.35
3	32	Other	7.83	5.85	1.51	3.54
4	25	Male	9.96	5.92	3.42	5.27

	edad	genero	horas_diarias_pantalla	horas_redes_sociales	horas_videojuegos	horas_trabajo/estudio
0	21	Male	3.23	2.01	0.89	4.55
1	24	Other	5.09	3.81	2.24	4.44
2	31	Other	6.06	1.36	3.83	2.35
3	32	Other	7.83	5.85	1.51	3.54
4	25	Male	9.96	5.92	3.42	5.27
...	...	...	...	...	...	...
7495	26	Other	9.85	1.75	3.13	3.49
7496	35	Male	5.67	2.33	2.76	5.90
7497	22	Female	9.99	3.61	1.09	1.16
7498	23	Male	8.74	1.59	0.07	4.64
7499	27	Female	10.04	5.40	0.73	5.45

5.2. Variable derivada para la comunicación

```
# TODO: agregar a df_clean una columna nueva (por ejemplo, estado_adiccion)
↳ que traduzca etiqueta_de_adiccion a etiquetas legibles ("No adicción" /
↳ "Con adicción") solo para tablas y gráficos.

df_clean["estado_adiccion"] = df_clean["etiqueta_de_adiccion"].
↳ replace({1:"Adicto", 0 : "No adicto"})
df_clean["estado_adiccion"].value_counts()
```

```
estado_adiccion
Adicto      5308
No adicto   2192
Name: count, dtype: int64
```

Instrucciones para esta sección: confirmar que la nueva variable de etiquetas legibles no introduce ninguna información distinta a `etiqueta_de_adiccion` (es solo una versión “para humanos” de la misma columna) y aclarar que para el modelamiento en P2 se seguirá usando la versión numérica original.


6. Análisis exploratorio de datos

6.1. Análisis univariado

```
# TODO: graficar la distribución de etiqueta_de_adiccion (conteo y/o
→ porcentaje por clase), usando df_clean #Aquí no se puede distribución
→ porque etiqueta_de_adiccion es una variable categórica
#sns.barplot(data=df_clean, x= "estado_adiccion", y = )
counts = df_clean["estado_adiccion"].value_counts()

counts.plot(kind="bar", color=['darkred','darkgreen'], edgecolor="none")

plt.xlabel("Estado de adicción")
plt.ylabel(None)
plt.show()
```








Instrucciones para esta sección: reportar cuántos registros hay en cada clase de etiqueta_de_adiccion (conteo y porcentaje) y comentar si existe desbalance de clases. Si lo hay, explicar qué implicancia tiene para la partición entrenamiento/prueba y las métricas que se deberán usar en P2 (por ejemplo, estratificación, F1, recall).




```
# TODO: graficar un histograma por cada variable numérica (usar num_cols).
# usa las columnas que ya tienes cargadas en la sesión

#crear una variable j que pase por una lista que tenga los nombres bien
→ escritos de los histogramas
colores =
→ ['steelblue','darkorange','forestgreen','crimson','gold','lightcoral','yellowgreen',']
```


```
'powderblue','lightgreen','lightgray','plum']
contador = 0
for col in num_cols:
    plt.figure(figsize=(4, 3))
    sns.histplot(
        data=df_clean,
        x=col,
        bins=20,
        kde=False,
        color= colores[contador]
    )
    plt.title(f"Histograma de {col}")
    plt.xlabel(None)
    plt.ylabel(None)
    plt.tight_layout() #es una función de matplotlib que ajusta
    ↪ automáticamente los márgenes
    plt.show()
    contador +=1
```









Histograma de tiempo_en_pantalla_fin_de_semana




Histograma de horas_ocio




Histograma de ratio_finde_diario





```
# TODO: graficar un histograma por cada variable numérica (usar num_cols).
df_clean['estado_adiccion'].value_counts().plot(kind='bar',color=['darkred','darkgreen'])
plt.show() #usamos la variable comunicativa de 'etiqueta_de_adiccion'
```







Instrucciones para esta sección: para cada histograma, describir la forma de la distribución (simétrica, sesgada, con varias modas) y qué implica para el análisis (por ejemplo, si conviene una transformación o estandarización más adelante). Comentar si alguna variable de conteo tiene una escala muy distinta a las variables medidas en horas.




```
# TODO: graficar un boxplot por cada variable numérica (usar num_cols).
# asegúrate de que num_cols existe y tiene nombres reales



colores =
    ↳ ['steelblue', 'darkorange', 'forestgreen', 'lightcoral', 'yellowgreen', 'cadetblue',
        'powderblue', 'lightgreen', 'lightgray']
num_cols = [
    "edad",
    "horas_diarias_pantalla",
    "horas_redes_sociales",
    "horas_videojuegos",
    "horas_trabajo/estudio",
    "horas_sueño",
    "notificaciones_por_dia",
    "aperturas_apps_por_dia",
    "tiempo_en_pantalla_fin_de_semana",
] #aquí descartamos "etiqueta_de_adiccion"

contador = 0
for col in num_cols:
    plt.figure(figsize=(4, 3))
    sns.boxplot(
        data=df_clean,
        y=col,
        color=colores[contador],
    )
    contador += 1
    plt.xlabel("")
    plt.ylabel(col)
    plt.tight_layout()
    plt.show()
```









Instrucciones para esta sección: comentar, variable por variable, la dispersión, la posible presencia de outliers y la simetría observada en los boxplots. Discutir si esos valores extremos deberían tratarse como errores de captura o si son observaciones reales del comportamiento de los usuarios, y justificar la decisión tomada.

```
# TODO: calcular media, mediana, moda, desviación estándar, varianza, rango
→ y cuartiles por variable numérica (num_cols).
for i in num_cols:
    display(df_clean[i].describe())
```

```
count    7500.000000
mean      26.568800
std        5.197108
min       18.000000
25%       22.000000
50%       27.000000
75%       31.000000
```

max 35.000000

Name: edad, dtype: float64

count 7500.000000

mean 7.499912

std 2.609188

min 3.000000

25% 5.220000

50% 7.525000

75% 9.810000

max 12.000000

Name: horas_diarias_pantalla, dtype: float64

count 7500.000000

mean 3.273484

std 1.585342

min 0.500000

25% 1.910000

50% 3.270000

75% 4.630000

max 6.000000

Name: horas_redes_sociales, dtype: float64

count 7500.000000

mean 2.014183

std 1.146039

min 0.000000

25% 1.020000

50% 2.040000

75% 2.990000

max 4.000000

Name: horas_videojuegos, dtype: float64

count 7500.000000

mean 3.242420

std 1.600765

min 0.500000

25% 1.850000

50% 3.230000

75% 4.640000

max 6.000000

Name: horas_trabajo/estudio, dtype: float64

count 7500.000000

mean 6.737561

```
std          1.283605
min          4.500000
25%          5.630000
50%          6.720000
75%          7.840000
max          9.000000
```

Name: horas_sueño, dtype: float64

```
count      7500.000000
mean       134.257333
std        66.586883
min        20.000000
25%        76.000000
50%       134.000000
75%       191.000000
max       250.000000
```

Name: notificaciones_por_dia, dtype: float64

```
count      7500.000000
mean        97.832400
std         48.423349
min         15.000000
25%         55.000000
50%         98.000000
75%        140.000000
max        180.000000
```

Name: aperturas_apps_por_dia, dtype: float64

```
count      7500.000000
mean         9.243827
std          2.718281
min          3.580000
25%          6.960000
50%          9.260000
75%         11.540000
max         14.880000
```

Name: tiempo_en_pantalla_fin_de_semana, dtype: float64

Instrucciones para esta sección: comparar media y mediana para detectar asimetría en cada variable, e interpretar la desviación estándar en el contexto de la escala de cada una (no comparar directamente variables con unidades distintas). Señalar qué variables muestran mayor dispersión o valores extremos.

```
# TODO: graficar la frecuencia de las variables categóricas (cat_cols:
→ genero, nivel_estres, impacto_academico/laboral). #están debajo
for i in cat_cols:
```

```
df_clean[i].value_counts(normalize=True)
```

genero

Male 0.340400

Other 0.331467

Female 0.328133

Name: proportion, dtype: float64

nivel_estres

High 0.341333

Low 0.333733

Medium 0.324933

Name: proportion, dtype: float64

impacto_academico/laboral

No 0.5004

Yes 0.4996

Name: proportion, dtype: float64

estado_adiccion

Adicto 0.707733

No adicto 0.292267

Name: proportion, dtype: float64


Instrucciones para esta sección: describir qué categorías son dominantes o poco frecuentes en cada variable categórica y comentar si eso podría afectar el análisis posterior (por ejemplo, categorías con muy pocos casos). Indicar si alguna de estas variables se tratará como ordinal y por qué.

6.2. Análisis multivariado

```
# TODO: graficar un mapa de calor de correlaciones entre las variables
→ numéricas (num_cols).
df_num = df_clean[num_cols+ ["etiqueta_de_adiccion"]].copy()
# 1. Primero va el tamaño y la resolución (el lienzo)
plt.figure(figsize=(30, 10), dpi=300)

# 2. Luego armamos el mapa de calor con tus mismos parámetros
sns.heatmap(
    df_num.corr(),
    annot=True,
    fmt=".1f",
    vmax=1,
    center=0,
    linewidths=0.5, # Líneas divisorias sutiles
    cbar_kws={"shrink": 1}, # Barra de color un poco más chica
    annot_kws={"size": 23}, # Números chiquitos para que no se amontonen
)
```

```
plt.xticks(fontsize=29) # etiquetas del eje X más grandes
plt.yticks(fontsize=29) # etiquetas del eje Y más grandes
# 3. Ponemos el título y mostramos
plt.title("Matriz de Correlación de Variables Numéricas")
plt.show()
```







Instrucciones para esta sección: identificar en el mapa de calor los pares de variables con correlación fuerte (positiva o negativa) y comentar si sugieren colinealidad. Aclarar que la correlación no implica causalidad.



```
# TODO: calcular y ordenar las correlaciones de cada variable numérica
→ (num_cols) con etiqueta_de_adiccion.
#Chamba Jossep
```

Instrucciones para esta sección: comentar qué variables tienen mayor asociación lineal con la etiqueta objetivo y cuáles tienen asociación muy baja. Aclarar que esto es solo un indicio y no una selección final de variables para el modelo.

```
# TODO: graficar boxplots comparativos de variables numéricas clave (por
→ ejemplo, horas_diarias_pantalla, horas_redes_sociales, horas_sueño)
→ separadas por etiqueta_de_adiccion.
del plt
import matplotlib.pyplot as plt
sns.boxplot(data=df_clean, x="estado_adiccion", y="horas_ocio", palette =
→ "husl", legend=True)
```








```
['edad',  
 'horas_diarias_pantalla',  
 'horas_redes_sociales',  
 'horas_videojuegos',  
 'horas_trabajo/estudio',  
 'horas_sueño',
```


```
'notificaciones_por_dia',
'aperturas_apps_por_dia',
'tiempo_en_pantalla_fin_de_semana']
```

```
['genero', 'nivel_estres', 'impacto_academico/laboral', 'estado_adiccion']
```



Instrucciones para esta sección: comentar cómo cambian la tendencia central y la dispersión de cada variable entre las dos clases, y si hay solapamiento amplio entre grupos (lo que anticiparía dificultad para separar las clases con un solo predictor).

```
plt.figure(figsize=(8,5))
sns.countplot(data=df_clean, x="nivel_estres", hue="estado_adiccion",
              order=["Low","Medium","High"], palette="colorblind")
plt.title("Nivel de estrés, agrupado por estado de adicción")
plt.xlabel("Nivel de estrés")
plt.ylabel("Conteo")
plt.tight_layout()
plt.show()
```



TODO: graficar histogramas o barras agrupadas comparando subgrupos (por ejemplo, nivel_estres o impacto_academico/laboral vs. etiqueta_de_adiccion).

Instrucciones para esta sección: interpretar las proporciones (no solo los conteos) entre subgrupos, evitando conclusiones que estigmaticen a los usuarios. Comentar si estas variables parecen ser causa, consecuencia o simplemente indicadores asociados al uso problemático.

TODO: graficar al menos 5 diagramas de dispersión (scatterplots) entre pares de variables numéricas (num_cols), coloreando por etiqueta_de_adiccion.

TODO: graficar al menos 5 diagramas de dispersión (scatterplots) entre pares de variables numéricas (num_cols), coloreando por etiqueta_de_adiccion.

Instrucciones para esta sección: para cada par de variables, comentar si se observa un patrón (lineal o no lineal), agrupamientos, o separación visible entre clases. Si los colores se solapan mucho, señalar que esas dos variables por sí solas no bastan para separar las clases.

TODO: calcular la covarianza entre pares de variables numéricas relevantes (num_cols).

Instrucciones para esta sección: interpretar el signo de la covarianza (si dos variables crecen o decrecen juntas) y explicar por qué se complementa con la correlación (que sí permite comparar la fuerza de la relación entre variables con escalas distintas).

7. Conclusiones de P1

Instrucciones para esta sección: redactar entre 4 y 6 conclusiones numeradas, basadas únicamente en los resultados obtenidos arriba (no inventar cifras). Deben cubrir, como mínimo: (1) calidad de datos (nulos, duplicados) y qué se hizo al respecto, (2) si la clase objetivo está balanceada o no y qué implica para P2, (3) qué variables se excluyen como predictoras y por qué, (4) qué variables lucen más prometedoras para el modelamiento, y (5) qué se debe tener en cuenta al pasar a la P2 (codificación, escalamiento, evaluación).

8. Limitaciones y consideraciones éticas

El archivo no incluye documentación sobre el muestreo, instrumento de medición, país, periodo de recolección ni procedimiento de etiquetado. En consecuencia, la muestra no debe asumirse representativa de la población universitaria peruana ni de un grupo demográfico específico. Además, el término “adicción” debe tratarse como una etiqueta del dataset y no como un diagnóstico clínico. La evidencia académica recomienda emplear instrumentos validados y distinguir entre uso frecuente y uso problemático Kwon et al. (2013); Csibi et al. (2018).

Si este análisis se trasladara a un contexto real, la privacidad, el consentimiento informado y el riesgo de estigmatización serían centrales. Una predicción debe apoyar la prevención o la derivación voluntaria, nunca justificar sanciones automáticas o decisiones de alto impacto.

Referencias

- Amez, S y S Baert (2020). Smartphone Use and Academic Performance: A Literature Review. *International Journal of Educational Research* **103**, 101618.
- Csibi, S, MD Griffiths, B Cook, Z Demetrovics y A Szabo (2018). The Psychometric Properties of the Smartphone Application-Based Addiction Scale (SABAS). *International Journal of Mental Health and Addiction* **16**(2), 393-403.
- Kwon, M, JY Lee, WY Won, JW Park, JA Min, C Hahn, X Gu, JH Choi y DJ Kim (2013). Development and Validation of a Smartphone Addiction Scale (SAS). *PLOS ONE* **8**(2), e56936.
- Nusrat, Z (s.f.). *Smartphone Usage and Addiction Analysis Dataset*. Kaggle. Fecha de publicación no indicada en la página; consultado el 17 de septiembre de 2026. <https://www.kaggle.com/datasets/zahranusratt/smartphone-usage-and-addiction-analysis-dataset>.
- Pedregosa, F, G Varoquaux, A Gramfort, V Michel, B Thirion, O Grisel, M Blondel, P Prettenhofer, R Weiss, V Dubourg, J Vanderplas, A Passos, D Cournapeau, M Brucher, M Perrot y É Duchesnay (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* **12**, 2825-2830.