

P1 - Uso de Smartphones y Riesgo de Adiccion

Hiter Frank Rubio Peralta

Alumno

Jossep Jorge Froilan Choroco Neyra

Alumno

Joel David De la Cruz Cardenas

Alumno

Rodrigo Octavio Lucatoni Flores Ruiz

Alumno

Victor Andres Diaz Garcia

Alumno

Curso:

Introduccion a Ciencia de Datos e Inteligencia Artificial

23 de Septiembre del 2026

Tabla de contenidos

1. Resumen	4
2. Planteamiento del problema	4
3. Contexto del dataset	4
3.1. Fuente y unidad de análisis	4
3.2. Diccionario de variables	4
4. Carga y exploración inicial	5
4.1. Librerías	5
4.2. Carga de datos	5
4.3. Dimensiones y estructura	6
4.4. Tipos de variables y primeras estadísticas	8
4.5. Calidad de datos	8
5. Preprocesamiento y decisiones de data wrangling	9
5.1. Revisión de fuga de información	10
6. Análisis exploratorio de datos	12
6.1. Análisis univariado	12
6.2. Análisis multivariado	21
7. Conclusiones de P1	32
8. Limitaciones y consideraciones éticas	33

Listado de Tablas

1. Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.	6
2. Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.	7
3. Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.	8
4. Primeras estadísticas de las variables numéricas (archivo original).	9
5. Primeras filas con valores nulos en nivel de adicción.	9
6. Tabla cruzada entre nivel_adiccion y etiqueta_de_adiccion.	10
7. Primeras cinco filas del dataset limpio (df_clean).	11
8. Primeras cinco filas del dataset con variables derivadas (horas_ocio y ratio_finde_diario).	12
9. Estadísticos descriptivos de las variables numéricas.	19
10. Proporción de registros por género.	20
11. Proporción de registros por nivel de estrés.	20
12. Proporción de registros por impacto académico o laboral.	20
13. Proporción de registros por estado de adicción.	20

14. Matriz de correlación entre las variables numéricas.	32
--	----

Listado de Figuras

1. Distribución de la variable objetivo: estado de adicción (0 = No adicción, 1 = Con adicción).	13
2. Histogramas de las variables numéricas del dataset.	14
3. Boxplots de las variables numéricas del dataset.	17
4. Matriz de correlación de las variables numéricas.	22
5. Horas de ocio según el estado de adicción.	23
6. Horas de ocio según el género.	24
7. Horas de ocio según el impacto académico o laboral.	24
8. Razón entre pantalla de fin de semana y pantalla diaria según el estado de adicción.	25
9. Horas de sueño según el estado de adicción.	25
10. Horas diarias de pantalla según el nivel de estrés.	26
11. Horas de ocio según el nivel de estrés.	26
12. Nivel de estrés según el estado de adicción.	27
13.	28
14. Relación entre horas de trabajo o estudio y horas diarias de pantalla, según la etiqueta de adicción.	29
15. Relación entre horas de sueño y horas en redes sociales, según la etiqueta de adicción.	30
16. Relación entre notificaciones por día y horas de sueño, según la etiqueta de adicción.	30
17. Relación entre horas de videojuegos y horas de trabajo o estudio, según la etiqueta de adicción.	31
18. Relación entre edad y horas diarias de pantalla, según la etiqueta de adicción.	31

1. Resumen

*Instrucciones para esta sección: este resumen se escribe **al final**, cuando ya se tengan los resultados de la exploración de datos y las conclusiones de P1. Debe tener entre 150 y 200 palabras e incluir, en este orden: (1) qué dataset se usó y cuántos registros/columnas tiene, (2) el objetivo del análisis (qué se busca entender sobre `etiqueta_de_adiccion`), (3) las dos o tres decisiones de limpieza más importantes que se tomaron y por qué, (4) los dos o tres hallazgos más relevantes del EDA, citando cifras reales obtenidas del código (no inventadas ni copiadas de un borrador), y (5) una frase que conecte con lo que se hará en la P2. No copiar texto de otras secciones; debe ser una síntesis propia, escrita por el equipo.*

2. Planteamiento del problema

El uso intensivo de celulares puede influir en la salud integral de las personas al relacionarse con irregularidades en el sueño, estrés, dificultades en el ámbito académico y laboral. Además, la investigación requiere de una conceptualización alta: una alta frecuencia de uso no significa necesariamente a una condición clínica. Artículos como SABAS permiten estudiar síntomas de uso problemático, pero no sustituyen una evaluación profesional Csibi et al. (2018). La literatura también ayuda con asociaciones entre el uso del smartphone y el desempeño académico, aunque con limitaciones claras para atribuir causalidad Amez y Baert (2020).

Para este proyecto, se formula la siguiente pregunta de análisis:

¿Qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos `smartphone-use-prediction`?

3. Contexto del dataset

3.1. Fuente y unidad de análisis

El archivo `Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv` fue proporcionado para el proyecto y corresponde al dataset publicado como *Smartphone Usage and Addiction Analysis* en Kaggle Nusrat (s.f.). Cada fila representa a un usuario y contiene indicadores demográficos, de comportamiento digital, descanso, estrés e impacto percibido en actividades académicas o laborales.

La unidad de análisis es el usuario. El dataset incluye 7,500 registros y 16 columnas originales: dos identificadores, nueve variables numéricas, cuatro variables categóricas y la etiqueta binaria objetivo.

3.2. Diccionario de variables

- **Identificadores:** `ID_transaccion` y `ID_usuario` son variables de texto. Se usan para verificar unicidad, pero no aportan significado analítico y se excluirán como predictores.
- **Demografía:** `edad` (numérica) y `genero` (categórica) caracterizan la muestra.
- **Uso del smartphone:** `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo_estudio`, `notificaciones_por_dia`, `aperturas_apps_por_dia` y `tiempo_pantalla_finde` son variables numéricas que miden intensidad y tipo de uso.

- **Bienestar y contexto:** horas_sueño es numérica; nivel_estres y impacto_academico/laboral son categóricas. Se emplean para explorar descanso e impacto funcional.
- **Severidad:** nivel_adiccion es categórica ordinal. Se describe en P1, pero se excluye como predictor en P2 por fuga de información.
- **Objetivo:** etiqueta_de_adiccion es binaria: 0 significa *No adicción* y 1 significa *Con adicción*.

La variable nivel_adiccion contiene una categorización de severidad (None, Mild, Moderate, Severe). Por su definición operativa, puede estar construida directamente a partir de la etiqueta final; por ello se audita explícitamente antes de considerar su uso en P2.

4. Carga y exploración inicial

4.1. Librerías

El primer bloque reúne las librerías necesarias para el proyecto y el estilo de seaborn

```
# =====  
# CONFIGURACIÓN ÚNICA DEL REPORTE  
# Librerías y estilos se ejecutan una sola vez  
# =====  
import pandas as pd  
import numpy as np  
from matplotlib.pyplot import boxplot  
from matplotlib.pyplot import hist  
import matplotlib.pyplot as plt  
import seaborn as sns  
from IPython.display import display, Latex  
import kagglehub  
from scipy import stats  
import math  
  
sns.set_theme(style="whitegrid")
```

El segundo bloque, que no se imprime en el PDF para no alargarlo, define funciones de presentación: la función tabla(), que reproduce desde Python el estilo de tabla (kable con booktabs), en el PDF se omite el código que solo dibuja los gráficos, igual que en la plantilla del curso; todo ese código está completo y comentado en Project-Report.qmd. Sí se muestra todo el código que carga, transforma o calcula.

4.2. Carga de datos

Usando la librería de kaggle y os logramos una carga universal exitosa en cualquier equipo y evitamos errores de carga del dataset

```
# Cargamos el archivo csv  
path = (kagglehub.dataset_download  
        ("jayjoshi37/smartphone-usage-and-addiction-prediction"))
```

```
import os
# Ruta directa al archivo CSV combinando la ruta de descarga y el nombre del
# archivo
ruta_csv = (os.path.join(path,
                          "Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv"))
df = pd.read_csv(ruta_csv)
n_filas, n_columnas = df.shape
print(f"Dimensiones: {n_filas:,} filas x {n_columnas} columnas")
```

Dimensiones: 7,500 filas x 16 columnas

El archivo se carga completo, con 7500 filas y 16 columnas. `df` no se modifica en ningún momento: todas las transformaciones posteriores se aplican sobre copias, de modo que cada decisión puede contrastarse contra el archivo original.

4.3. Dimensiones y estructura

```
primeras = df.head(5).fillna("NaN").T.astype(str)
primeras.columns = [f"Usuario {i}" for i in range(1, 6)]
primeras.index.name = "Columna"
tabla(primeras, tamaño="footnotesize")
```

Tabla 1: *Primeras cinco filas del archivo original, transpuestas: cada fila de la tabla es una columna del CSV.*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
transaction_id	TXN00001	TXN00002	TXN00003	TXN00004	TXN00005
user_id	U00001	U00002	U00003	U00004	U00005
age	21	24	31	32	25
gender	Male	Other	Other	Other	Male
daily_screen_time_hours	3.23	5.09	6.06	7.83	9.96
social_media_hours	2.01	3.81	1.36	5.85	5.92
gaming_hours	0.89	2.24	3.83	1.51	3.42
work_study_hours	4.55	4.44	2.35	3.54	5.27
sleep_hours	7.55	7.66	4.92	8.23	6.21
notifications_per_day	248	127	44	178	136
app_opens_per_day	154	71	106	107	177
weekend_screen_time	3.95	6.71	8.68	9.77	12.55
stress_level	Medium	Medium	High	High	Low
academic_work_impact	Yes	Yes	No	Yes	No
addiction_level	NaN	NaN	Mild	Moderate	Severe
addicted_label	0	0	0	1	1

La Tabla 1 se presenta transpuesta porque las 16 columnas no caben a lo ancho de la página. Ya en estas cinco filas aparece una señal de alerta: los usuarios 1 y 2 muestran NaN (valor nulo) en `addiction_level`, un valor que se investiga en la sección (Sección 5.1).

Tabla 2: Estructura del archivo: tipo de dato asignado por pandas, valores no nulos, nulos y valores distintos por columna.

Columna	Tipo (pandas)	No nulos	Nulos	Valores distintos
transaction_id	str	7,500	0	7,500
user_id	str	7,500	0	7,500
age	int64	7,500	0	18
gender	str	7,500	0	3
daily_screen_time_hours	float64	7,500	0	900
social_media_hours	float64	7,500	0	551
gaming_hours	float64	7,500	0	401
work_study_hours	float64	7,500	0	551
sleep_hours	float64	7,500	0	451
notifications_per_day	int64	7,500	0	231
app_opens_per_day	int64	7,500	0	166
weekend_screen_time	float64	7,500	0	1,096
stress_level	str	7,500	0	3
academic_work_impact	str	7,500	0	2
addiction_level	str	6,681	819	3
addicted_label	int64	7,500	0	2

Interpretación. La Tabla 2 permite verificar que el tipo asignado por pandas sea coherente con lo que representa cada variable:

- Las nueve variables de uso, edad y sueño se cargaron como números (int64 o float64) y no como texto, que es el error silencioso más frecuente al leer un CSV.
- addicted_label se cargó como entero, pero es una variable **categorica binaria**: el tipo de dato no coincide con su naturaleza estadística, y así se tratará en el análisis.
- Las columnas de texto (tipo object en pandas 2 o str en pandas 3) son de dos clases muy distintas: transaction_id y user_id tienen 7500 valores distintos, uno por fila, lo que las identifica como **identificadores**; en cambio, gender, stress_level, academic_work_impact y addiction_level tienen entre 2 y 4 valores, es decir, son **categoricas**.
- Solo addiction_level presenta nulos np.int64(819), y muestra 3 valores distintos, cuando una escala de severidad suele tener cuatro niveles.

4.4. Tipos de variables y primeras estadísticas

Tabla 3: Diccionario de variables: nombre original, nombre usado en el reporte, tipo estadístico y descripción.

Columna original	Nombre en el reporte	Tipo estadístico	Descripción
transaction_id	ID_transaccion	Identificador	Código del registro (TXN00001...)
user_id	ID_usuario	Identificador	Código del usuario (U00001...)
age	edad	Cuantitativa discreta	Edad en años cumplidos
gender	genero	Cualitativa nominal	Masculino, Femenino u Otro
daily_screen_time_hours	horas_diarias_pantalla	Cuantitativa continua	Horas de pantalla en un día típico
social_media_hours	horas_redes_sociales	Cuantitativa continua	Horas diarias en redes sociales
gaming_hours	horas_videojuegos	Cuantitativa continua	Horas diarias en videojuegos
work_study_hours	horas_trabajo/estudio	Cuantitativa continua	Horas diarias de trabajo o estudio
sleep_hours	horas_sueño	Cuantitativa continua	Horas de sueño por noche
notifications_per_day	notificaciones_por_dia	Cuantitativa discreta	Notificaciones recibidas al día
app_opens_per_day	aperturas_apps_por_dia	Cuantitativa discreta	Veces que abre aplicaciones al día
weekend_screen_time	tiempo_pantalla_finde	Cuantitativa continua	Horas de pantalla en un día de fin de semana
stress_level	nivel_estres	Cualitativa ordinal	Bajo < Medio < Alto
academic_work_impact	impacto_academico/laboral	Cualitativa nominal (binaria)	Si el uso afecta sus estudios o trabajo (Sí/No)
addiction_level	nivel_adiccion	Cualitativa ordinal	Ninguna < Leve < Moderada < Severa
addicted_label	etiqueta_de_adiccion	Cualitativa binaria (objetivo)	1 = adicto, 0 = no adicto

La Tabla 3 resume la naturaleza de cada variable. La distinción entre tipos estadísticos no es un detalle formal: decide qué gráficos y estadísticos corresponden a cada variable (histogramas y boxplots para las cuantitativas, gráficos de barras para las cualitativas) y, en la P2, cómo se codificará cada una.

4.5. Calidad de datos

```
nulos_por_columna = df.isnull().sum()
filas_duplicadas = df.duplicated().sum()
print("Valores nulos por columna:")
print(nulos_por_columna[nulos_por_columna > 0])
print(f"\nFilas duplicadas: {filas_duplicadas}")
```

Valores nulos por columna:

addiction_level 819

dtype: int64

Filas duplicadas: 0

Se encontraron **819 valores nulos** en la columna nivel_adicción, esto es aproximadamente un 10.92% de los registros del dataset. Por otro lado, no hay filas duplicadas, probablemente esto sea porque los usuarios con nivel_adiccion = None simplemente no completaron esa escala de severidad. A partir de este problema, decidimos **excluir** a la variable nivel_adicción ya que esta representa una fuga de información y no aporta información nueva.

Tabla 4: Primeras estadísticas de las variables numéricas (archivo original).

Variable	n	Media	Desv. est.	Mín.	Q1	Mediana	Q3	Máy.
edad	7,500	26.57	5.20	18.00	22.00	27.00	31.00	35.00
horas_diarias_pantalla	7,500	7.50	2.61	3.00	5.22	7.53	9.81	12.00
horas_redes_sociales	7,500	3.27	1.59	0.50	1.91	3.27	4.63	6.00
horas_videojuegos	7,500	2.01	1.15	0.00	1.02	2.04	2.99	4.00
horas_trabajo/estudio	7,500	3.24	1.60	0.50	1.85	3.23	4.64	6.00
horas_sueño	7,500	6.74	1.28	4.50	5.63	6.72	7.84	9.00
notificaciones_por_dia	7,500	134.26	66.59	20.00	76.00	134.00	191.00	250.00
aperturas_apps_por_dia	7,500	97.83	48.42	15.00	55.00	98.00	140.00	180.00
tiempo_pantalla_finde	7,500	9.24	2.72	3.58	6.96	9.26	11.54	14.88
etiqueta_de_adiccion	7,500	0.71	0.45	0.00	0.00	1.00	1.00	1.00

Los rangos que se observan en la anterior tabla `df.describe()` son coherentes con lo que representan las variables. La edad está entre 18 y 35 años, con una media de 26.57, las horas de pantalla diaria van de 3 a 12 horas con una media de 7.50, las horas de sueño de 4.5 a 9 con una media de 6.74 y las horas de trabajo/estudio de 0.5 a 6 con media de 3.24. Por otro lado, los valores de notificaciones por día y aperturas de apps por día muestran una alta dispersión, eso es esperable ya que cada usuario tiene distintos patrones de uso que generar cantidades completamente diferentes de notificaciones y aperturas. Además, `ID_transaccion` y `ID_usuario` se conservan únicamente como referencia para verificar autenticidad, pero no forman parte del análisis.

5. Preprocesamiento y decisiones de data wrangling

Notamos que hay 819 valores nulos en la columna “nivel_adiccion”, por lo que procederemos a analizar las filas que contengan valores nulos en esta columna

```
columnas_mostrar = [
    "ID_transaccion", "edad", "genero",
    "horas_diarias_pantalla", "horas_sueño",
    "nivel_estres", "etiqueta_de_adiccion"
]

df_adiccionnull = df_renombrado[df_renombrado["nivel_adiccion"].isnull()]
df_adiccionnull_head = df_adiccionnull.head()

tabla(df_adiccionnull_head[columnas_mostrar], indice=False,
      ↪ tamaño="scriptsize", interlineado=1.1)
```

Tabla 5: Primeras filas con valores nulos en nivel de adicción.

ID_transaccion	edad	genero	horas_diarias_pantalla	horas_sueño	nivel_estres	etiqueta_de_adiccion
TXN00001	21	Male	3.23	7.55	Medium	0
TXN00002	24	Other	5.09	7.66	Medium	0
TXN00009	21	Other	4.38	6.23	High	0
TXN00012	27	Other	5.16	7.79	High	0
TXN00014	32	Male	4.09	5.54	High	0

5.1. Revisión de fuga de información

```
crosstab = pd.crosstab(df_renombrado["nivel_adiccion"],  
    ↪ df_renombrado["etiqueta_de_adiccion"])  
tabla(crosstab)
```

Tabla 6: *Tabla cruzada entre nivel_adiccion y etiqueta_de_adiccion.*

nivel_adiccion	0	1
Mild	1,373	0
Moderate	0	2,874
Severe	0	2,434

En la tabla cruzada Notamos que la columna `nivel_adiccion` o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de `etiqueta_de_adiccion` es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando.

Notamos que la columna `nivel_adiccion` o cae en 0 cuando es baja o cae en 1 cuando es media o alta, no hay ninguna excepción para alguien de adicción media p alta, la información de `etiqueta_de_adiccion` es la necesaria y objetivo para este análisis puesto que queremos encontrar qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos que estamos abordando. Esto permitirá no repetir información en el proceso de modelamiento, ya que `nivel_adiccion` ya revelaría que `etiqueta_de_adiccion` es 1 o 0. Por lo tanto, con esto confirmamos que incluir `nivel_adiccion` en el predictor del modelo P2 sería igual a una **fuga de información**, entonces lo excluirémos de las variables predictoras. Además, se descartan `ID_transaccion` e `ID_usuario` al ser solo identificadores sin un valor predictivo.

Contrato de nombres para el resto del proyecto (acordado por el equipo, para que el código de todos encaje sin romperse al juntarlo): a partir de aquí se crean y se reutilizan siempre las mismas variables:

```
df_clean = df_renombrado.drop(columns=["ID_transaccion", "ID_usuario",  
    ↪ "nivel_adiccion"])  
num_cols = ["edad", "horas_diarias_pantalla", "horas_redes_sociales",  
    "horas_videojuegos", "horas_trabajo/estudio", "horas_sueño",  
    ↪ "notificaciones_por_dia",  
    "aperturas_apps_por_dia", "tiempo_pantalla_finde"]  
cat_cols = ["genero", "nivel_estres", "impacto_academico/laboral"]  
vista_df_clean = df_clean.head().T  
vista_df_clean.columns = [f"Usuario {i}" for i in range(1, 6)]  
vista_df_clean.index.name = "Columna"  
  
tabla(vista_df_clean, tamano="footnotesize")
```

Tabla 7: *Primeras cinco filas del dataset limpio (df_clean).*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
edad	21	24	31	32	25
genero	Male	Other	Other	Other	Male
horas_diarias_pantalla	3.23	5.09	6.06	7.83	9.96
horas_redes_sociales	2.01	3.81	1.36	5.85	5.92
horas_videojuegos	0.89	2.24	3.83	1.51	3.42
horas_trabajo/estudio	4.55	4.44	2.35	3.54	5.27
horas_sueño	7.55	7.66	4.92	8.23	6.21
notificaciones_por_dia	248	127	44	178	136
aperturas_apps_por_dia	154	71	106	107	177
tiempo_pantalla_finde	3.95	6.71	8.68	9.77	12.55
nivel_estres	Medium	Medium	High	High	Low
impacto_academico/laboral	Yes	Yes	No	Yes	No
etiqueta_de_adiccion	0	0	0	1	1

5.1.1. Enriquecimiento de datos:

Se crean dos variables derivadas para el análisis exploratorio:

```
df_clean["horas_ocio"] = df_renombrado["horas_redes_sociales"] +  
    ↪ df_renombrado["horas_videojuegos"]  
df_clean["ratio_finde_diario"] = (  
    df_renombrado["tiempo_pantalla_finde"]  
    / df_renombrado["horas_diarias_pantalla"]  
)  
df_clean["estado_adiccion"] =  
    ↪ df_renombrado["etiqueta_de_adiccion"].replace({1:"Adicto", 0:"No  
    ↪ adicto"})  
vista2_df_clean = df_clean.head().T  
vista2_df_clean.columns = [f"Usuario {i}" for i in range(1, 6)]  
vista2_df_clean.index.name = "Columna"  
  
tabla(vista2_df_clean, tamano="footnotesize")
```

Tabla 8: *Primeras cinco filas del dataset con variables derivadas (horas_ocio y ratio_finde_diario).*

Columna	Usuario 1	Usuario 2	Usuario 3	Usuario 4	Usuario 5
edad	21	24	31	32	25
genero	Male	Other	Other	Other	Male
horas_diarias_pantalla	3.23	5.09	6.06	7.83	9.96
horas_redes_sociales	2.01	3.81	1.36	5.85	5.92
horas_videojuegos	0.89	2.24	3.83	1.51	3.42
horas_trabajo/estudio	4.55	4.44	2.35	3.54	5.27
horas_sueño	7.55	7.66	4.92	8.23	6.21
notificaciones_por_dia	248	127	44	178	136
aperturas_apps_por_dia	154	71	106	107	177
tiempo_pantalla_finde	3.95	6.71	8.68	9.77	12.55
nivel_estres	Medium	Medium	High	High	Low
impacto_academico/laboral	Yes	Yes	No	Yes	No
etiqueta_de_adiccion	0	0	0	1	1
horas_ocio	2.90	6.05	5.19	7.36	9.34
ratio_finde_diario	1.22	1.32	1.43	1.25	1.26
estado_adiccion	No adicto	No adicto	No adicto	Adicto	Adicto

Con esto se confirma que estado_adiccion es solo una traducción de etiqueta_de_adiccion a etiquetas legibles: 5308 registros se etiquetaron como “Adicto” (equivalente a 1) y 2192 como “No adicto” (equivalente a 0). No se está introduciendo nada nuevo. Las variables num_cols y cat_cols actualizadas son: - num_cols: edad, horas_diarias_pantalla, horas_redes_sociales, horas_videojuegos, horas_trabajo/estudio, horas_sueño, notificaciones_por_dia, aperturas_apps_por_dia, tiempo_en_pantalla_fin_de_semana, horas_ocio, ratio_finde_diario, etiqueta_de_adiccion - cat_cols: genero, nivel_estres, impacto_academico/laboral, estado_adiccion

6. Análisis exploratorio de datos

6.1. Análisis univariado

```
counts = df_clean["estado_adiccion"].value_counts()
counts.plot(kind="bar", color=['darkred', 'darkgreen'], edgecolor="none")
plt.xlabel("Estado de adicción")
plt.ylabel(None)
plt.xticks(rotation=0)
plt.show()
```




Figura 1: Distribución de la variable objetivo: estado de adicción (0 = No adicción, 1 = Con adicción).

De los 7,500 registros, **5308 (70.77%)** corresponden a la clase “Con adicción” y **2192 (29.23%)** a “No adicción”. Hay un desbalance, la clase positiva tiene más del doble de registros que la negativa.

```
colores = [
    "steelblue", "darkorange", "forestgreen",
    "crimson", "gold", "lightcoral",
    "yellowgreen", "cadetblue", "powderblue",
    "lightgreen", "lightgray", "plum"
]

n_columnas = 3
n_filas = math.ceil(len(num_cols) / n_columnas)

fig, axes = plt.subplots(
    n_filas,
    n_columnas,
    figsize=(10.5, 2.25 * n_filas),
    constrained_layout=True
)

axes = axes.flatten()

for i, col in enumerate(num_cols):
    sns.histplot(
        data=df_clean,
```

```

x=col,
bins=20,
kde=False,
color=colores[i % len(colores)],
ax=axes[i]
)

axes[i].set_title(col.replace("_", " "), fontsize=8)
axes[i].set_xlabel("")
axes[i].set_ylabel("Frecuencia", fontsize=7)
axes[i].tick_params(axis="both", labelsize=6)

# Quitar recuadros que no se usan
for ax in axes[len(num_cols):]:
    ax.remove()

fig.suptitle(
    "Distribución de las variables numéricas",
    fontsize=11
)

plt.show()

```





Figura 2: Histogramas de las variables numéricas del dataset.

Cada histograma muestra cómo se distribuyen los valores de cada variable numérica. En las variables relacionadas con la interacción, como `notificaciones_por_dia` y `aperturas_apps_por_dia`, se observa una dispersión bastante amplia. Aunque la mayoría de los usuarios se concentra en rangos intermedios, también hay algunos con frecuencias mucho más altas. Por otro lado, las variables expresadas en horas, como `horas_diarias_pantalla`, `horas_redes_sociales`, `horas_videojuegos`, `horas_trabajo/estudio` y `horas_sueño`, presentan rangos más reducidos. En particular, `horas_sueño` se concentra alrededor de valores medios, mientras que el tiempo de pantalla y de uso de redes sociales varía más entre los usuarios. La edad también se encuentra dentro de un rango relativamente limitado, correspondiente principalmente a adultos jóvenes.

```
df_clean['estado_adiccion'].value_counts().plot(kind='bar',color=['darkred',  
                                                                'darkgreen'])  
plt.show() #usamos la variable comunicativa de 'etiqueta_de_adiccion'
```



El gráfico de barras muestra una clara asimetría y desbalance de clases, donde la categoría “Adicto” predomina ampliamente (superando las 5,000 observaciones) frente a la de “No adicto” (alrededor de 2,200). Este desequilibrio implica que, para fases posteriores de modelado o análisis estadístico, se debe considerar el balanceo de datos o métricas de evaluación adecuadas para evitar sesgos hacia la clase mayoritaria.*

Los boxplots se apoyan en los cuartiles, que dividen los datos ordenados en cuatro partes iguales (Walpole et al. 2012):

$$Q_k = \text{valor en la posición } \frac{k}{4}(n+1) \quad (1)$$

```
colores = [
    "steelblue", "darkorange", "forestgreen",
    "lightcoral", "yellowgreen", "cadetblue",
    "powderblue", "lightgreen", "lightgray"
]

num_cols = [
    "edad",
    "horas_diarias_pantalla",
    "horas_redes_sociales",
    "horas_videojuegos",
    "horas_trabajo_estudio",
    "horas_sueño",
    "notificaciones_por_dia",
    "aperturas_apps_por_dia",
    "tiempo_pantalla_finde",
]

n_columnas = 3
n_filas = math.ceil(len(num_cols) / n_columnas)

fig, axes = plt.subplots(
    n_filas,
    n_columnas,
    figsize=(10.5, 2.4 * n_filas),
    constrained_layout=True
)

axes = axes.flatten()

for i, col in enumerate(num_cols):
    sns.boxplot(
        data=df_clean,
        y=col,
        color=colores[i % len(colores)],
        ax=axes[i],
        width=0.45,
        fliersize=2
    )

    axes[i].set_title(col.replace("_", " "), fontsize=8)
    axes[i].set_xlabel("")
    axes[i].set_ylabel("")
    axes[i].tick_params(axis="both", labelsize=6)
```

```

for ax in axes[len(num_cols):]:
    ax.remove()

fig.suptitle(
    "Dispersión y valores atípicos de las variables numéricas",
    fontsize=11
)

plt.show()

```




Figura 3: Boxplots de las variables numéricas del dataset.

La visualización de las variables numéricas (edad, tiempo en pantalla, uso de apps, sueño, etc.) muestra en general una distribución bastante homogénea y centrada. Salvo por ligeras asimetrías o atípicos aislados en hábitos de uso intensivo (como notificaciones o videojuegos), las observaciones representan comportamientos reales de los usuarios y no errores de registro, por lo que se decide conservar todas las variables completas para el análisis.*

Se calculan las medidas de tendencia central y dispersión de cada variable numérica (Walpole et al. 2012):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ es impar} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & \text{si } n \text{ es par} \end{cases} \quad (3)$$

$$Mo = L_i + \left(\frac{d_1}{d_1 + d_2} \right) \cdot A_i \quad (4)$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (5)$$

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (6)$$

$$CV = \frac{s}{\bar{x}} \times 100\% \quad (7)$$

```
for i in num_cols:
    display(df_clean[i].describe())
```

Tabla 9: Estadísticos descriptivos de las variables numéricas.

```

count      7500.000000
mean        26.568800
std         5.197108
min         18.000000
25%         22.000000
50%         27.000000
75%         31.000000
max         35.000000
Name: edad, dtype: float64
count      7500.000000
mean         7.499912
std          2.609188
min          3.000000
25%          5.220000
50%          7.525000
75%          9.810000
max          12.000000
Name: horas_diarias_pantalla, dtype: float64
count      7500.000000
mean         3.273484
std          1.585342
min          0.500000
25%          1.910000
50%          3.270000
75%          4.630000
max          6.000000
Name: horas_redes_sociales, dtype: float64
count      7500.000000
mean         2.014183
std          1.146039
min          0.000000
25%          1.020000
50%          2.040000
75%          2.990000
max          4.000000
Name: horas_videojuegos, dtype: float64
count      7500.000000
mean         3.242420
std          1.600765
min          0.500000
25%          1.850000
50%          3.230000
75%          4.640000
max          6.000000
Name: horas_trabajo/estudio, dtype: float64

```

Al evaluar la relación entre la media y la mediana, la mayoría de las variables muestran valores muy cercanos, lo que refleja distribuciones mayoritariamente simétricas. En cuanto a la dispersión, variables de conteo diario (como `notificaciones_por_dia` y `aperturas_apps_por_dia`) registran una desviación estándar mayor en proporción a su escala en comparación con las variables en horas (como `horas_sueño` o `horas_trabajo/estudio`), las cuales presentan mayor estabilidad. Finalmente, las variables asociadas a hábitos intensivos digitales son las que exhiben mayor variabilidad y presencia de valores extremos.

```
for i in cat_cols:
    df_clean[i].value_counts(normalize=True)
```

Tabla 10: *Proporción de registros por género.*

```
genero
Male      0.340400
Other     0.331467
Female    0.328133
Name: proportion, dtype: float64
```

Tabla 11: *Proporción de registros por nivel de estrés.*

```
nivel_estres
High      0.341333
Low       0.333733
Medium    0.324933
Name: proportion, dtype: float64
```

Tabla 12: *Proporción de registros por impacto académico o laboral.*

```
impacto_academico/laboral
No      0.5004
Yes     0.4996
Name: proportion, dtype: float64
```

Tabla 13: *Proporción de registros por estado de adicción.*

```
estado_adiccion
Adicto      0.707733
No adicto   0.292267
Name: proportion, dtype: float64
```

Las variables de género (Male: 34.0 %, Other: 33.1 %, Female: 32.8 %), nivel de estrés (High: 34.1 %, Low: 33.4 %, Medium: 32.5 %) e impacto académico/laboral (No: 50.0 %, Yes: 50.0 %) presentan una distribución completamente equitativa e uniforme, sin presencia de categorías minoritarias que puedan sesgar el análisis. La única excepción es `estado_adiccion`, la cual exhibe un desbalance significativo donde el 70.8 % corresponde a usuarios clasificados como “Adicto” y solo el 29.2 % a “No

adicto”. Por otro lado, la variable nivel_estres se tratará como ordinal debido a que sus categorías (Low, Medium, High) poseen un orden jerárquico natural implícito.

6.2. Análisis multivariado

```
df_num = df_clean[num_cols + ["etiqueta_de_adiccion"]].copy()

nombres_cortos = {
    "edad": "Edad",
    "horas_diarias_pantalla": "Pantalla diaria",
    "horas_redes_sociales": "Redes sociales",
    "horas_videojuegos": "Videojuegos",
    "horas_trabajo/estudio": "Trabajo/estudio",
    "horas_sueño": "Sueño",
    "notificaciones_por_dia": "Notificaciones",
    "aperturas_apps_por_dia": "Aperturas apps",
    "tiempo_pantalla_finde": "Pantalla fin de sem.",
    "etiqueta_de_adiccion": "Adicción"
}

correlacion = df_num.corr()
correlacion = correlacion.rename(
    index=nombres_cortos,
    columns=nombres_cortos
)

fig, ax = plt.subplots(figsize=(10, 8))

sns.heatmap(
    correlacion,
    annot=True,
    fmt=".2f",
    vmin=-1,
    vmax=1,
    center=0,
    cmap="vlag",
    linewidths=0.4,
    cbar_kws={"shrink": 0.8},
    annot_kws={"size": 7},
    ax=ax
)

ax.set_title("Matriz de correlación de variables numéricas", fontsize=11,
    ↪ pad=12)
ax.tick_params(axis="x", labelsz=8, rotation=40)
ax.tick_params(axis="y", labelsz=8, rotation=0)

plt.tight_layout()
```

```
plt.show()
```




Figura 4: Matriz de correlación de las variables numéricas.

En el mapa de calor se observa una relación fuerte entre las horas de pantalla diarias y las horas de pantalla durante el fin de semana, con una correlación cercana a 1. Esto quiere decir que las personas que suelen pasar más tiempo frente a una pantalla durante el día a día también tienden a mantener un uso elevado los fines de semana. Debido a que ambas variables muestran un comportamiento muy parecido, lo que podría generar colinealidad.

Por otro lado, la etiqueta de adicción presenta una correlación aproximada de 0.6 con las horas diarias de pantalla, 0.4 con el tiempo dedicado a redes sociales y 0.6 con las horas de pantalla durante el fin de semana.

Estos resultados muestran que las tres variables tienen cierta relación con la etiqueta de adicción. Pero es importante recordar que una correlación no significa necesariamente que exista una relación de causa y efecto.

Las variables que tienen mayor asociación lineal podemos fijarnos que son cantidad de horas diarias en pantalla, cantidad de horas en redes sociales y tiempo de pantalla en los fines de semanas, siendo

aproximadamente 0.6 , 0.4 , 0.6 aproximadamente. A diferencia del resto que cuenta con valores muy cercanos 0.0. Estos resultados podrían ser útil para futuros modelos

La correlación de Pearson mide la fuerza y dirección de la relación lineal entre dos variables, y se calcula a partir de la covarianza y las desviaciones estándar de cada una (Walpole et al. 2012):

$$r_{xy} = \frac{\text{cov}(x, y)}{s_x s_y} \quad (8)$$

```
del plt
import matplotlib.pyplot as plt
sns.boxplot(data=df_clean, x="estado_adiccion", y="horas_ocio", palette =
→ "husl", legend=True)
```




Figura 5: Horas de ocio según el estado de adicción.




Figura 6: Horas de ocio según el género.




Figura 7: Horas de ocio según el impacto académico o laboral.




Figura 8: Razón entre pantalla de fin de semana y pantalla diaria según el estado de adicción.




Figura 9: Horas de sueño según el estado de adicción.




Figura 10: Horas diarias de pantalla según el nivel de estrés.




Figura 11: Horas de ocio según el nivel de estrés.

En los tres géneros, los usuarios con etiqueta de adicción presentan una mediana de horas de ocio mayor que quienes tienen etiqueta 0.

Las cajas del grupo con etiqueta 1 también son algo más altas, lo que indica mayor dispersión. Pero existe solapamiento entre ambas clases, por lo que las horas de ocio por sí solas no permiten separarlas completamente.

Al comparar los géneros, las medianas y la dispersión son similares dentro de cada clase.

```
plt.figure(figsize=(8,5))
sns.countplot(data=df_clean, x="nivel_estres", hue="estado_adiccion",
              order=["Low","Medium","High"], palette="colorblind")
plt.title("Nivel de estrés, agrupado por estado de adicción")
plt.xlabel("Nivel de estrés")
plt.ylabel("Conteo")
plt.tight_layout()
plt.show()
```






Figura 12: Nivel de estrés según el estado de adicción.


```
for columna in cat_cols:
    sns.histplot(data=df_clean, x = columna, hue = 'etiqueta_de_adiccion')
plt.show()
```



(a) Distribución de las variables categóricas según la etiqueta de adicción.



(b)



La proporción de usuarios con una etiqueta de adicción se mantiene bastante similar entre los distintos géneros, niveles de estrés y categorías de impacto académico o laboral. Esto indica que no existen diferencias importantes entre estos grupos. Sin embargo, con estos resultados no podemos concluir que estas variables sean una causa o una consecuencia directa del uso problemático.

```
sns.scatterplot(data=df_renombrado, x= 'horas_trabajo/estudio', y=
↳ 'horas_diarias_pantalla', hue = 'etiqueta_de_adiccion')
```




Figura 14: Relación entre horas de trabajo o estudio y horas diarias de pantalla, según la etiqueta de adicción.




Figura 15: Relación entre horas de sueño y horas en redes sociales, según la etiqueta de adicción.




Figura 16: Relación entre notificaciones por día y horas de sueño, según la etiqueta de adicción.




Figura 17: Relación entre horas de videojuegos y horas de trabajo o estudio, según la etiqueta de adicción.




Figura 18: Relación entre edad y horas diarias de pantalla, según la etiqueta de adicción.

En la primera comparación podemos observar que a medida que aumentan las horas diarias frente a una pantalla, también parece aumentar la posibilidad de que una persona sea 'adicta'. A partir de las

8 horas, se puede notar que la mayoría de las personas son consideradas adictas. En cambio, en las horas de trabajo y estudio no se observa un patrón claro.

En la segunda comparación, entre las 0 y 4 horas no se logra identificar un patrón a simple vista. Sin embargo, entre las 4 y 6 horas podemos observar que todas las personas son consideradas adictas. Por otro lado, en las horas de sueño tampoco se aprecia un patrón claro relacionado con la adicción.

En la tercera y cuarta comparación no se observa una tendencia clara entre las variables. Lo que sí podemos notar en las gráficas es que las personas consideradas adictas aparecen en una mayor proporción que las que no lo son.

Finalmente, en la última gráfica podemos observar que, en las edades más bajas, hay una mayor cantidad de personas consideradas adictas. Además, nuevamente se puede apreciar que mientras aumentan las horas diarias de uso de pantalla, también parece aumentar la posibilidad de que una persona sea considerada adicta hasta el valor de 8, ya que de 8 en adelante la persona ya se le considera como una persona ‘adicta’

```
variables = [
    "edad",
    "horas_diarias_pantalla",
    "horas_redes_sociales",
    "horas_sueño",
    "etiqueta_de_adiccion"
]

matriz_correlacion = df_clean[variables].corr().round(2)
tabla(matriz_correlacion, decimales=2, tamaño="scriptsize")
```

Tabla 14: Matriz de correlación entre las variables numéricas.

index	edad	horas_diarias_pantalla	horas_redes_sociales	horas_sueño	etiqueta_de_adiccion
edad	1.00	0.01	0.00	-0.01	0.00
horas_diarias_pantalla	0.01	1.00	0.01	0.02	0.58
horas_redes_sociales	0.00	0.01	1.00	0.01	0.41
horas_sueño	-0.01	0.02	0.01	1.00	0.04
etiqueta_de_adiccion	0.00	0.58	0.41	0.04	1.00

La covarianza mide cómo varían juntas dos variables: positiva si crecen juntas, negativa si una crece cuando la otra decrece (Walpole et al. 2012).

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (9)$$

7. Conclusiones de P1

Hemos encontrado 819 valores nulos correspondientes a una única columna: nivel_adiccion, por lo cual hemos optado excluir la columna nivel_adiccion, puesto que revelaba la misma información que la variable objetivo que es etiqueta_de_adiccion.

La cantidad de personas que presentan la condición de “Adicto” de la variable `etiqueta_de_adiccion` es 5308 y la que presentan la condición de “No adicto” es 2192. El 70.77% presenta adicción al smartphone y el 29.22% no presenta esta adicción: por lo tanto la clase objetivo no está balanceada y eso implica una mayor tendencia a la categoría “Adicto” lo cual en un futuro puede llevar a sesgos en el modelo de predicción. Las variables más prometedoras que encontramos fueron: `horas_diarias_pantalla`, `horas_redes_sociales`, `ratio_ratio_finde_diario` y `nivel_estres` reúnen información muy relacionada con `etiqueta_de_adiccion`. `horas_diarias_pantalla`: Las personas que usan más tiempo su celular son las que tienen la mayor cantidad de adictos. `horas_redes_sociales`: En los adictos, dedican la mayor cantidad de horas a las redes sociales. `ratio_ratio_finde_diario`: En las personas adictas el ratio de su uso del fin de semana con el uso diario normal se mantiene cerca a uno, dejando en claro que ven la misma cantidad de horas sin importar el día. En cambio en las no adictas encontramos que el ratio de su uso del fin de semana con su uso diario tiende siempre a más que uno, por lo cual se infiere que usan menos el celular en horarios de trabajo o estudio y lo usan más en su tiempo libre. Por último hemos encontrado que el factor más determinante en clasificar a una persona como Adicto o No adicto es la cantidad de horas que dedica al celular, específicamente a redes sociales, lo cual nos servirá a futuro para el entrenamiento del modelo de clasificación. Por otro lado, al ser un set de datos sintéticos no encontramos muchos patrones clásicos relacionados con estudios previos que asocian la adicción al smartphone con menor rendimiento académico, en parte por su efecto negativo sobre el sueño (Rathakrishnan et al. 2021).

8. Limitaciones y consideraciones éticas

El archivo no incluye documentación sobre el muestreo, instrumento de medición, país, periodo de recolección ni procedimiento de etiquetado. En consecuencia, la muestra no debe asumirse representativa de la población universitaria peruana ni de un grupo demográfico específico. Además, el término “adicción” debe tratarse como una etiqueta del dataset y no como un diagnóstico clínico. La evidencia académica recomienda emplear instrumentos validados y distinguir entre uso frecuente y uso problemático Kwon et al. (2013); Csibi et al. (2018).

Referencias

- Amez, S y S Baert (2020). Smartphone Use and Academic Performance: A Literature Review. *International Journal of Educational Research* **103**, 101618.
- Csibi, S, MD Griffiths, B Cook, Z Demetrovics y A Szabo (2018). The Psychometric Properties of the Smartphone Application-Based Addiction Scale (SABAS). *International Journal of Mental Health and Addiction* **16**(2), 393-403.
- Kwon, M, JY Lee, WY Won, JW Park, JA Min, C Hahn, X Gu, JH Choi y DJ Kim (2013). Development and Validation of a Smartphone Addiction Scale (SAS). *PLOS ONE* **8**(2), e56936.
- Nusrat, Z (s.f.). *Smartphone Usage and Addiction Analysis Dataset*. Kaggle. Fecha de publicación no indicada en la página; consultado el 17 de septiembre de 2026. <https://www.kaggle.com/datasets/zahranusratt/smartphone-usage-and-addiction-analysis-dataset>.
- Rathakrishnan, B, SS Bikar Singh, MR Kamaluddin, A Yahaya, MA Mohd Nasir, F Ibrahim y Z Ab Rahman (2021). Smartphone Addiction and Sleep Quality on Academic Performance of University

Students: An Exploratory Research. *International Journal of Environmental Research and Public Health* **18**(16), 8291.

Walpole, RE, RH Myers, SL Myers y K Ye (2012). *Probabilidad y Estadística para Ingeniería y Ciencias*. 9na. Pearson Educación.