

P1 - Uso de Smartphones y Riesgo de Adiccion

Hiter Frank Rubio Peralta

Alumno

Jossep Jorge Froilan Choroco Neyra

Alumno

Joel David De la Cruz Cardenas

Alumno

Rodrigo Octavio Lucatoni Flores Ruiz

Alumno

Victor Andres Diaz Garcia

Alumno

Curso:

Introduccion a Ciencia de Datos e Inteligencia Artificial

19 de Septiembre del 2026

Tabla de contenidos

1. Resumen	3
2. Planteamiento del problema	3
3. Contexto del dataset	3
3.1. Fuente y unidad de análisis	3
3.2. Diccionario de variables	4
4. Carga y exploración inicial	5
4.1. Dimensiones y tipos de variables	5
4.2. Calidad de datos	5
5. Preprocesamiento y decisiones de data wrangling	5
5.1. Revisión de fuga de información	5
5.2. Variable derivada para la comunicación	6
6. Análisis exploratorio de datos	6
6.1. Análisis univariado	6
6.2. Análisis multivariado	7
7. Conclusiones de P1	8
8. Limitaciones y consideraciones éticas	8

Listado de Tablas

Listado de Figuras

1. Resumen

*Instrucciones para esta sección: este resumen se escribe **al final**, cuando ya se tengan los resultados de la exploración de datos y las conclusiones de P1. Debe tener entre 150 y 200 palabras e incluir, en este orden: (1) qué dataset se usó y cuántos registros/columnas tiene, (2) el objetivo del análisis (qué se busca entender sobre `addicted_label`), (3) las dos o tres decisiones de limpieza más importantes que se tomaron y por qué, (4) los dos o tres hallazgos más relevantes del EDA, citando cifras reales obtenidas del código (no inventadas ni copiadas de un borrador), y (5) una frase que conecte con lo que se hará en la P2. No copiar texto de otras secciones; debe ser una síntesis propia, escrita por el equipo.*

2. Planteamiento del problema

El uso intensivo de celulares puede influir en la salud integral de las personas al relacionarse con irregularidades en el sueño, estrés, dificultades en el ámbito académico y laboral. Además, la investigación requiere de una conceptualización alta: una alta frecuencia de uso no significa necesariamente a una condición clínica. Artículos como SABAS permiten estudiar síntomas de uso problemático, pero no sustituyen una evaluación profesional Csibi et al. (2018). La literatura también ayuda con asociaciones entre el uso del smartphone y el desempeño académico, aunque con limitaciones claras para atribuir causalidad Amez y Baert (2020).

Para este proyecto, se formula la siguiente pregunta de análisis:

¿Qué patrones de uso, descanso y contexto personal están asociados con la etiqueta de adicción en el conjunto de datos?

La P1 no entrena modelos predictivos. Su finalidad es asegurar que la P2 use variables pertinentes, datos de calidad y decisiones justificadas.

3. Contexto del dataset

3.1. Fuente y unidad de análisis

El archivo `Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv` fue proporcionado para el proyecto y corresponde al dataset publicado como *Smartphone Usage and Addiction Analysis* en Kaggle Nusrat (s.f.). Cada fila representa a un usuario y contiene indicadores demográficos, de comportamiento digital, descanso, estrés e impacto percibido en actividades académicas o laborales.

La unidad de análisis es el usuario. El dataset incluye 7,500 registros y 16 columnas originales: dos identificadores, nueve variables numéricas, cuatro variables categóricas y la etiqueta binaria objetivo.

```
# Cargamos el archivo csv
import kagglehub
path = kagglehub.dataset_download("jayjoshi37/smartphone-usage-and-addiction-prediction")
import os

# Ruta directa al archivo CSV combinando la ruta de descarga y el nombre del archivo
ruta_csv = os.path.join(path, "Smartphone_Usage_And_Addiction_Analysis_7500_Rows.csv")
df = pd.read_csv(ruta_csv)
```

```
# Analizamos las primeras filas
df.head(10)

# Analizamos los tipos de variables contenidos en la csv
df.info() # Observamos valores nulos en la columna "addiction_level"

# Obtenemos la lista de columnas
df.columns

# Renombramos todas las columnas para un uso natural
df = df.rename({'transaction_id':'ID_transaccion' , 'user_id':'ID_usuario' , 'age':'edad' }
```

```
<class 'pandas.DataFrame'>
```

```
RangeIndex: 7500 entries, 0 to 7499
```

```
Data columns (total 16 columns):
```

#	Column	Non-Null Count	Dtype
0	transaction_id	7500 non-null	str
1	user_id	7500 non-null	str
2	age	7500 non-null	int64
3	gender	7500 non-null	str
4	daily_screen_time_hours	7500 non-null	float64
5	social_media_hours	7500 non-null	float64
6	gaming_hours	7500 non-null	float64
7	work_study_hours	7500 non-null	float64
8	sleep_hours	7500 non-null	float64
9	notifications_per_day	7500 non-null	int64
10	app_opens_per_day	7500 non-null	int64
11	weekend_screen_time	7500 non-null	float64
12	stress_level	7500 non-null	str
13	academic_work_impact	7500 non-null	str
14	addiction_level	6681 non-null	str
15	addicted_label	7500 non-null	int64

```
dtypes: float64(6), int64(4), str(6)
```

```
memory usage: 937.6 KB
```

3.2. Diccionario de variables

- **Identificadores:** ID_transaccion y ID_usuario son variables de texto. Se usan para verificar unicidad, pero no aportan significado analítico y se excluirán como predictores.
- **Demografía:** edad (numérica) y genero (categórica) caracterizan la muestra.
- **Uso del smartphone:** horas_diarias_pantalla, horas_redes_sociales, horas_videojuegos, horas_trabajo/estudio, notificaciones_por_dia,

`aperturas_apps_por_dia` y `tiempo_en_pantalla_fin_de_semana` son variables numéricas que miden intensidad y tipo de uso.

- **Bienestar y contexto:** `horas_sueño` es numérica; `nivel_estres` y `impacto_academico/laboral` son categóricas. Se emplean para explorar descanso e impacto funcional.
- **Severidad:** `nivel_adiccion` es categórica ordinal. Se describe en P1, pero se excluye como predictor en P2 por fuga de información.
- **Objetivo:** `etiqueta_de_adiccion` es binaria: 0 significa *No adicción* y 1 significa *Con adicción*.

La variable `nivel_adiccion` contiene una categorización de severidad (None, Mild, Moderate, Severe). Por su definición operativa, puede estar construida directamente a partir de la etiqueta final; por ello se audita explícitamente antes de considerar su uso en P2.

4. Carga y exploración inicial

4.1. Dimensiones y tipos de variables

```
# TODO: mostrar df.shape y df.dtypes (o df.info()) para revisar dimensiones y tipos de va
```

Instrucciones para esta sección: comentar, con base en la salida real de `df.info()` / `df.dtypes`, cuántas filas y columnas tiene el dataset, qué columnas son numéricas y cuáles categóricas, y si algún tipo de dato no corresponde con lo esperado (por ejemplo, una variable numérica cargada como texto). No repetir de memoria las cifras ya mencionadas en “Contexto del dataset”; verificarlas con el código.

4.2. Calidad de datos

```
# TODO: contar valores nulos por columna (df.isnull().sum()) y filas duplicadas (df.dupli
```

Instrucciones para esta sección: reportar cuántos valores faltantes se encontraron y en qué columna(s), y cuántas filas duplicadas existen. Explicar la causa probable de los faltantes (por ejemplo, si corresponden a una categoría real como “sin severidad registrada”) y justificar la decisión tomada: ¿se imputan, se eliminan o se excluye la columna? Si se excluye una variable por fuga de información, explicarlo aquí o remitir a la sección de fuga de información.

```
# TODO: revisar rangos (df.describe()) de las variables numéricas y valores únicos de las
```

Instrucciones para esta sección: comentar si los rangos observados en `df.describe()` son plausibles para lo que representa cada variable (por ejemplo, edades, horas de uso, horas de sueño). Señalar explícitamente cualquier valor fuera de rango lógico y qué se hizo con los identificadores (`transaction_id`, `user_id`): ¿se conservan solo como referencia o se descartan del análisis?

5. Preprocesamiento y decisiones de data wrangling

5.1. Revisión de fuga de información

```
# TODO: construir una tabla cruzada (pd.crosstab) entre addiction_level y addicted_label
```

Instrucciones para esta sección: interpretar la tabla cruzada anterior: ¿existe alguna categoría de `addiction_level` que se asocie de forma perfecta o casi perfecta con una sola clase de `addicted_label`? Si es así, explicar por qué eso constituye **fuga de información** y qué variables se decide excluir de X para la P2 (y por qué).

Instrucciones para esta sección: explicar por qué excluir las variables identificadas en el punto anterior protege la validez de la evaluación del modelo. Indicar además qué método de codificación se planea usar en P2 para cada variable categórica (`gender`, `academic_work_impact`, `stress_level`) y por qué (one-hot, binaria, ordinal, etc.), aclarando que cualquier transformación debe ajustarse solo con los datos de entrenamiento. Si se usa `scikit-learn` para esto, citar la librería (Pedregosa et al. (2011)).

5.2. Variable derivada para la comunicación

```
# TODO: crear una columna nueva (por ejemplo, estado_adiccion) que traduzca addicted_label
```

Instrucciones para esta sección: confirmar que la nueva variable de etiquetas legibles no introduce ninguna información distinta a `addicted_label` (es solo una versión “para humanos” de la misma columna) y aclarar que para el modelamiento en P2 se seguirá usando la versión numérica original.

6. Análisis exploratorio de datos

6.1. Análisis univariado

```
# TODO: graficar la distribución de addicted_label (conteo y/o porcentaje por clase).
```

Instrucciones para esta sección: reportar cuántos registros hay en cada clase de `addicted_label` (conteo y porcentaje) y comentar si existe desbalance de clases. Si lo hay, explicar qué implicancia tiene para la partición entrenamiento/prueba y las métricas que se deberán usar en P2 (por ejemplo, estratificación, F1, recall).

```
# TODO: graficar un histograma por cada variable numérica.
```

Instrucciones para esta sección: para cada histograma, describir la forma de la distribución (simétrica, sesgada, con varias modas) y qué implica para el análisis (por ejemplo, si conviene una transformación o estandarización más adelante). Comentar si alguna variable de conteo tiene una escala muy distinta a las variables medidas en horas.

```
# TODO: graficar un boxplot por cada variable numérica.
```

Instrucciones para esta sección: comentar, variable por variable, la dispersión, la posible presencia de outliers y la simetría observada en los boxplots. Discutir si esos valores extremos deberían tratarse como errores de captura o si son observaciones reales del comportamiento de los usuarios, y justificar la decisión tomada.

```
# TODO: calcular media, mediana, moda, desviación estándar, varianza, rango y cuartiles p
```

Instrucciones para esta sección: comparar media y mediana para detectar asimetría en cada variable, e interpretar la desviación estándar en el contexto de la escala de cada una (no comparar directamente variables con unidades distintas). Señalar qué variables muestran mayor dispersión o valores extremos.

TODO: graficar la frecuencia de las variables categóricas (gender, stress_level, academ

Instrucciones para esta sección: describir qué categorías son dominantes o poco frecuentes en cada variable categórica y comentar si eso podría afectar el análisis posterior (por ejemplo, categorías con muy pocos casos). Indicar si alguna de estas variables se tratará como ordinal y por qué.

6.2. Análisis multivariado

TODO: graficar un mapa de calor de correlaciones entre las variables numéricas.

Instrucciones para esta sección: identificar en el mapa de calor los pares de variables con correlación fuerte (positiva o negativa) y comentar si sugieren colinealidad. Aclarar que la correlación no implica causalidad.

TODO: calcular y ordenar las correlaciones de cada variable numérica con addicted_label

Instrucciones para esta sección: comentar qué variables tienen mayor asociación lineal con la etiqueta objetivo y cuáles tienen asociación muy baja. Aclarar que esto es solo un indicio y no una selección final de variables para el modelo.

TODO: graficar boxplots comparativos de variables numéricas clave (por ejemplo, horas d

Instrucciones para esta sección: comentar cómo cambian la tendencia central y la dispersión de cada variable entre las dos clases, y si hay solapamiento amplio entre grupos (lo que anticiparía dificultad para separar las clases con un solo predictor).

TODO: graficar histogramas o barras agrupadas comparando subgrupos (por ejemplo, stress

Instrucciones para esta sección: interpretar las proporciones (no solo los conteos) entre subgrupos, evitando conclusiones que estigmaticen a los usuarios. Comentar si estas variables parecen ser causa, consecuencia o simplemente indicadores asociados al uso problemático.

TODO: graficar al menos 5 diagramas de dispersión (scatterplots) entre pares de variabl

Instrucciones para esta sección: para cada par de variables, comentar si se observa un patrón (lineal o no lineal), agrupamientos, o separación visible entre clases. Si los colores se solapan mucho, señalar que esas dos variables por sí solas no bastan para separar las clases.

TODO: calcular la covarianza entre pares de variables numéricas relevantes.

Instrucciones para esta sección: interpretar el signo de la covarianza (si dos variables crecen o decrecen juntas) y explicar por qué se complementa con la correlación (que sí permite comparar la fuerza de la relación entre variables con escalas distintas).

7. Conclusiones de P1

Instrucciones para esta sección: redactar entre 4 y 6 conclusiones numeradas, basadas únicamente en los resultados obtenidos arriba (no inventar cifras). Deben cubrir, como mínimo: (1) calidad de datos (nulos, duplicados) y qué se hizo al respecto, (2) si la clase objetivo está balanceada o no y qué implica para P2, (3) qué variables se excluyen como predictoras y por qué, (4) qué variables lucen más prometedoras para el modelamiento, y (5) qué se debe tener en cuenta al pasar a la P2 (codificación, escalamiento, evaluación).

8. Limitaciones y consideraciones éticas

El archivo no incluye documentación sobre el muestreo, instrumento de medición, país, periodo de recolección ni procedimiento de etiquetado. En consecuencia, la muestra no debe asumirse representativa de la población universitaria peruana ni de un grupo demográfico específico. Además, el término “adicción” debe tratarse como una etiqueta del dataset y no como un diagnóstico clínico. La evidencia académica recomienda emplear instrumentos validados y distinguir entre uso frecuente y uso problemático Kwon et al. (2013); Csibi et al. (2018).

Si este análisis se trasladara a un contexto real, la privacidad, el consentimiento informado y el riesgo de estigmatización serían centrales. Una predicción debe apoyar la prevención o la derivación voluntaria, nunca justificar sanciones automáticas o decisiones de alto impacto.

Referencias

- Amez, S y S Baert (2020). Smartphone Use and Academic Performance: A Literature Review. *International Journal of Educational Research* **103**, 101618.
- Csibi, S, MD Griffiths, B Cook, Z Demetrovics y A Szabo (2018). The Psychometric Properties of the Smartphone Application-Based Addiction Scale (SABAS). *International Journal of Mental Health and Addiction* **16**(2), 393-403.
- Kwon, M, JY Lee, WY Won, JW Park, JA Min, C Hahn, X Gu, JH Choi y DJ Kim (2013). Development and Validation of a Smartphone Addiction Scale (SAS). *PLOS ONE* **8**(2), e56936.
- Nusrat, Z (s.f.). *Smartphone Usage and Addiction Analysis Dataset*. Kaggle. Fecha de publicación no indicada en la página; consultado el 17 de septiembre de 2026. <https://www.kaggle.com/datasets/zahranusratt/smartphone-usage-and-addiction-analysis-dataset>.
- Pedregosa, F, G Varoquaux, A Gramfort, V Michel, B Thirion, O Grisel, M Blondel, P Prettenhofer, R Weiss, V Dubourg, J Vanderplas, A Passos, D Cournapeau, M Brucher, M Perrot y É Duchesnay (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* **12**, 2825-2830.