

Guía de fórmulas estadísticas del proyecto

Predicción de adicción al smartphone · Uso correcto y citas académicas

Este documento resume las 3 fórmulas estadísticas estándar que probablemente usaremos en el análisis del dataset de Kaggle sobre uso y adicción al smartphone. Para cada una se explica qué mide, cómo se calcula, un ejemplo numérico, y cómo citarla correctamente en el informe (references.bib, formato Quarto).

1. Correlación de Pearson (r)

¿Qué mide?

Mide qué tan fuerte y en qué dirección se relacionan linealmente dos variables numéricas (por ejemplo: tiempo de pantalla vs. nivel de adicción). El resultado va de -1 a 1:

- r cercano a +1: relación positiva fuerte (cuando una sube, la otra también sube)
- r cercano a -1: relación negativa fuerte (cuando una sube, la otra baja)
- r cercano a 0: casi no hay relación lineal entre ellas

Fórmula

```
Numerador: suma[ (x_i - x_prom) * (y_i - y_prom) ]
Denominador: raiz[ suma(x_i - x_prom)^2 ] * raiz[ suma(y_i - y_prom)^2 ]
r = Numerador / Denominador
```

Donde x_i y y_i son cada observación (cada fila del dataset), y x_{prom} / y_{prom} son los promedios de cada variable.

Ejemplo

Un estudio con dataset similar al nuestro (Azeez, 2026) encontró:

- Tiempo de pantalla vs. adicción: $r = 0.721$ (relación positiva fuerte)
- Duración del sueño vs. adicción: $r = -0.611$ (relación negativa fuerte)

Interpretación: a más horas de pantalla, más probabilidad de adicción; a más horas de sueño, menos probabilidad de adicción. Si en nuestro dataset calculamos, por ejemplo, $r = 0.68$ entre 'notificaciones diarias' y 'horas de uso', se interpreta como una asociación positiva fuerte similar a la reportada en la literatura.

Cómo citarla

En el texto del informe (.qmd): "Se observó una correlación positiva fuerte entre tiempo de pantalla y adicción ($r = 0.68$), consistente con hallazgos previos [azeez2026ml]."

Entrada ya disponible en references.bib: **azeez2026ml**

2. Métricas de clasificación (Accuracy, Precision, Recall, F1, AUC)

¿Qué miden?

Si el equipo entrena un modelo que predice "adicto" / "no adicto", estas métricas evalúan qué tan bien acierta el modelo. Se basan en 4 resultados posibles al comparar la predicción vs. la realidad: Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN).

Fórmulas

$$\text{Accuracy} = (\text{VP} + \text{VN}) / (\text{VP} + \text{VN} + \text{FP} + \text{FN})$$
$$\text{Precision} = \text{VP} / (\text{VP} + \text{FP})$$
$$\text{Recall} = \text{VP} / (\text{VP} + \text{FN})$$
$$\text{F1-score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$$

AUC-ROC no tiene una fórmula tan directa: mide el área bajo la curva que compara la tasa de verdaderos positivos contra la tasa de falsos positivos en distintos umbrales de decisión. Va de 0.5 (modelo que adivina al azar) a 1.0 (modelo perfecto).

Ejemplo

Un estudio con dataset similar (Azeez, 2026) reportó para su mejor modelo (Random Forest):

Accuracy = 88.4% | F1-score = 0.898 | AUC = 0.923

Interpretación: el modelo clasificó correctamente al 88.4% de los usuarios, con buen balance entre precisión y recall (F1 alto), y una capacidad muy fuerte para distinguir adictos de no adictos (AUC cercano a 1).

Cómo citarlas

Las fórmulas en sí son estándar de la disciplina (no requieren cita si solo las usas como herramienta), pero Sí debes citar la fuente si comparas tus resultados contra los de otro estudio, o si usas una implementación específica (ej. scikit-learn) o un algoritmo con nombre propio.

Ejemplo en el texto: "Nuestro modelo de Random Forest [breiman2001randomforests] obtuvo un F1-score de 0.85, cercano al 0.898 reportado por Azeez [azeez2026ml] en un dataset similar."

Entradas disponibles en references.bib: **breiman2001randomforests**, **cortesvapnik1995svm**, **hosmer2013logistic**, **azeez2026ml**

3. SMOTE (balanceo de clases)

¿Qué hace?

SMOTE (Synthetic Minority Over-sampling Technique) no es una fórmula de evaluación, sino una técnica de preprocesamiento. Se usa cuando el dataset está desbalanceado (ej. muchos más "no adictos" que "adictos"), porque eso hace que el modelo tienda a predecir siempre la clase mayoritaria. SMOTE genera ejemplos sintéticos de la clase minoritaria en vez de simplemente duplicar filas existentes.

Cómo funciona (idea general)

- 1) Para cada ejemplo de la clase minoritaria, busca sus "vecinos" más cercanos (otros ejemplos parecidos de la misma clase).
- 2) Crea un nuevo punto sintético en algún lugar "entre" el ejemplo original y uno de sus vecinos (interpolación), no una copia exacta.
- 3) Repite este proceso hasta que ambas clases queden balanceadas.

Ejemplo

Si el dataset tiene 800 usuarios "no adictos" y solo 200 "adictos", SMOTE genera aproximadamente 600 ejemplos sintéticos adicionales de la clase "adictos" (interpolados a partir de los 200 reales) para llegar a un dataset más balanceado (ej. 800 vs. 800). Importante: SMOTE debe aplicarse SOLO sobre el set de entrenamiento, nunca sobre el set de prueba, para no inflar artificialmente el desempeño del modelo.

Cómo citarla

Ejemplo en el texto: *"Debido al desbalance de clases (58% adictos vs. 42% no adictos), se aplicó SMOTE [chawla2002smote] únicamente sobre el conjunto de entrenamiento."*

Entrada disponible en references.bib: **chawla2002smote**

Recordatorio para el equipo: todas las claves de cita (@kwon2013sassv, @azeez2026ml, @breiman2001randomforests, @cortesvapnik1995svm, @hosmer2013logistic, @chawla2002smote) ya están en el archivo **references.bib** del repositorio. Solo hace falta escribir [clave] en el .qmd donde corresponda — Quarto arma la lista final de referencias automáticamente.