

PROYECTO FINAL

Walter Quispe Vargas
Docente

Curso:
Introducción a Ciencia de Datos e Inteligencia Artificial

18 de Agosto del 2026

**CIENCIA DE DATOS E
INTELIGENCIA ARTIFICIAL**

☎ (+51) 920000757
✉ wquispev@continental.edu.pe

Tabla de contenidos

1. REQUISITOS	4
2. GRAFICOS, TABLAS, FORMULAS Y CITAS	4
3. CARGAR DATOS DE UN ARCHIVO CSV	6
4. PYTHON	7
5. RESUMEN	9
6. PLANTEAMIENTO DEL PROBLEMA	9
7. CUERPO DE LA INVESTIGACIÓN	9
7.1. Población	10
7.2. Muestra	10
7.3. Variables estadísticas	10
8. TABLA ESTADÍSTICA DE FRECUENCIA DE DATOS AGRUPADOS	10
9. GRÁFICO ESTADÍSTICO	11
10. MEDIDAS DE TENDENCIA CENTRAL	14
11. MEDIDAS DE DISPERSIÓN	14
12. ESTADÍSTICA INFERENCIAL	14
12.1. Prueba de Hipótesis	14
12.2. Análisis de Regresión Lineal	15
13. CONCLUSIONES	16

Listado de Tablas

1. Ejemplo de una tabla	5
2. Primeras seis filas del set de datos cargados.	6
3. Tabla de Frecuencia Agrupada de Producción (Toneladas)	10

Listado de Figuras

1. Simulación de datos de una Distribución $N(0,1)$	4
2. Histograma de producción agrícola.	11

3.	Producción agrícola total por provincia.	12
4.	Gráfica de cajas de las variables id, producción y área sembrada.	13
5.	Gráfica de dispersión entre el área sembrada y producción.	16

1. REQUISITOS

Instalar:

- LaTeX mediante la distribución *MikTeX* <https://miktex.org>
- Quarto <https://quarto.org>
- R and Rstudio <https://posit.co/download/rstudio-desktop/>
- Explorar Positron (new IDL) <https://positron.posit.co>

2. GRAFICOS, TABLAS, FORMULAS Y CITAS

En el artículo famoso, Box y Cox (1964) introdujeron una **familia de transformaciones** ... (recuerda usar el archivo `references.bib` para editar los artículos, libros y demas citas.)

```
library(tidyverse)
set.seed(1234)
df <- tibble(x = rnorm(200))
df |>
  ggplot(aes(x=x)) +
  geom_density(bw = "SJ", color = "magenta") +
  geom_rug(alpha=0.9, color = "cyan")
```




Figura 1: Simulación de datos de una Distribución $N(0,1)$.

La Figura 1 muestra el *Kernel* de una distribución Normal Estándar “ $N(0, 1)$ ” simulada. La varianza muestral esta dada por:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = 1.02. \quad (1)$$

Notar que la Ecuación 1 es un estimador insegado de la varianza, pero no es un estimador de maxima *verosimilitud* (Rice 2007, pág. 269).

```
library(knitr)
library(kableExtra)
head(iris,10) |>
  kable(booktabs = TRUE,
        align = 'cccl',
        linesep = "" ,
        format.args = list(big.mark = ",", digits = 4)) |>
  kable_styling(latex_options = c("HOLD_position","striped"),
               font_size = 11)%>%
  row_spec(0, align = "c",bold=T )
```

Tabla 1: Ejemplo de una tabla

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa
4.6	3.4	1.4	0.3	setosa
5.0	3.4	1.5	0.2	setosa
4.4	2.9	1.4	0.2	setosa
4.9	3.1	1.5	0.1	setosa

La Tabla 1 muestra las primeras 10 filas del *dataset* **IRIS**...

3. CARGAR DATOS DE UN ARCHIVO CSV

Para cargar a R datos de un archivo .csv tenemos la siguiente línea de código:

```
data = read.csv('datos/resultados_modelo_ventas.csv')
head(data,6) |>
  kable(booktabs = TRUE,
        align = 'cccl',
        linesep = "" ,
        format.args = list(big.mark = ",", digits = 4)) |>
  kable_styling(latex_options = c("HOLD_position","striped"),
               font_size = 11) %>%
  row_spec(0, align = "c",bold=T )
```

Tabla 2: *Primeras seis filas del set de datos cargados.*

Producto	Categoría_Producto	Precio	Ventas_Predichas	Mes
Producto C	Alimentos	79.76	818.8	2023-01-31
Producto A	Alimentos	94.55	943.6	2023-02-28
Producto C	Electrónica	90.53	736.1	2023-03-31
Producto C	Alimentos	63.81	559.8	2023-04-30
Producto A	Electrónica	92.97	856.6	2023-05-31
Producto A	Alimentos	17.96	880.4	2023-06-30

La Tabla 2 muestra las primeras 6 filas del archivo cargado .

4. PYTHON

Usamos la libreria reticulate para ejecutar codigo de python y su enviroment

```
library(reticulate)
use_virtualenv("r-reticulate", required = TRUE)
py_config()
```

```
python:          /Users/nate/.virtualenvs/r-reticulate/bin/python
libpython:       /Library/Frameworks/Python.framework/Versions/3.11/lib/python3.11/config-
pythonhome:      /Users/nate/.virtualenvs/r-reticulate:/Users/nate/.virtualenvs/r-reticula
version:         3.11.4 (v3.11.4:d2340ef257, Jun  6 2023, 19:15:51) [Clang 13.0.0 (clang-1
numpy:           /Users/nate/.virtualenvs/r-reticulate/lib/python3.11/site-packages/numpy
numpy_version:   2.4.4
```

NOTE: Python version was forced by use_python() function

Python code:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import time
data = pd.read_csv('datos/breast_cancer.csv')
data.head()
```

	id	diagnosis	...	fractal_dimension_worst	Unnamed: 32
0	842302	M	...	0.11890	NaN
1	842517	M	...	0.08902	NaN
2	84300903	M	...	0.08758	NaN
3	84348301	M	...	0.17300	NaN
4	84358402	M	...	0.07678	NaN

[5 rows x 33 columns]

```
col = data.columns
print(col)
```

```
Index(['id', 'diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean',  
      'area_mean', 'smoothness_mean', 'compactness_mean', 'concavity_mean',  
      'concave points_mean', 'symmetry_mean', 'fractal_dimension_mean',  
      'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se',  
      'compactness_se', 'concavity_se', 'concave points_se', 'symmetry_se',  
      'fractal_dimension_se', 'radius_worst', 'texture_worst',  
      'perimeter_worst', 'area_worst', 'smoothness_worst',  
      'compactness_worst', 'concavity_worst', 'concave points_worst',  
      'symmetry_worst', 'fractal_dimension_worst', 'Unnamed: 32'],  
      dtype='str')
```

5. RESUMEN

Este estudio presenta un análisis estadístico aplicado a datos simulados de producción agrícola en cinco provincias del departamento de Cusco, considerando diversos cultivos representativos de la región. La investigación se desarrolló con el objetivo de observar patrones productivos, estimar medidas estadísticas clave y aplicar pruebas de hipótesis e inferencia, como análisis de regresión lineal. La generación de datos sintéticos permitió representar escenarios realistas de comportamiento agrícola en ausencia de registros oficiales completos. Se construyó una base de datos que incluye variables como área sembrada y toneladas de producción, lo que facilitó la aplicación de estadística descriptiva y modelos predictivos. Los resultados evidencian una fuerte correlación positiva entre el área sembrada y la producción, lo que sugiere que la planificación adecuada del uso del suelo podría mejorar significativamente el rendimiento agrícola. Asimismo, las pruebas de hipótesis realizadas permiten validar diferencias estadísticas relevantes entre grupos de cultivo. Este análisis aporta una base sólida para orientar decisiones técnicas y políticas, contribuyendo a una gestión más eficiente de los recursos agrícolas en el contexto regional.

6. PLANTEAMIENTO DEL PROBLEMA

La actividad agrícola en la región Cusco representa un pilar económico fundamental, especialmente en zonas rurales donde gran parte de la población depende directa o indirectamente de la agricultura para su sustento. No obstante, los registros de producción no siempre se encuentran actualizados, estandarizados ni centralizados, lo que limita las posibilidades de análisis técnico en favor de la eficiencia productiva (Estadística e Informática (INEI) 2019).

Ante la ausencia de datos completos, el uso de técnicas estadísticas sobre datos simulados se presenta como una herramienta metodológicamente válida para ensayar escenarios de comportamiento agrícola. Este enfoque permite realizar estimaciones, pruebas de hipótesis y modelos predictivos que orienten la toma de decisiones públicas y privadas, incluso en contextos de baja disponibilidad de información (Agresti y Finlay 2018).

En este contexto, el presente estudio tiene como objetivo principal analizar estadísticamente la relación entre el área sembrada y la producción agrícola en toneladas, utilizando datos sintéticos representativos del entorno rural de Cusco. A través del análisis descriptivo e inferencial, se busca identificar patrones y generar evidencia útil para la gestión agrícola regional y el diseño de políticas públicas.

7. CUERPO DE LA INVESTIGACIÓN

7.1. Población

La población está compuesta por 1000 registros simulados de producción agrícola en distintas provincias, considerando cultivo, área sembrada (ha) y producción (tn).

7.2. Muestra

Se toma una muestra aleatoria simple de 200 registros para su análisis detallado.

7.3. Variables estadísticas

Área sembrada (ha): variable cuantitativa continua.

Producción (tn): variable cuantitativa continua.

Cultivo: variable cualitativa nominal.

Provincia: variable cualitativa nominal.

8. TABLA ESTADÍSTICA DE FRECUENCIA DE DATOS AGRUPADOS

Se agrupa la variable producción en intervalos de 5 toneladas para su análisis.

Tabla 3: *Tabla de Frecuencia Agrupada de Producción (Toneladas)*

grupo_prod	Frecuencia Absoluta	Marca de Clase	Frec. Acum.	Frec. Rel. %	Frec. Rel. Acum. %
[0,5)	27	2.5	27	13.5	13.5
[5,10)	37	7.5	64	18.5	32.0
[10,15)	41	12.5	105	20.5	52.5
[15,20)	48	17.5	153	24.0	76.5
[20,25)	25	22.5	178	12.5	89.0
[25,30)	12	27.5	190	6.0	95.0
[30,35)	10	32.5	200	5.0	100.0

Interpretación: La mayor frecuencia de producción se concentra entre los 10 y 20 toneladas, lo que indica un rendimiento intermedio predominante en la muestra analizada.

9. GRÁFICO ESTADÍSTICO




Figura 2: *Histograma de producción agrícola.*

Interpretación: Este histograma representa la distribución de la producción agrícola en toneladas (tn) para una muestra determinada. Se observa que la mayor concentración de frecuencias se encuentra entre los 5 y 15 tn, lo que indica que la mayoría de las producciones agrícolas están en ese rango. La barra más alta, correspondiente a este intervalo, muestra que más de 45 registros se encuentran ahí, lo que sugiere que es el nivel de producción más común. Hacia la derecha del gráfico, la frecuencia comienza a disminuir progresivamente, lo cual es indicativo de que las producciones más altas (mayores a 20 tn) son menos frecuentes. Por otro lado, también se visualiza una pequeña cantidad de producciones muy bajas, cercanas a 0 tn. En general, la distribución muestra una asimetría negativa, con una concentración de datos hacia valores bajos y una cola extendida hacia producciones más altas.

Esta tendencia puede deberse a múltiples factores como diferencias en el tamaño de las parcelas, el tipo de cultivo, las técnicas agrícolas utilizadas o condiciones climáticas. Las producciones más comunes en el rango medio podrían representar explotaciones agrícolas con niveles de tecnología o eficiencia estándar. En cambio, las pocas producciones altas podrían estar relacionadas con explotaciones altamente tecnificadas o de gran escala. La baja frecuencia de producciones cercanas a cero también podría señalar problemas puntuales como sequías, plagas o falta de recursos.




Figura 3: *Producción agrícola total por provincia.*

Interpretación: La gráfica de barras presentada muestra una comparación clara del volumen total de producción agrícola en toneladas entre las cinco provincias evaluadas: Urubamba, Cusco, Calca, Anta y Canchis. Se observa que Urubamba lidera con una producción ligeramente superior, seguida de Cusco y Calca, que presentan valores similares y bastante altos en relación con las otras provincias. Estas tres provincias superan las 500 toneladas de producción, lo cual sugiere una mayor capacidad productiva, ya sea por un mayor número de hectáreas sembradas, condiciones agroecológicas más favorables o una gestión más eficiente de los cultivos.

En contraste, Anta y especialmente Canchis registran volúmenes de producción totales menores, situándose por debajo de las 500 toneladas. Esta diferencia puede deberse a limitaciones en el acceso a tecnología, menores extensiones de cultivo o una menor productividad por hectárea. El análisis comparativo evidencia así una desigual distribución en la producción agrícola entre las provincias, lo que puede ser útil para la planificación regional, focalización de asistencia técnica o distribución de recursos. Estas diferencias también pueden orientar investigaciones futuras sobre las causas específicas de la variabilidad en el rendimiento agrícola entre provincias.




Figura 4: Gráfica de cajas de las variables id, producción y área sembrada.

Variable produccion_tn (Producción en toneladas)

La producción agrícola por unidad muestra un rango que va de aproximadamente 0 hasta más de 30 toneladas.

La mediana se ubica en torno a 13 toneladas, indicando que el 50 % de los datos tiene una producción menor o igual a ese valor.

El rango intercuartílico (RIC) (Q1 a Q3) va de aproximadamente 8 a 18 toneladas, lo que sugiere una concentración de datos en ese rango.

La asimetría es leve hacia la derecha, mostrando una mayor frecuencia de producciones bajas, pero con algunos valores superiores a 30 que podrían considerarse altos.

conclusión: La producción presenta una distribución razonablemente balanceada, con valores extremos altos pero no excesivamente dispersos.

Variable area_semrada_ha (Área sembrada en hectáreas)

Los valores oscilan entre aproximadamente 1 ha hasta 10 ha.

La mediana está cerca de 6 ha, lo que indica que la mitad de las unidades tienen una extensión sembrada menor o igual a ese valor.

El RIC se sitúa entre 4 y 8 ha, lo que refleja una cierta homogeneidad en el tamaño de las parcelas agrícolas.

No se observan valores atípicos, lo cual sugiere que el tamaño de las parcelas es bastante consistente entre las unidades productivas.

conclusión: El área sembrada presenta una distribución centrada y sin valores extremos, adecuada para comparaciones con la variable `produccion_tn` (ideal para un análisis de regresión).

10. MEDIDAS DE TENDENCIA CENTRAL

```
# A tibble: 1 x 3
  Media Mediana Moda
  <dbl>   <dbl> <dbl>
1  14.3    13.9     6
```

****Interpretación**:** La media representa el valor promedio de producción, mientras que la mediana indica el punto medio. La moda muestra la producción más común entre los agricultores.

11. MEDIDAS DE DISPERSIÓN

```
# A tibble: 1 x 4
  Rango Varianza Desviación_Estándar Coef_Variación
  <dbl>   <dbl>           <dbl>         <dbl>
1  32.9    63.8             7.99         55.8
```

Interpretación: Un coeficiente de variación bajo sugiere que los datos están relativamente concentrados cerca de la media, lo cual se interpreta como estabilidad productiva (Gonzales 2020).

12. ESTADÍSTICA INFERENCIAL

12.1. Prueba de Hipótesis

Hipótesis nula (H0): La media de producción es igual a 15 toneladas.

Hipótesis alternativa (H1): La media de producción es distinta a 15 toneladas.

One Sample t-test

```
data: muestra$produccion_tn
t = -1.1884, df = 199, p-value = 0.2361
alternative hypothesis: true mean is not equal to 15
```

95 percent confidence interval:

13.21443 15.44267

sample estimates:

mean of x

14.32855

Interpretación: Si el valor p es menor a 0.05, se rechaza la hipótesis nula. En ese caso, la producción media sería significativamente diferente a 15 toneladas.

12.2. Análisis de Regresión Lineal

Call:

```
lm(formula = produccion_tn ~ area_semrada_ha, data = muestra)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.2731	-2.0805	0.0899	2.2426	9.0861

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.08511	0.58599	-0.145	0.885
area_semrada_ha	2.54362	0.09279	27.412	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.658 on 198 degrees of freedom

Multiple R-squared: 0.7915, Adjusted R-squared: 0.7904

F-statistic: 751.4 on 1 and 198 DF, p-value: < 2.2e-16




Figura 5: Gráfica de dispersión entre el área sembrada y producción.

Interpretación: El análisis muestra que la producción aumenta con el área sembrada. El coeficiente de regresión indica cuántas toneladas se producen por hectárea adicional. Si el valor p del modelo es significativo, la relación es estadísticamente válida (Montgomery y Runger 2012).

13. CONCLUSIONES

- La producción agrícola simulada presenta una distribución relativamente normal, con promedio cercano a 15 toneladas.
- Se confirma una correlación positiva significativa entre área sembrada y producción total.
- La prueba de hipótesis sugiere que la media poblacional podría diferir del valor supuesto de 15 toneladas.
- Este estudio demuestra cómo la estadística puede apoyar la toma de decisiones en contextos agrícolas simulados, útiles para planificaciones reales.

Referencias

Agresti, A y B Finlay (2018). *Statistical Methods for the Social Sciences*. 5th. Boston, MA: Pearson.

Box, G y D Cox (1964). An analysis of transformations. *Journal of the Royal Statistical Society, Series B* **26**(2), 211-252.

Estadística e Informática (INEI), IN de (2019). *Compendio Estadístico del Sector Agrario*. <https://www.inei.gob.pe>.

Gonzales, L (2020). *Estadística Aplicada*. Universidad Nacional Mayor de San Marcos.

Montgomery, DC y GC Runger (2012). *Applied Statistics and Probability for Engineers*. John Wiley & Sons.

Rice, J (2007). *Mathematical Statistics and Data Analysis*. 3rd edition. Duxbury.